

SISTEMA DE RECOMENDAÇÃO E ALERTAS PARA IDENTIFICAR E PREVENIR ERROS DE PRESCRIÇÃO DE MEDICAMENTOS

Pedro Miguel Almeida Domingues

**Dissertação para obtenção do Grau de Mestre em
Engenharia Informática, Área de Especialização em
Jogos, Sistemas Gráficos e Interativos**

Orientadora: Dulce Mota

Co-orientador: Constantino Martins

Porto, janeiro 2026

Declaração de Integridade

Declaro ter conduzido este trabalho académico com integridade.

Não plagiei ou apliquei qualquer forma de uso indevido de informações ou falsificação de resultados ao longo do processo que levou à sua elaboração.

Portanto, o trabalho apresentado neste documento é original e de minha autoria, não tendo

sido utilizado anteriormente para nenhum outro fim.

Declaro ainda que tenho pleno conhecimento do Código de Conduta Ética do P.PORTO.

ISEP, Porto, 7 de janeiro de 2026

Resumo

Os erros de prescrição médica representam um desafio crítico de saúde pública, com impacto direto na segurança do doente e nos custos hospitalares. Este trabalho propõe a investigação e o desenvolvimento de um sistema inteligente de recomendação e alertas para identificar e prevenir estes erros.

A revisão da literatura iniciou-se com os tipos de características farmacológica e de erros de prescrição, seguida de uma análise abrangente dos tipos sistemas de recomendação e da sua aplicação no domínio da saúde, em contraste com os sistemas de alertas clínicos tradicionais. Através desta revisão, concluiu-se que as abordagens atuais, baseadas estritamente em regras, sofrem de limitações significativas, nomeadamente a "fadiga de alertas" causada pelo excesso de notificações irrelevantes. Consequentemente, identificou-se que a abordagem mais eficaz para mitigar estas limitações reside na integração de uma metodologia do tipo híbrido. Em que diferentes técnicas de filtragem serão utilizadas, nomeadamente baseadas em conhecimento e contexto, e também combinando a robustez das regras clínicas determinísticas (para validações críticas) com a capacidade de interpretação semântica dos Grandes Modelos de Linguagem (LLM) melhorados pela técnica de *Retrieval-Augmented Generation* (RAG) e com interpretação do contexto clínico do doente, através do potencial dos *embeddings* clínicos e da arquitetura *Transformer*. Esta escolha justifica-se pela necessidade de aliar a precisão das regras à capacidade da IA em interpretar o contexto clínico do doente, permitindo uma deteção personalizada e contextualizada de interações e contraindicações que os sistemas rígidos não conseguem realizar.

A dissertação foi desenvolvida no âmbito do Mestrado em Engenharia Informática - Jogos, Sistemas Gráficos e Interativos (PREPD / DIMEI) do Instituto Superior de Engenharia do Porto (ISEP), juntamente com o GECAD.

A investigação efetuada apresenta as oportunidades e os desafios éticos e técnicos inerentes à aplicação de IA na área da saúde, sendo uma base sólida para o desenvolvimento e validação futura de um protótipo flexível, eficaz e seguro.

Palavras-chave: Sistemas de Recomendação, Erros de Prescrição, Sistemas de Recomendação em Saúde, Grandes Modelos de Linguagem (LLM), *Retrieval-Augmented Generation* (RAG), Apoio à Decisão Clínica, Segurança do Doente.

Abstract

Prescription errors represent a critical public health challenge, with a direct impact on patient safety and hospital costs. This work proposes the research and development of an intelligent recommendation and alert system to identify and prevent these errors.

The literature review began with the types of pharmacological characteristics and prescription errors, followed by a comprehensive analysis of the types of recommendation systems and their application in the health domain, in contrast to traditional clinical alert systems. Through this review, it was concluded that current approaches, based strictly on rules, suffer from significant limitations, namely “alert fatigue” caused by an excess of irrelevant notifications. Consequently, it was identified that the most effective approach to mitigate these limitations lies in the integration of a hybrid methodology. In which different filtering techniques will be used, namely based on knowledge and context, and also combining the robustness of deterministic clinical rules (for critical validations) with the semantic interpretation capacity of Large Language Models (LLMs) enhanced by the Retrieval-Augmented Generation (RAG) technique and with interpretation of the patient's clinical context, through the potential of clinical embeddings and Transformer architecture. This choice is justified by the need to combine the accuracy of the rules with the AI's ability to interpret the patient's clinical context, enabling personalized and contextualized detection of interactions and contraindications that rigid systems cannot perform.

This dissertation was developed within the scope of the Master in Informatics Engineering - Games, Graphics, and Interactive Systems (PREPD / DIMEI) at the School of Engineering of the Polytechnic of Porto (ISEP), in collaboration with the GECAD research group.

The conducted research presents the opportunities as well as the ethical and technical challenges inherent to the application of AI in healthcare, providing a solid foundation for the future development and validation of a flexible, effective, and safe prototype.

Keywords: Recommender Systems, Prescription Errors, Health Recommender Systems, Large Language Models (LLM), Retrieval-Augmented Generation (RAG), Clinical Decision Support, Patient Safety.

Agradecimentos

Em primeiro lugar, gostaria de agradecer à minha família e à minha namorada. A vossa presença constante e o apoio incansável ajudaram imenso para o sucesso deste trabalho, dando-me a força e o ânimo necessários para superar os desafios, tanto académicos como pessoais, que surgiram ao longo deste percurso.

Aos meus orientadores, Dulce Mota e Constantino Martins, e docentes do ISEP expresso um agradecimento especial. A vossa orientação científica, aliada a uma disponibilidade constante e crítica construtiva, foi determinante para melhorar este projeto e enriquecer a minha aprendizagem.

Um agradecimento também aos meus colegas de turma do mestrado, pelo espírito de entreajuda e pelo companheirismo que tornou este percurso académico mais enriquecedor.

Por fim, quero expressar a minha gratidão a todos os que, direta ou indiretamente, ajudaram na concretização deste trabalho. O vosso contributo foi essencial para alcançar este objetivo.

Índice

1	Introdução	1
1.1	Enquadramento	1
1.2	Descrição do Problema	2
1.2.1	Descrição	2
1.2.2	Restrições.....	3
1.2.3	Desafios	3
1.3	Objetivos	4
1.4	Interpretação Analítica, Crítica e Ética	5
1.4.1	Interpretação Analítica	6
1.4.2	Interpretação Crítica.....	6
1.4.3	Interpretação Ética.....	6
1.5	Abordagem	7
1.6	Resultados Esperados	8
1.7	Principais contributos.....	8
1.8	Estrutura do Documento.....	9
2	Planeamento.....	11
2.1	Gestão de Riscos.....	11
2.1.1	Principais Riscos Identificados	11
2.1.2	Plano de Mitigação	12
2.1.3	Impacto dos Riscos	12
2.1.4	Análise Geral dos Riscos	13
2.2	Gestão de Competências	14
2.2.1	Competências Necessárias.....	14
2.2.2	Desenvolvimento de Competências	14
2.2.3	Plano de Desenvolvimento de Competências	16
2.3	Plano de Desenvolvimento	17
2.4	Planeamento do Projeto.....	18
2.4.1	<i>Project Charter</i>	18
2.4.2	Estrutura Analítica do Projeto (EAP).....	18
2.4.3	Cronograma e Entregáveis.....	19
2.4.4	Gestão de Recursos.....	20
2.4.5	Monitorização e Controlo.....	21
2.5	Conclusões do Planeamento	22
3	Revisão da Literatura	23
3.1	Introdução.....	23
3.2	Metodologia de Revisão da Literatura	23
3.2.1	Questão Principal de Pesquisa	23
3.2.2	Questões de Investigação.....	24

3.2.3	Estratégia de Pesquisa	24
3.3	Características Farmacológicas	24
3.3.1	Princípio Ativo.....	25
3.3.2	Indicações Terapêuticas	25
3.3.3	Posologia e Dose Máxima	25
3.3.4	Contraindicações.....	25
3.3.5	Interações Medicamentosas	26
3.3.6	Efeitos indesejáveis	26
3.3.7	Populações Especiais e Advertências.....	26
3.4	Erros de Medicação	26
3.4.1	Erros de Prescrição	27
3.4.2	Tipos de Erros de Prescrição	27
3.5	Sistemas de Apoio à Decisão Clínica	28
3.5.1	Evolução e Tipologia	28
3.5.2	Barreiras à Adoção e Desafios Éticos.....	29
3.5.3	Eficácia e Impacto Clínico	29
3.6	Sistemas de Recomendação	30
3.6.1	Filtragem Colaborativa (<i>Collaborative Filtering</i>).....	30
3.6.2	Filtragem Baseada em Conteúdo (<i>Content-Based</i>)	30
3.6.3	Filtragem Baseada em Conhecimento (<i>Knowledge-Based</i>)	31
3.6.4	Filtragem Demográfica.....	31
3.6.5	Sistemas Sensíveis ao Contexto (<i>Context-Aware</i>)	32
3.6.6	Filtragem Comunitária (<i>Community-Based</i>).....	32
3.6.7	Filtragem Híbrida	32
3.6.8	Comparação entre Técnicas de Filtragem.....	34
3.7	Sistemas de Recomendação em Saúde	35
3.7.1	Trabalhos relacionados.....	35
3.7.2	Limitações atuais	39
3.8	Sistemas de Recomendação com recurso a LLM	40
3.8.1	Arquitetura Transformer e LLM	41
3.8.2	<i>Retrieval-Augmented Generation</i> (RAG)	43
3.8.3	Tendências Atuais	44
3.9	Interoperabilidade e Normas de Dados Médicos	47
3.10	Métricas de Avaliação	48
3.10.1	Métricas de Performance	48
3.10.2	Métricas de Usabilidade e Aceitação	49
3.11	Conclusão da Revisão da Literatura	49
4	Conclusões.....	51
4.1	Resumo dos Resultados	51
4.2	Limitações do Estudo.....	52
4.3	Trabalhos Futuros.....	52
4.3.1	Melhorias à Metodologia	52
4.3.2	Extensão da Abordagem	53

Anexos	61
Anexo A - Project Charter	61
Anexo B - Estrutura Analítica do Projeto	64
Anexo C - Diagrama de <i>Gantt</i>	65
Anexo D - Diagrama de <i>PRISMA</i>	66

Lista de Figuras

Figura 1 - Diagrama de <i>Gantt</i> do projeto.....	20
Figura 2 - Estrutura Analítica do Projeto (EAP).....	64
Figura 4 - Diagrama de <i>PRISMA</i>	66

Lista de Tabelas

Tabela 1 - Matriz de Riscos e Mitigação	13
Tabela 2 - Matriz de Diagnóstico de Competências	14
Tabela 3 - Lista de entregáveis da unidade curricular de PREPD	19
Tabela 4 - Comparação entre Técnicas de Filtragem em Sistemas de Recomendação.	34

Acrónimos e Símbolos

Lista de Acrónimos e Definições

ACM	<i>Association for Computing Machinery</i> - Organização internacional científica e educativa dedicada à computação.
AINE	Anti-Inflamatórios Não Esteroides - Classe de medicamentos utilizados para tratar a dor e inflamação, frequentemente associados a contraindicações renais.
API	<i>Application Programming Interface (Interface de Programação de Aplicações)</i> - Conjunto de protocolos que permite a comunicação e troca de dados entre diferentes sistemas de software.
ATC	<i>Anatomical Therapeutic Chemical</i> - Sistema de classificação internacional de fármacos, divididos em grupos de acordo com o órgão ou sistema sobre o qual atuam.
Backend	A camada de acesso a dados e lógica de um sistema, responsável pelo processamento, invisível ao utilizador final.
Big Data	Conjuntos de dados extremamente grandes e complexos que exigem ferramentas avançadas para captura, gestão e processamento.
CDSS	<i>Clinical Decision Support Systems</i> (Sistemas de Apoio à Decisão Clínica) - Ferramentas informáticas desenhadas para auxiliar profissionais de saúde na tomada de decisões clínicas.
CPOE	<i>Computerized Physician Order Entry</i> - Ferramentas informáticas desenhadas para auxiliar profissionais de saúde na tomada de decisões clínicas.
DDI	<i>Drug-Drug Interactions</i> (Interações Medicamentosas) - Alteração do efeito de um fármaco devido à administração simultânea de outro.
DIMEI	Dissertação do Mestrado em Engenharia Informática - Unidade curricular final do curso onde se desenvolve o projeto prático.
DL	<i>Deep Learning</i> - Subcampo da Inteligência Artificial que utiliza redes neuronais com múltiplas camadas para aprender padrões complexos a partir de grandes volumes de dados.
EAP	Estrutura Analítica do Projeto - Decomposição hierárquica do trabalho a ser executado pela autor do projeto para cumprir os objetivos.

EHR	<i>Electronic Health Record</i> (Registo de Saúde Eletrónico) - Versão digital do histórico médico de um paciente, mantido pelo prestador de cuidados de saúde.
Embeddings	Representações vetoriais de dados (como palavras ou códigos médicos) num espaço multidimensional, capturando o seu significado semântico.
EM	Erro de Medicação - Qualquer evento medicamentoso evitável que possa causar ou levar ao uso inadequado do medicamento ou a danos no doente.
FHIR	<i>Fast Healthcare Interoperability Resources</i> - Norma para a troca de informações de saúde eletrónicas, facilitando a interoperabilidade entre sistemas distintos.
Frontend	A interface gráfica de uma aplicação com a qual o utilizador interage diretamente.
GAT	<i>Graph Attention Networks</i> (Redes de Atenção em Grafos) - Tipo de rede neuronal que opera em dados estruturados em grafos, utilizando mecanismos de atenção.
GECAD	<i>Research Group on Intelligent Engineering and Computing for Advanced Innovation and Development</i> - Grupo de investigação do ISEP onde o projeto se insere.
GNN	<i>Graph Neural Networks</i> (Redes Neurais de Grafos) - Classe de redes neurais desenhadas para realizar inferências sobre dados descritos por grafos.
GPU	<i>Graphics Processing Unit</i> (Unidade de Processamento Gráfico) - Hardware especializado utilizado para acelerar o treino de modelos de Inteligência Artificial.
IA	Inteligência Artificial - Ramo da ciência da computação que se dedica ao desenvolvimento de sistemas capazes de realizar tarefas que requerem inteligência humana.
ICD	<i>International Classification of Diseases</i> (Classificação Internacional de Doenças) - Sistema global de categorização de doenças e problemas relacionados com a saúde.
IEEE	<i>Institute of Electrical and Electronics Engineers</i> - Organização profissional técnica dedicada ao avanço da tecnologia e engenharia.
ISEP	Instituto Superior de Engenharia do Porto - Instituição de ensino superior onde o mestrado é lecionado.
JSON	<i>JavaScript Object Notation</i> - Formato estruturado de intercâmbio de dados, fácil de ler e escrever por humanos e máquinas.

LLM	<i>Large Language Models</i> (Grandes Modelos de Linguagem) - Modelos de IA treinados em vastas quantidades de texto capazes de compreender e gerar linguagem natural.
LSTM	<i>Long Short-Term Memory</i> - Arquitetura de rede neuronal recorrente capaz de aprender dependências de longo prazo em sequências de dados.
MEI	Mestrado em Engenharia Informática
MIMIC	<i>Medical Information Mart for Intensive Care</i> - Base de dados pública de cuidados intensivos utilizada para investigação em informática médica.
ML	<i>Machine Learning</i> (Aprendizagem Automática) - Campo da IA que permite aos sistemas aprenderem e melhorarem a partir da experiência sem serem explicitamente programados.
MPNN	<i>Message Passing Neural Network</i> (Rede Neuronal de Passagem de Mensagens) - Arquitetura de rede neuronal para grafos onde os “nós” trocam informações (mensagens) com os seus vizinhos.
MVP	<i>Minimum Viable Product</i> (Produto Mínimo Viável) - Versão de um produto com funcionalidades suficientes para satisfazer os primeiros utilizadores e obter feedback.
NHS	<i>National Health Service</i> - Serviço Nacional de Saúde do Reino Unido.
PID	<i>Proportional-Integral-Derivative</i> (Derivada-Integral-Proporcional) - Mecanismo de controlo por realimentação utilizado em sistemas industriais e adaptado para otimização de funções de perda em IA.
PREPD	Preparação para Dissertação - Unidade curricular focada no planeamento e revisão bibliográfica do projeto de mestrado.
PRISMA	<i>Preferred Reporting Items for Systematic Reviews and Meta-Analyses</i> - Conjunto de diretrizes para reportar revisões sistemáticas e meta-análises.
Prompt	Instrução textual fornecida a um modelo de linguagem para guiar a sua resposta ou tarefa.
RAG	<i>Retrieval-Augmented Generation</i> - Técnica que otimiza a saída (<i>output</i>) de um LLM ao referenciar uma base de conhecimento externa fidedigna antes de gerar a resposta.
RAM	Reações Adversas a Medicamentos - Efeitos nocivos e não intencionais resultantes da utilização de um medicamento.

RCM	Resumo das Características do Medicamento - Documento oficial aprovado, geralmente pelo INFARMED, que descreve as propriedades e as condições de utilização segura de um medicamento.
RGPD	Regulamento Geral sobre a Proteção de Dados - Legislação sobre a proteção de dados e privacidade para todos os cidadãos da União Europeia.
RNN	<i>Recurrent Neural Network</i> (Redes Neurais Recorrentes) - Classe de redes neurais artificiais onde as conexões entre nós formam um grafo direcionado ao longo de uma sequência temporal.
RSE	Registo de Saúde Eletrónico - Repositório digital de informações de saúde de um paciente.
SPMS	Serviços Partilhados do Ministério da Saúde - Entidade responsável pelos sistemas de informação da saúde em Portugal.
Sprint	Período de tempo fixo (geralmente quinzenal) durante o qual tarefas específicas devem ser completadas, no contexto de metodologias ágeis.
STOPP	<i>Screening Tool of Older Persons' Prescriptions</i> - Ferramenta de rastreio para detetar prescrições potencialmente inapropriadas em idosos.
SUS	<i>System Usability Scale</i> - Escala com um conjunto de 10 questões para avaliação da usabilidade de sistemas.
Synthea	Ferramenta de acesso aberto para a geração de registos de pacientes sintéticos e realistas.
TAM	<i>Technology Acceptance Model</i> - Teoria que modela como os utilizadores aceitam e usam uma tecnologia.
Transformer	Arquitetura de <i>Deep Learning</i> baseada em mecanismos de atenção, que serve de base para a maioria dos LLM modernos.
UCI	Unidades de Cuidados Intensivos - Secção hospitalar especializada no tratamento de doentes graves.
UX	<i>User Experience</i> (Experiência do Utilizador) - O conjunto de sentimentos e interações de uma pessoa ao utilizar um sistema ou produto.

Lista de Símbolos

$\approx$	Aproximadamente
$>$	Maior que
$\geq$	Maior ou igual que
$\mathbf{d}$	Vetor do documento
$\mathbf{d}_k$	Dimensão dos vetores chave (<i>Keys</i>)
$\mathbf{h}_t$	Estado oculto no instante t
$\mathbf{K}$	Matriz de Chaves (<i>Keys</i>)
n	Tamanho da sequência ou número de amostras
$\mathcal{O}(n)$	Notação <i>Big O</i> (Complexidade temporal)
$\mathbf{Q}$	Matriz de Consultas (<i>Queries</i>)
$\mathbf{q}$	Vetor da consulta
$\mathbf{V}$	Matriz de <i>Values</i> (Valores)
$\text{sim}(\mathbf{q}, \mathbf{d})$	Pontuação de similaridade entre a consulta e o documento

1 Introdução

Este capítulo tem como objetivo apresentar uma contextualização do projeto a desenvolver na área de sistemas de recomendação relacionados com a identificação e prevenção de erros de prescrição de medicamentos.

Inicia-se com o enquadramento do projeto, seguida da caracterização do problema e da explicitação dos objetivos que orientam a sua conceção.

Adicionalmente, é apresentada uma abordagem proposta para a concretização dos objetivos deste projeto, bem como a metodologia de investigação, concluindo com a descrição da estrutura deste mesmo documento.

1.1 Enquadramento

Este relatório de dissertação do Mestrado em Engenharia Informática (MEI) do Instituto Superior de Engenharia do Porto (ISEP) teve uma duração de 1 ano, com o apoio do *Research Group on Intelligent Engineering and Computing for Advanced Innovation and Development* (GECAD).

A prescrição de medicamentos constitui uma das etapas mais críticas do processo terapêutico, esta desempenha um papel crucial na eficácia dos tratamentos e na segurança dos doentes.

Na última década, diversos estudos mostram que os erros de prescrição continuam a ser um problema persistente e de grande impacto nos sistemas de saúde. A revisão de Elliott *et al.* [1] estimou que 237 milhões de erros de medicação ocorrem anualmente durante o processo de medicação em Inglaterra, sendo que 38,4% acontecem nos cuidados primários e 72% têm pouco ou nenhum potencial de dano, no entanto, 66 milhões são potencialmente significativos clinicamente. As reações adversas evitáveis custaram ao *National Health Service* (NHS) cerca de 98.462.582 libras por ano ($\approx 111.582.228,74$ €), com a utilização de 181.626 dias de internamento, provocando cerca de 1.708 mortes. Destas incluem eventos adversos nos cuidados primários que levam a internamento hospitalar (83,7 milhões de libras, provocando

627 mortes) e eventos adversos nos cuidados secundários que levam a internamentos hospitalares mais longos (14,8 milhões de libras, provocando 1.081 mortes).

Atualmente verifica-se uma crescente digitalização dos sistemas de informação em saúde, gerido em Portugal pelos Serviços Partilhados do Ministério da Saúde (SPMS) [2], e a adoção generalizada de registos clínicos eletrónicos, o que permite emergir novas oportunidades para o desenvolvimento de ferramentas inteligentes capazes de apoiar os profissionais de saúde no processo de prescrição. Em particular, os Sistemas de Recomendação têm sido amplamente adotados em múltiplos setores, nomeadamente no entretenimento e e-commerce, demonstrando elevada eficácia na personalização de decisões complexas, e começam a ser aplicados ao domínio da saúde, o que pode incluir a prescrição médica, quanto à deteção de interações medicamentosas, contraindicações e terapias duplicadas [3],[4].

1.2 Descrição do Problema

1.2.1 Descrição

O problema de investigação deste projeto foca-se na elevada prevalência de erros de prescrição de medicação e na insuficiência das ferramentas atuais para mitigar este risco de forma eficaz e personalizada. Esta situação resulta num risco elevado de morbimortalidade para os pacientes e em custos para as instituições de saúde e para a economia geral.

A causa principal deste problema não se limita apenas ao erro do profissional de saúde, mas estende-se à escassez de *software* inteligente capaz de oferecer recomendações contextualizadas em tempo real.

Este problema tem-se tornado mais evidente devido a vários fatores, nomeadamente:

- **Complexidade Farmacológica:** Os medicamentos possuem características específicas e múltiplas variáveis (grupo farmacológico, princípio ativo, dosagem, via de administração, indicações, contraindicações, interações medicamentosas), tornando o processo de prescrição e administração mais complexo, sendo por vezes difícil para o profissional de saúde considerar todas as permutações possíveis durante uma consulta rápida.
- **Limitações dos Sistemas Atuais:** A maioria das ferramentas de suporte à decisão baseia-se em regras rígidas, faltando flexibilidade para lidar com a incerteza ou para fornecer sugestões baseadas em evidência de forma proativa.
- **Impacto Transversal nos Stakeholders:** O erro afeta diretamente médicos, farmacêuticos e doentes, bem como as entidades reguladoras e instituições de saúde, que lidam com as consequências clínicas, operacionais e financeiras dos eventos adversos associados aos erros de prescrição.

Estes fatores agravam a discrepância entre a necessidade de apoio à prática médica segura e a capacidade de resposta dos sistemas de informação tradicionais, comprometendo a qualidade do serviço prestado ao doente.

1.2.2 Restrições

A realização deste projeto encontra-se condicionada pelas seguintes restrições:

- **Privacidade:** Devido a questões éticas e legais do Regulamento Geral sobre a Proteção de Dados (RGPD), não será possível aceder a dados reais de pacientes ou históricos clínicos hospitalares nesta fase, recorrendo-se exclusivamente a *datasets* públicos anonimizados (ex: *MIMIC-III*) ou dados sintéticos (ex: *Synthea*).
- **Validação Clínica:** A validação do sistema não poderá ser realizada em ambiente clínico real com doentes (ensaios clínicos), limitando-se a simulações e à avaliação por utilizadores como médicos e farmacêuticos.
- **Recursos Computacionais:** O treino e a execução do sistema de recomendação com Grandes Modelos de Linguagem (LLM) exige elevado poder computacional, o que pode constituir uma limitação técnica dependendo do *hardware* disponível ou dos custos de *Application Programming Interface* (API) externas.
- **Tempo de Desenvolvimento:** O projeto deve ser concluído no prazo académico referido no Capítulo 2, sendo necessário uma gestão do tempo rigorosa de modo a garantir a entrega de um protótipo funcional.

1.2.3 Desafios

Os principais desafios deste problema incluem:

- **Alucinações da IA:** A utilização de LLM em contexto clínico necessita de uma mitigação do risco de alucinações, geração de informações falsas ou imprecisas, sendo fundamental que o sistema apenas forneça recomendações baseadas em evidência científica validada.
- **Privacidade dos Dados:** O treinamento e validação de modelos com dados clínicos reais apresenta restrições éticas e legais de proteção de dados (RGPD). O desafio para este projeto reside na utilização de técnicas de anonimização ou *datasets* sintéticos que mantenham a representatividade clínica sem comprometer a privacidade.
- **Evitar a Fadiga de Alertas:** Desenvolver um sistema que seja capaz de minimizar alertas irrelevantes para evitar a dessensibilização dos profissionais de saúde (*alert fatigue*). O desafio é equilibrar a sensibilidade do sistema (detetar erros) com a especificidade (não incomodar o profissional de saúde com falsos positivos ou avisos triviais).

- **Integração e Usabilidade:** Assegurar que a nova ferramenta seja integrada de forma fluida nos fluxos de trabalho existentes, sem aumentar a carga cognitiva ou o tempo de consulta dos profissionais de saúde.

A resolução deste problema passa pela implementação de uma arquitetura híbrida que combine regras clínicas robustas com a flexibilidade da Inteligência Artificial (IA), assegurando precisão, segurança e aceitação por parte dos utilizadores.

1.3 Objetivos

O presente trabalho tem como objetivo principal o desenvolvimento de um sistema de recomendação e alertas capaz de identificar erros de prescrição, nomeadamente doses incorretas, interações medicamentosas, contraindicações e duplicação de terapias.

Este projeto deverá demonstrar a relevância clínica da solução através de uma avaliação quantitativa e qualitativa, incluindo métricas de desempenho do sistema e feedback de profissionais de saúde (SUS score > 85).

Para a concretização do objetivo geral, foram definidos os seguintes objetivos específicos:

1. **Análise do Estado da Arte e Sistematização de Requisitos:**

- a. Realizar uma revisão sistemática da literatura sobre a prevalência de erros de prescrição e as limitações dos sistemas de apoio à decisão clínica atuais.
- b. Investigar a aplicação de Inteligência Artificial, especificamente LLM e técnicas de *Retrieval-Augmented Generation* (RAG), na área da saúde e segurança na prescrição de medicação.
- c. Identificar e analisar *datasets* públicos de farmacologia e interações medicamentosas (e.g., *DrugBank*, *RxNorm*, *Infarmed*) adequados para o treino e validação do sistema.

2. **Conceção da Arquitetura do Sistema:**

- a. Projetar uma arquitetura de sistema híbrida que integre:
 - i. Um módulo baseado em regras para verificações determinísticas críticas;
 - ii. Um módulo com integração de LLM para a interpretação do contexto/histórico clínico e geração de alertas em linguagem natural.
- b. Definir a estrutura de dados para a recolha de informação clínica, como o perfil do paciente e regime de medicamentos.

3. Desenvolvimento do Protótipo:

- Integrar o *backend* do sistema que é capaz de sincronizar os dados (*datasets*) e treinar eficazmente o modelo IA.
- Implementar uma interface (*frontend*), intuitiva para o profissional de saúde, com ênfase na apresentação clara das alertas.
- Integrar técnicas de mitigação das alucinações, garantindo que as recomendações sejam suportadas por evidências fidedignas.

4. Avaliação e Validação do Sistema:

- Analisar o desempenho técnico do modelo com a utilização de métricas de recuperação de informação, tais como Precisão (*Precision*), Revocação (*Recall*) e *F1-Score*, com o objetivo de minimizar o número de falsos-positivos.
- Executar testes de usabilidade com potenciais utilizadores (profissionais de saúde) de modo a avaliar a aceitação do sistema, com a utilização de questionários como o *System Usability Scale* (SUS), com uma meta de *SUS score* > 85.
- Comparar a eficácia do sistema desenvolvido face às abordagens tradicionais: métodos robustos baseados exclusivamente em regras.

5. Perspetivas de Evolução e Generalização:

- Avaliar a viabilidade da integração do protótipo desenvolvido com os sistemas de Registo de Saúde Eletrónico (RSE) existentes.
- Avaliar a escalabilidade da solução para incluir novas classes terapêuticas e diretrizes clínicas atualizadas automaticamente.

Assim sendo, os objetivos definidos respondem diretamente à necessidade de diminuir os erros de prescrição, oferecendo uma solução tecnológica que não só alerta o erro, mas também apoia a decisão do médico através de explicações claras, que visam um cuidado médico mais eficiente e seguro.

1.4 Interpretação Analítica, Crítica e Ética

A natureza sensível do domínio da saúde exige que o desenvolvimento de sistemas de informação não se limite à componente técnica, o que requer uma reflexão profunda sobre as implicações morais da automatização em contexto clínico.

1.4.1 Interpretação Analítica

Do ponto de vista analítico, o problema dos erros de prescrição não deve ser apenas interpretado como uma falha humana, mas sim como uma consequência sistémica da crescente complexidade farmacológica e da sobrecarga laboral e cognitiva a que os profissionais de saúde estão sujeitos. O estado da arte demonstra no Capítulo 3 que os sistemas de suporte à decisão clínica (CDSS) tradicionais, baseados apenas em regras estáticas ("se-então"), apresentam são limitados em relação à sua eficácia. Deste forma, a análise do problema estabelece duas lacunas principais que este projeto visa melhorar:

- **A lacuna da contextualização:** Os sistemas atuais, mais à frente discutidos no Estado da Arte, analisam interações de forma isolada, não sendo eficazes em relação à incerteza.
- **A lacuna da interoperabilidade semântica:** A informação médica encontra-se dispersa e muitas vezes não estruturada, dificultando a sua análise automática. Portanto, a solução proposta não deve ser apenas uma digitalização de características farmacológicas, mas sim um sistema capaz de analisar a condição do doente, o histórico terapêutico e as diretrizes clínicas.

1.4.2 Interpretação Crítica

Numa perspetiva crítica, é relevante reconhecer as limitações e os riscos inerentes à implementação de IA, especificamente LLM, na área da prescrição médica. A crítica ao Estado da Arte atual foca-se no fenómeno de *Alert Fatigue*. Estudos indicam que os médicos uma grande parte dos alertas de segurança devido à sua irrelevância ou excessiva frequência. Desat forma, um novo sistema que apenas aumente o volume de notificações, sem melhorar a sua precisão (especificidade), será contraproducente e rejeitado pelos utilizadores.

Simultaneamente, a adoção de IA generativa levanta a questão crítica das alucinações (geração de factos incorretos). Assim, este projeto adota uma postura crítica de que a IA não deve substituir o juízo clínico, mas sim aumentá-lo, funcionando como um apoio e "segunda opinião" validada [5].

1.4.3 Interpretação Ética

O projeto segue os princípios de integridade, rigor, transparência e responsabilidade definidos pelo *European Code of Conduct for Research Integrity* e pelas orientações éticas apresentadas no contexto de investigação da unidade curricular de Preparação para Dissertação (PREPD). Na sua fase atual, o trabalho não pretende envolver dados clínicos identificáveis, nem a participação direta de doentes, sendo desenvolvido exclusivamente com bases de conhecimento farmacológicas, dados públicos anonimizados e *datasets* sintéticos. Desta maneira, está em conformidade com o princípio de proteção e gestão de dados (*data protection*

and stewardship), o que garante que qualquer informação utilizada é tratada de forma responsável e de acordo com o Regulamento Geral sobre a Proteção de Dados (RGPD), reduzindo riscos de reidentificação e assegurando práticas de gestão de dados transparentes e auditáveis.

Foram igualmente consideradas as recomendações internacionais relativas à utilização ética de sistemas de IA, incluindo a necessidade de divulgar o uso de ferramentas automáticas, assegurar transparência algorítmica, promover reprodutibilidade e avaliar potenciais enviesamentos que possam produzir recomendações discriminatórias ou clinicamente inadequadas. A análise ética do projeto enquadra-se na categoria de investigação de baixo risco, não envolvendo intervenções clínicas nem manipulação de dados sensíveis, mas ainda assim respeitando os princípios de honestidade, fiabilidade e responsabilidade exigidos em investigação em saúde digital [6],[7].

Qualquer interação prevista com profissionais de saúde será realizada mediante consentimento informado, garantindo confidencialidade, participação voluntária e minimização de riscos, conforme recomendado para estudos exploratórios com utilizadores. O projeto adota ainda práticas de documentação rigorosa, registo explícito de contributos, mecanismos de controlo para evitar má conduta científica (como falsificação, omissão de métodos ou uso oculto de IA) e medidas preventivas contra erros de interpretação ou utilização indevida de resultados.

Desta forma, garante-se que o sistema proposto é desenvolvido de forma responsável, equitativa e alinhada com os padrões internacionais para investigação segura e íntegra em tecnologias digitais aplicadas à saúde.

Complementarmente à ética na investigação, o projeto rege-se pelos princípios de Ética em Engenharia, alinhando-se com o *ACM Code of Ethics and Professional Conduct* [8] e o *ACM/IEEE-CS Software Engineering Code* [9]. Dado que o sistema de recomendação opera num domínio crítico (saúde), assume-se o compromisso com o princípio da segurança e bem-estar público como prioridade máxima. Isto implica não só a garantia da privacidade, mas também a responsabilidade técnica de assegurar a robustez do *software*, a mitigação de *bugs* que possam levar a erros e a validação rigorosa das sugestões geradas pelo sistema, evitando a entrega de funcionalidades que não tenham sido devidamente testadas ou que apresentem riscos injustificados para os utilizadores finais.

1.5 Abordagem

Para alcançar o objetivo proposto, será adotada uma abordagem que combina a análise detalhada do problema, a revisão crítica da literatura e a implementação de técnicas de inteligência artificial aplicadas à prescrição médica.

Numa primeira fase, será realizada uma revisão sistemática e narrativa da literatura, através de métodos como PRISMA, *snowballing* e pesquisa individual por tema, com vista na identificação

das principais causas de erro de prescrição, dos tipos de sistemas de recomendação existentes na área da saúde e das abordagens mais eficazes.

Posteriormente, será feita a arquitetura do sistema, com foco na integração de dados clínicos relevantes e na definição das regras e algoritmos que permitirão identificar incompatibilidades terapêuticas, nomeadamente: interações medicamentosas, doses inadequadas, contraindicações e duplicação de terapias.

O sistema será desenvolvido seguindo uma abordagem que integra componentes de *backend*, *frontend*, técnicas de filtragem baseadas em conhecimento e contexto, e modelos de LLM com RAG, com o uso de representações vetoriais (*embeddings*) para capturar a semântica dos dados não estruturados do doente, em linha com as tendências identificadas na revisão da literatura. Serão ainda implementados mecanismos de alerta em tempo real e recomendações baseadas em conhecimento e em padrões derivados dos dados.

Por fim, serão realizados testes quantitativos e qualitativos de forma a avaliar a precisão do sistema, a usabilidade e a eficácia na identificação precoce de potenciais erros.

1.6 Resultados Esperados

Com o desenvolvimento deste sistema, espera-se reduzir significativamente a ocorrência de erros de prescrição, oferecendo aos profissionais de saúde um apoio à decisão robusto e eficaz. De forma mais específica, prevê-se:

- melhoria da segurança do doente através da identificação precoce de riscos;
- redução de efeitos adversos associados à medicação;
- aumento da eficiência e confiança no processo terapêutico;
- disponibilização de recomendações personalizadas, claras e justificadas;
- integração harmoniosa com fluxos de trabalho clínicos já existentes.

O sistema deverá demonstrar alta precisão na deteção de erros e elevada aceitação pelos utilizadores finais, contribuindo para uma prática clínica mais segura e informatizada.

1.7 Principais contributos

Os contributos esperados incluem a redução de erros de prescrição evitáveis na prática clínica através do desenvolvimento de uma ferramenta flexível para uso em ambientes clínicos reais, que alerte e apoie o profissional de saúde durante o processo de prescrição, o que poderá

melhorar significativamente a segurança do doente ao prevenir eventos adversos, garantir a adequação terapêutica e reduzir a probabilidade de interações medicamentosas ou doses incorretas.

1.8 Estrutura do Documento

Este documento está organizado em quatro capítulos, cada um aborda diferentes etapas do trabalho desenvolvido neste relatório final de PREPD. Segue-se uma descrição detalhada de cada capítulo:

No primeiro capítulo, é apresentada a introdução ao tema, estabelecendo o enquadramento e a contextualização do problema dos elevados erros de prescrição médica. São definidos os objetivos gerais e específicos da investigação, bem como a abordagem metodológica proposta e a relevância do estudo. Este capítulo aborda ainda a interpretação analítica, crítica e ética do projeto, fundamentando a necessidade de uma solução baseada em inteligência artificial.

O segundo capítulo foca-se no planeamento do trabalho de investigação e desenvolvimento. É apresentada a metodologia do projeto adotada, incluindo a análise de riscos e as respetivas estratégias de mitigação. Este capítulo detalha ainda o cronograma proposto para a realização das várias etapas da dissertação, bem como a gestão de recursos e a definição dos entregáveis.

No terceiro capítulo, é apresentado o Estado da Arte, resultante da revisão sistemática da literatura. Este capítulo constitui a base teórica do trabalho, analisa a tipologia e impacto dos erros de medicação, bem como as abordagens existentes em sistemas de recomendação na área da saúde. Este capítulo também enfatiza a integração de LLM e a análise crítica da literatura nas limitações das soluções atuais, como a fadiga de alertas.

O quarto e último capítulo apresenta as conclusões deste relatório. Neste capítulo é feita uma síntese do trabalho realizado, discute-se as limitações identificadas e perspetiva-se o trabalho futuro a desenvolver na unidade curricular de Dissertação, com vista à implementação e validação do protótipo proposto.

2 Planeamento

O planeamento constitui uma etapa fundamental para assegurar a exequibilidade do projeto de dissertação. Este capítulo descreve a abordagem adotada para a organização das atividades, a gestão de riscos e a alocação de recursos. O foco principal reside na definição de uma estratégia que permita desenvolver um sistema de recomendação seguro e eficaz, cumprindo os requisitos temporais e éticos estabelecidos.

São apresentadas as estratégias de mitigação para os riscos identificados, as competências técnicas e científicas necessárias para trabalhar com inteligência artificial em saúde, e o cronograma detalhado que guia o trabalho desde a fase de preparação (PREPD) até à conclusão da dissertação na fase da Dissertação do Mestrado em Engenharia Informática (DIMEI).

2.1 Gestão de Riscos

A natureza do projeto, que envolve a aplicação de algoritmos de IA num domínio crítico como a saúde, apresenta riscos específicos que podem comprometer a validade científica, a exequibilidade técnica ou a aceitação ética da solução. A gestão proativa destes riscos é, portanto, um pilar fundamental do planeamento.

2.1.1 Principais Riscos Identificados

A análise de riscos permitiu identificar ameaças em quatro dimensões críticas:

- **Riscos Técnicos:** O risco mais pertinente é o fenómeno das "Alucinações" da IA, onde os Grandes Modelos de Linguagem (LLM) podem gerar recomendações clinicamente incorretas ou inventar interações medicamentosas inexistentes com elevada confiança. Adicionalmente, identificou-se o risco associado à qualidade dos dados de treino,

nomeadamente a possibilidade de estes estarem incompletos ou não normalizados nos *datasets* públicos, comprometendo deste modo o treino do modelo.

- **Riscos Ético-Legais:** A violação de privacidade constitui um risco significativo, relacionado com o potencial uso indevido de dados sensíveis ou a reidentificação de doentes, o que violaria o Regulamento Geral sobre a Proteção de Dados (RGPD).
- **Riscos Organizacionais:** Destaca-se a “fadiga de alertas”, que se traduz na rejeição do sistema pelos médicos devido a um excesso de avisos de baixa relevância clínica, bem como a desconfiança inerente a sistemas do tipo “caixa preta”, quando um utilizador não compreende bem o funcionamento interno de um sistema.
- **Riscos de Projeto:** A não conclusão do protótipo (ex: atrasos no Cronograma) dentro dos prazos académicos estipulados é um risco operacional significativo.

2.1.2 Plano de Mitigação

Para cada risco identificado, foram delineadas estratégias de mitigação concretas:

- **Mitigação Técnica:** Para mitigar as alucinações, será implementada uma arquitetura RAG, que obriga o modelo a fundamentar as suas respostas em bases de dados farmacológicas validadas, juntamente com uma camada de verificação baseada em regras determinísticas. A qualidade dos dados será, desta forma, assegurada através de processos robustos de pré-processamento e normalização antes da ingestão pelo modelo.
- **Mitigação Ética:** O risco de privacidade será eliminado através da utilização exclusiva de dados sintéticos e bases de dados públicas anonimizadas, garantindo conformidade total com as normas éticas sem necessitar de acesso a dados reais de doentes nesta fase.
- **Mitigação Organizacional:** Para prevenir a fadiga de alertas, a estratégia foca-se na Experiência do Utilizador (UX), com ajuste nos limiares de sensibilidade do sistema para apresentar apenas alertas clinicamente relevantes.
- **Mitigação de Projeto:** O cumprimento dos prazos será gerido através da adoção de uma metodologia que envolve reuniões quinzenais e a priorização rigorosa das funcionalidades essenciais (Produto Mínimo Viável - MVP) em detrimento de funcionalidades acessórias (“*nice-to-haves*”).

2.1.3 Impacto dos Riscos

A avaliação do impacto revela que a materialização dos riscos de alucinações e violação de privacidade teria consequências elevadas, podendo invalidar clinicamente o protótipo ou levantar barreiras legais não superáveis.

O risco de atraso no cronograma possui também um impacto alto, pois comprometeria a avaliação acadêmica. No entanto, os riscos de fadiga de alertas e qualidade dos dados apresentam um impacto médio, afetando a eficácia e usabilidade do sistema, mas não necessariamente a sua viabilidade fundamental.

2.1.4 Análise Geral dos Riscos

A Tabela 1 sistematiza e sumaria a matriz de riscos, classificando-os quanto ao seu impacto e probabilidade, e associando-os às respectivas estratégias de mitigação.

Tabela 1 - Matriz de Riscos e Mitigação

Risco	Categoria	Impacto	Probabilidade	Estratégia de Mitigação
"Alucinações" da IA: O modelo gerar recomendações clinicamente incorretas ou inventadas.	Técnica	Elevado	Média	Implementação de arquitetura RAG (<i>Retrieval-Augmented Generation</i>) ligada a bases de dados validadas (DrugBank). Verificação baseada em regras determinísticas.
Violação de Privacidade (RGPD): Uso indevido de dados sensíveis ou reidentificação.	Ético-Legal	Elevado	Baixa	Utilização exclusiva de <i>datasets</i> sintéticos (Synthea) e bases de dados públicas anonimizadas. Conformidade rigorosa com normas éticas.
Fadiga de Alertas: Rejeição do sistema pelos médicos por excesso de avisos.	Organizacional	Médio	Alta	Ajuste dos limiares de sensibilidade do sistema. Foco na UX (<i>User Experience</i>) para apresentar apenas alertas de severidade relevante.
Qualidade dos Dados: Dados incompletos ou não normalizados nos <i>datasets</i> públicos.	Técnica	Médio	Média	Pré-processamento robusto e normalização de dados antes da ingestão pelo modelo.
Atrasos no Cronograma: Não conclusão do protótipo a tempo da entrega final.	Projeto	Alto	Média	Adoção de metodologia Ágil com <i>sprints</i> quinzenais. Priorização de funcionalidades essenciais (MVP) em detrimento de "nice-to-haves".

2.2 Gestão de Competências

O desenvolvimento deste sistema exige a combinação de competências de engenharia informática com conhecimentos específicos de informática médica e ciência de dados.

2.2.1 Competências Necessárias

Para a concretização dos objetivos, foram identificadas as seguintes competências nucleares:

- **Técnicas:** Domínio de Python e *frameworks* de IA (LangChain, OpenAI API, PyTorch); Capacidade de manipulação de grandes volumes de dados (Pandas, SQL).
- **Científicas:** Capacidade de análise de literatura médica e compreensão de terminologias farmacológicas (grupos, interações, posologia, contraindicações).
- **Transversais:** Rigor ético no tratamento de dados; Gestão de tempo e autonomia na investigação e desenvolvimento.

2.2.2 Desenvolvimento de Competências

Após a identificação das competências nucleares, foi realizado um diagnóstico inicial para avaliar o estado atual destas capacidades. Este processo baseou-se num modelo de autoavaliação (escala 1 a 5) complementado por uma heteroavaliação realizada por pares, permitindo uma análise mais objetiva dos pontos fortes e das áreas que carecem de melhoria.

A Tabela 2 apresenta os resultados detalhados do diagnóstico efetuado:

Tabela 2 - Matriz de Diagnóstico de Competências

Competência	Importância	Autoavaliação	Heteroavaliação
Análise e resolução de problemas	5	4	5
Aprendizagem ao longo da vida	5	4	4
Trabalho em equipa e colaboração	5	5	5
Motivação para a excelência	4	4	4
Adaptabilidade e flexibilidade	4	4	5
Ética e responsabilidade social	5	4	5
Domínio de línguas estrangeiras	5	5	5

Competências técnicas da área específica	5	4	4
Tomada de decisão	5	4	5
Gestão do tempo	5	3	4
Capacidade para assumir riscos	5	4	4
Comunicação oral	5	3	5
Comunicação escrita	5	4	5
Resiliência	4	4	4
Escuta ativa	5	5	5
Relacionamento interpessoal	4	4	5
Liderança	4	4	4
Criatividade e inovação	5	4	4
Gestão das emoções	4	5	5
Negociação	4	3	4
Empatia	5	5	4
Assertividade	4	4	4
Gestão do stress	4	4	4
Proatividade	4	4	5

Competências mais desenvolvidas: A análise dos resultados evidencia um conjunto de competências sólidas, fundamentais para a execução do projeto, destacando-se:

- **Trabalho em equipa e Escuta Ativa (5/5):** A avaliação máxima em ambas as vertentes (auto e heteroavaliação) demonstra uma elevada capacidade de colaboração e de assimilação de feedback, essenciais para a interação com a equipa de orientação.
- **Gestão das Emoções (5/5):** Revela maturidade emocional para lidar com os desafios inerentes a um projeto de investigação.
- **Competências Técnicas e Capacidade de Risco (4/5):** Esta classificação indica uma razoável preparação base para lidar com as tecnologias propostas e para explorar abordagens inovadoras.

Competências a melhorar: Por outro lado, identificaram-se competências com pontuações inferiores face ao seu grau de importância (nível 5), que constituem o foco do plano de desenvolvimento:

- **Gestão do Tempo (3/5):** Identificada como uma área crítica, dado o rigor dos prazos acadêmicos e a complexidade do cronograma.
- **Comunicação Oral (3/5):** A discrepância entre a autoavaliação e a importância desta competência sugere a necessidade de treino específico para a defesa da dissertação.
- **Gestão do Stress (4/5):** Embora com uma avaliação positiva, a sua importância crítica num contexto de *deadlines* justifica a inclusão de um plano de ação preventivo.
- **Tomada de Decisão (4/5):** Sendo um projeto de investigação que exige autonomia, pretende-se elevar esta competência para o nível de excelência.

2.2.3 Plano de Desenvolvimento de Competências

Com base no diagnóstico anterior, foi elaborado um plano de ação focado no fortalecimento das competências identificadas como prioritárias. Este plano define ações concretas e indicadores de progresso para cada área.

1. Gestão do Stress:

- **Ações de Desenvolvimento:**
 - Implementação de rotinas de exercício físico regular para libertação de stress acumulado.
 - Prática de técnicas de meditação e *mindfulness* para melhoria do foco e controlo da ansiedade.
- **Indicadores de Progresso:**
 - Manutenção de níveis de produtividade constantes durante picos de trabalho.
 - Capacidade de resposta equilibrada perante imprevistos técnicos.

2. Gestão do Tempo:

- **Ações de Desenvolvimento:**
 - Elaboração e cumprimento rigoroso do diagrama de *Gantt*.
 - Adoção da prática de iniciar as tarefas com antecedência em relação aos prazos limite, evitando a acumulação de trabalho.
- **Indicadores de Progresso:**
 - Cumprimento integral das *milestones* definidas posteriormente neste Capítulo 2.
 - Ausência de atrasos na entrega dos relatórios parciais.

3. Comunicação Oral:

- **Ações de Desenvolvimento:**

- Leitura regular de artigos científicos em voz alta de modo a melhorar a fluência técnica.
- Participação ativa em reuniões com os orientadores, de modo a ter uma maior intervenção e exposição de ideias ("Falar mais").

- **Indicadores de Progresso:**

- Clareza e assertividade demonstradas nas reuniões quinzenais de acompanhamento.
- Feedback positivo dos orientadores relativamente à capacidade de argumentação.

4. Tomada de Decisão:

- **Ações de Desenvolvimento:**

- Maior iniciativa nas escolhas técnicas do projeto (ex: seleção de *datasets* ou algoritmos), fundamentando-as cientificamente antes da validação.
- Exercício de liderança no planeamento das próprias tarefas, reduzindo a dependência de microgestão externa.

- **Indicadores de Progresso:**

- Redução do tempo despendido em indecisões sobre a arquitetura do sistema.
- Aprovação das escolhas técnicas propostas sem necessidade de correções estruturais profundas.

2.3 Plano de Desenvolvimento

Foi realizado um diagnóstico inicial que identificou a necessidade de aprofundar conhecimentos específicos em Arquiteturas RAG e Normalização de Dados Clínicos. O plano de desenvolvimento inclui a realização de cursos especializados *online*, a leitura técnica da documentação das API (ex: OpenFDA, DrugBank) e reuniões quinzenais de acompanhamento técnico com a equipa de orientação.

2.4 Planeamento do Projeto

O planeamento do projeto segue as diretrizes estabelecidas no *Project Charter*, garantindo o alinhamento entre o âmbito, o tempo e os recursos. O planeamento do projeto segue as diretrizes e metodologias necessárias para assegurar a execução bem-sucedida da dissertação, apresentando aspetos fundamentais como a definição de objetivos, cronogramas, recursos, monitorização de progresso e avaliação de desempenho. Esta subsecção baseia-se em práticas de gestão de projetos académicos da unidade curricular de PREPD, e combina elementos de planeamento, como a Estrutura Analítica do Projeto (EAP) e o diagrama de *Gantt*.

2.4.1 *Project Charter*

O *Project Charter* (Anexo A) serviu como um documento de formalização inicial, estabelecendo as fronteiras e as premissas estratégicas do projeto. Neste documento, foram definidos os seguintes elementos estruturantes:

- **Âmbito:** O projeto foca-se no desenvolvimento de um protótipo de sistema de recomendação híbrido para a prevenção de erros de prescrição. Ficam explicitamente fora do âmbito a integração direta com sistemas hospitalares em produção (devido a restrições de acesso) e a realização de ensaios clínicos com doentes reais.
- **Stakeholders:** Foram identificados e classificados os interessados no projeto quanto ao seu poder e interesse. Destacam-se os médicos (alto poder/alto interesse) como utilizadores principais e os farmacêuticos (alto poder/médio interesse) como validadores técnicos.
- **Restrições e Pressupostos:** O planeamento assume a utilização de dados sintéticos (gerados via *Synthea*) e bases de dados públicas (ex: *DrugBank*, *MIMIC-III*) para garantir a conformidade com o RGPD, dado que não haverá acesso a dados reais de instituições de saúde portuguesas nesta fase.

2.4.2 Estrutura Analítica do Projeto (EAP)

Para tornar o projeto organizável, o âmbito foi decomposto hierarquicamente através de uma Estrutura Analítica do Projeto (EAP). As principais fases de trabalho, ilustradas no Anexo B, são:

1. **Gestão e Planeamento:** Inclui a elaboração do *Project Charter*, cronograma e plano de requisitos e âmbito.
2. **Investigação (Estado da Arte):** Revisão sistemática sobre erros de prescrição e sistemas de recomendação.
3. **Design da Solução:** Definição da arquitetura de sistema, *mockups* e *wireframes*.

4. **Desenvolvimento:** Implementação do *backend*, *frontend*, integração de API e do modelo LLM.
5. **Validação:** Testes de desempenho técnico e avaliação de usabilidade (SUS).
6. **Escrita da Dissertação:** Redação do documento final e preparação da defesa.

2.4.3 Cronograma e Entregáveis

O cronograma do projeto foi desenhado para cumprir os prazos académicos das duas unidades curriculares de: Preparação para Dissertação (PREPD) e Dissertação (DIMEI).

Fase 1: PREPD (Setembro 2025 - Janeiro 2026)

A fase de PREPD foca-se no planeamento e fundamentação teórica. A Tabela 3 resume as datas objetivas de cada tarefa (*milestones*) e entregáveis já concluídos ou previstos para esta etapa:

Tabela 3 - Lista de entregáveis da unidade curricular de PREPD

Entregável	Data de Entrega	Descrição
Project Charter	07/11/2025*	Documento inicial que identifica a equipa, <i>stakeholders</i> , âmbito, <i>milestones</i> , custos, pressupostos e restrições do projeto.
WBS (Work Breakdown Structure)	13/11/2025*	Decomposição hierárquica do trabalho necessário para cumprir os objetivos do projeto: planeamento, investigação e análise, design, desenvolvimento e integração, avaliação e validação, conclusão e documentação.
Plano de Projeto Aprovado	26/11/2025*	Versão consolidada e aprovada do planeamento e gestão de recursos do projeto.
Extended Abstract	15/12/2025	Resumo alargado descrevendo: introdução e enquadramento do problema, perguntas de investigação e objetivos, estado da arte, metodologia proposta, plano de trabalho, considerações éticas e profissionais, e referências bibliográficas.
Trabalho Final PREPD e Apresentação	07/01/2026	Trabalho final da UC contendo a introdução, contexto, problema, objetivo, abordagem, resultados esperados, estrutura do documento, estado da arte, análise de valor, questões éticas e preparação da apresentação.

*Datas não oficiais da UC de PREPD, apenas entregáveis do estudante.

Fase 2: DIMEI (Fevereiro 2026 - Junho 2026)

A segunda fase corresponde à execução técnica e validação. Conforme evidenciado no Diagrama de *Gantt* (Anexo C), as atividades principais desta fase incluem:

- **Fevereiro - Março 2026:** Desenvolvimento do protótipo funcional (MVP) e integração do motor de IA.
- **Abril 2026:** Testes de integração e mitigação de alucinações do modelo.
- **Mai 2026:** Validação com utilizadores e recolha de métricas de precisão.
- **Junho 2026:** Escrita final da dissertação e entrega do documento.

A Figura 1 apresenta o Diagrama de *Gantt*, que evidencia o cronograma temporal e o encadeamento das atividades até à conclusão da dissertação.




Figura 1 - Diagrama de *Gantt* do projeto.

2.4.4 Gestão de Recursos

Para assegurar a execução do plano dentro dos prazos estipulados no diagrama de *Gantt*, foram alocados os seguintes recursos:

- **Recursos Humanos:**
 - **Autor (Pedro Domingues):** Responsável por todas as atividades de execução, desenvolvimento e documentação do projeto.
 - **Orientadora (Dulce Mota):** Supervisão académica, apoio técnico-científico e validação dos entregáveis.
 - **Co-orientador (Constantino Martins):** Supervisão académica, apoio técnico-científico e validação dos entregáveis.
 - **Utilizadores Finais:** Participação em testes e recolha de feedback, com elevado interesse no protótipo final.

- **Recursos Tecnológicos:**

- **Infraestrutura Computacional:** Computador pessoal com capacidade de processamento para execução local de modelos leves e acesso a API na *cloud* (OpenAI/Llama);
- **Software:** IDE de desenvolvimento (*VS Code*) e ferramentas de gestão de projeto (*MS Project*).
- **Dados:** Acesso a *datasets* abertos (*OpenFDA*, *DrugBank*) e ferramentas de geração de dados sintéticos (*Synthea*) para contornar a escassez de dados clínicos reais acessíveis.

- **Recursos Financeiros:**

- **Formações em Inteligência Artificial:** 0€ - 50€
 - Cursos online em IA (e.g., Coursera, Udemy) para reforço de competências técnicas.
- **Treino de Modelos de IA:** 0€ - 50€
 - Custos de computação em *cloud* para treino de modelos.
- **Ferramentas de Desenvolvimento Adicionais:** 0€ - 50€
 - Licenças ou aquisições de software complementar, caso necessário.

Deste modo, a gestão eficiente destes recursos é essencial para garantir que as diferentes fases do projeto decorrem sem interrupções, respeitando as restrições orçamentais e prazos definidos.

2.4.5 Monitorização e Controlo

A monitorização e controlo do projeto foram estruturados para garantir um acompanhamento contínuo do progresso, a identificação atempada de bloqueios e o alinhamento rigoroso com os objetivos científicos definidos.

Desde o início da unidade curricular, foram estabelecidas reuniões regulares de ponto de situação com a equipa de orientação, composta pela Prof.^a Dulce Mota e pelo Prof. Constantino Martins. Estas sessões têm como foco principal a validação do trabalho desenvolvido, garantindo o alinhamento do projeto com os requisitos académicos e ajustando o planeamento conforme necessário.

Estas sessões de acompanhamento permitem:

- **Validação Científica:** Discussão crítica sobre a revisão da literatura e a adequação da arquitetura proposta.
- **Controlo do Cronograma:** Revisão dos marcos (*milestones*) e verificação do cumprimento dos prazos dos entregáveis de PREPD.
- **Gestão de Riscos:** Identificação precoce de desafios técnicos, nomeadamente na integração das API e na normalização dos dados clínicos.
- **Feedback Contínuo:** Ajustes e melhorias na escrita do relatório e na conceção do protótipo.

Assim sendo, as reuniões quinzenais com a equipa de orientação asseguram que o projeto se mantém alinhado aos objetivos pretendidos e promove uma abordagem equilibrada entre a inovação tecnológica e o rigor ético exigido na área da saúde.

2.5 Conclusões do Planeamento

O processo de planeamento constituiu-se como um passo fundamental para a estruturação do projeto e para a identificação e análise das possíveis dificuldades que poderiam dificultar o desenvolvimento do mesmo. Em relação à categorização dos riscos e, especialmente, às questões éticas relacionadas com a privacidade dos dados (RGPD) e ao riscos técnicos relacionados com "alucinações" em IA, formulou-se um plano eficaz para mitigar estes riscos através dos dados sintéticos e o uso de técnicas como RAG.

E uma gestão de competências que demonstrou que era necessário aprofundar conhecimentos tecnológicos (plano de autoformação), que constituem aspetos fundamentais para o melhoramento da qualidade técnica.

A Estrutura de Análise de Projetos de PREPD, ajuda a ter uma perspetiva dos diferentes tópicos e fases definidas sobre o seu desenvolvimento deste projeto, sendo distinguidas no diagrama de *Gantt* a fase da entrega teórica de PREPD e a fase de desenvolvimento prático de DIMEI.

Relativamente aos recursos, a garantia de acesso a bases de dados abertas, como OpenFDA, DrugBank, juntamente com dados sintéticos, Synthea, garante viabilidade na implementação, superando o desafio de acesso a dados hospitalares reais. Sendo um dos principais fatores de sucesso para este projeto a realização de reuniões quinzenais com a equipa de orientação.

Em suma, o planeamento efetuado apresenta bases sólidas para o desenvolvimento do sistema de recomendações e alertas, porque tenta mitigar o risco principal e garante um percurso alinhado ao objetivo principal de ajudar o profissional de saúde na diminuição de erros de prescrições médicas.

3 Revisão da Literatura

3.1 Introdução

Este capítulo apresenta a fundamentação teórica que suporta o desenvolvimento do projeto proposto, contextualizando o problema dos erros de prescrição e analisando as tecnologias existentes para a sua mitigação. A revisão abrange a definição e taxonomia dos erros de medicação, as características farmacológicas relevantes para a segurança do doente e a evolução dos sistemas de recomendação na área da saúde. Enfatiza-se que existe uma integração recente de LLM e técnicas híbridas, sendo também identificadas as lacunas que este projeto visa melhorar.

Adicionalmente, descreve-se a metodologia utilizada para a condução desta revisão, garantindo a reprodutibilidade e o rigor científico da análise.

3.2 Metodologia de Revisão da Literatura

A investigação realizada para este projeto baseou-se na análise sistemática e narrativa da literatura científica, com o objetivo de compreender o estado atual dos sistemas de recomendação aplicados à prescrição médica e à prevenção de erros medicamentosos.

3.2.1 Questão Principal de Pesquisa

A formulação da questão principal de pesquisa orienta todo o processo de revisão da literatura e desenvolvimento da solução. Deste modo, esta questão de investigação define-se:

Como pode um sistema inteligente de recomendação e alertas, baseado em inteligência artificial, ajudar na identificação e prevenção de erros de prescrição de medicamentos em contexto clínico?

3.2.2 Questões de Investigação

Para implementar a questão principal de pesquisa no contexto prático e orientar a análise das diferentes dimensões do problema, foram definidas três questões específicas de investigação que pretendem guiar a revisão da literatura:

Q1: Que tipos de erros de prescrição podem ser identificados de forma eficaz através de sistemas de recomendação e alertas baseados em IA? (ex: interações medicamentosas, doses inadequadas, contraindicações clínicas)

Q2: Que técnicas de inteligência artificial e de recomendação apresentam melhor desempenho e adequação para apoiar decisões de prescrição, minimizando falsos alertas e fadiga do utilizador?

Q3: De que forma a integração do sistema nos fluxos de trabalho clínicos influencia a utilidade percebida e a aceitação por parte dos profissionais de saúde?

3.2.3 Estratégia de Pesquisa

A estratégia de pesquisa seguiu uma combinação da metodologia PRISMA (Anexo D), *snowballing* e narrativa (Consensus: AI e Google Scholar) nas bases de dados (EBSCO, PubMed, Elsevier, ResearchGate, MDPI, Repositório P.Porto, etc.). As seguintes palavras-chave em inglês foram introduzidas na EBSCO: ("prescription error*" OR "medication error*") AND ("alert system" OR "clinical decision support" OR "recommendation system") AND ("machine learning" OR "artificial intelligence" OR "deep learning" OR "neural network*" OR "predictive model*"). Os critérios de inclusão privilegiaram artigos *peer-reviewed*, escritos em inglês e português e nos últimos 5 anos.

- **Sem critérios de inclusão:** 3,950 publicações
- **Após critérios de inclusão:**
 1. Últimos 10 anos: 2,908 publicações
 2. Peer Review: 1,154 publicações
 3. Inglês ou Português: 1,114 publicações
 4. Últimos 5 anos: 861 publicações

Excluíram-se artigos sem validação experimental e publicações sem relevância direta para as questões de investigação anteriormente referidas.

3.3 Características Farmacológicas

Antes de qualquer administração de medicação é recomendado seguir a metodologia dos cinco certos: paciente certo, medicamento certo, via de administração certa, dose certa e horário certo [10].

Adicionalmente, os medicamentos apresentam características específicas, como o princípio ativo/nome comercial, indicações terapêuticas, posologia (modo de preparação/conservação/administração), contraindicações, interações medicamentosas, efeitos indesejáveis, e advertências, o que torna o processo de prescrição particularmente complexo, exigindo uma análise rigorosa de múltiplas variáveis farmacológicas para garantir a segurança e eficácia terapêutica.

Nesta subsecção, detalha-se os principais aspetos considerados pelos sistemas de apoio à decisão, ilustrados com o exemplo do medicamento *Ben-u-ron* 1g comprimidos.

3.3.1 Princípio Ativo

O princípio ativo corresponde à substância quimicamente ativa responsável pelo efeito terapêutico do medicamento. A sua identificação correta é crucial para evitar duplicações terapêuticas e sobredosagens (ex: o princípio ativo do *Ben-u-ron* é o Paracetamol, na dosagem de 1 g por comprimido) [11].

3.3.2 Indicações Terapêuticas

Referem-se às condições clínicas específicas para as quais o medicamento foi testado e para o qual provou ser eficaz. A prescrição fora destas indicações (*off-label*) exige cautela acrescida (ex: o Paracetamol está indicado para o tratamento sintomático de febre e dores ligeiras a moderadas, como cefaleias, odontalgias, dores traumáticas, musculares e articulares, entre outras) [11].

3.3.3 Posologia e Dose Máxima

A posologia define a quantidade de medicamento, a frequência e a duração do tratamento, devendo ser ajustada ao peso e idade do doente. O desrespeito pelos limites de segurança pode levar a toxicidade grave (ex: para o *Ben-u-ron* 1g, a dose máxima diária não deve exceder 4 g, ou seja, 4 comprimidos, com intervalo mínimo de 4 horas entre tomas. Contudo o ideal é de 6 a 8 horas, sendo a posologia habitual de 1 comprimido 2 a 4 vezes por dia) [11].

3.3.4 Contraindicações

Representam situações clínicas ou fisiológicas em que o medicamento não deve ser administrado devido ao risco elevado de danos para o doente. Podem ser classificadas como:

- **Absolutas:** O uso é estritamente contraindicado (ex: o Paracetamol está contraindicado em doentes com doença hepática grave ou hipersensibilidade à substância ativa) [11].

- **Relativas:** O uso pode ser considerado se o benefício superar o risco, exigindo monitorização (ex: precaução em doentes com insuficiência renal moderada a grave, alcoolismo, desidratação, entre outros) [11].

3.3.5 Interações Medicamentosas

Ocorrem quando a ação de um fármaco é alterada pela presença de outro, podendo resultar em toxicidade ou ineficácia. Classificam-se em:

- **Farmacocinéticas:** Alteram a absorção, distribuição, metabolismo ou excreção (ex: a administração simultânea de Paracetamol com anticonvulsivantes e Rifampicina, pode provocar ou agravar a lesão hepática; a Colestiramina reduz a absorção do Paracetamol; entre outros) [11].
- **Farmacodinâmicas:** Alteram o efeito farmacológico final (ex: o uso a longo prazo de Paracetamol (doses elevadas) pode potenciar o efeito anticoagulante da Varfarina, aumentando o risco de hemorragia) [11].

3.3.6 Efeitos indesejáveis

Os medicamentos podem causar reações nocivas e não intencionais, mesmo quando administrados nas doses recomendadas. Estes efeitos, também conhecidos como Reações Adversas a Medicamentos (RAM), são classificados de acordo com a sua frequência e o sistema orgânico afetado, sendo a sua monitorização crucial para a segurança do doente (ex: para o *Ben-u-ron*, os efeitos podem variar desde frequentes, como náuseas e sonolência ligeira, a muito raros, como reações alérgicas graves ou distúrbios da hematopoiese) [11].

3.3.7 Populações Especiais e Advertências

Certos grupos de doentes requerem ajustes de dose ou vigilância acrescida devido a alterações fisiológicas, existindo ainda avisos de segurança críticos sobre a duração e condições de uso de modo a prevenir toxicidade (ex: o *Ben-u-ron 1g* não deve ser utilizado em pessoas com idade inferior a 18 anos; aconselha-se precaução em doentes com insuficiência renal, hepática ou alcoolismo crónico; e o uso prolongado ou doses excessivas podem provocar alterações renais ou lesões hepáticas graves, como necrose) [11].

3.4 Erros de Medicação

A literatura define o erro de medicação (EM) como “sendo qualquer evento evitável que possa causar ou levar ao uso inadequado do medicamento ou a danos no doente enquanto o medicamento estiver sob o controlo do profissional de saúde ou do doente” [12]. As causas do EM podem ser durante a prescrição, verificação, dispensa, administração, semelhança da

embalagem, nomes semelhantes, rotulagem incorreta, dose incorreta, preparação incorreta, falta de informação, erros do sistema, não adesão do doente, duplicação terapêutica, entre outros [12].

3.4.1 Erros de Prescrição

Um dos tipos de EM mais comum é o erro de prescrição, definido como o “EM iniciado durante o processo de prescrição, que inclui a seleção incorreta do medicamento (contraindicações e interações), dose errada (dosagem terapêutica excessiva ou insuficiente), concentração errada, frequência errada, via de administração incorreta, instruções inadequadas para a utilização do medicamento e forma farmacêutica errada” [13].

3.4.2 Tipos de Erros de Prescrição

Deste modo, os erros de prescrição podem ser classificados nas seguintes categorias [14]:

a) Erros de Seleção do Medicamento

Ocorrem quando o medicamento escolhido não é adequado ao diagnóstico, ao estado clínico do doente ou às suas características fisiológicas.

b) Erros de Dosagem

Incluem a prescrição de doses demasiado baixas (ineficazes) ou demasiado elevadas (potencialmente tóxicas), bem como erros na frequência ou duração do tratamento.

c) Erros de Contraindicação

Relacionam-se com a prescrição de medicamentos inadequados devido ao historial clínico, intolerâncias, alergias ou condições fisiológicas específicas.

d) Erros por Interações Medicamentosas

Podem ocorrer entre dois ou mais medicamentos, entre medicamentos e alimentos ou entre medicamentos e condições clínicas. Estas interações podem alterar a eficácia do tratamento ou causar efeitos adversos significativos.

e) Erros de Duplicação Terapêutica

Quando dois medicamentos com o mesmo mecanismo de ação ou finalidade terapêutica são prescritos em simultâneo sem indicação clínica justificada.

f) Erros de Via de Administração

Envolvem a seleção incorreta da forma farmacêutica ou da via de administração, impactando a eficácia ou segurança do medicamento.

3.5 Sistemas de Apoio à Decisão Clínica

Os Sistemas de Apoio à Decisão Clínica (CDSS) são definidos como *software* que utiliza as características individuais de um paciente para apresentar avaliações ou recomendações específicas ao profissional de saúde, com o intuito de apoiar a tomada de decisão [15]. Com o aumento exponencial da disponibilidade de dados de saúde (*Big Data*) provenientes de registos eletrónicos, o foco destes sistemas transitou da simples digitalização de protocolos para uma análise complexa de dados. Peiffer-Smadja *et al.* [15] destacam que, no contexto das doenças infecciosas e prescrição de antimicrobianos, estas ferramentas têm sido aplicadas predominantemente no diagnóstico (33%), na previsão de sépsis (30%) e na previsão de resposta ao tratamento (22%).

A aplicação de CDSS estende-se a outras áreas da saúde nomeadamente a gestão da diabetes e a otimização da terapêutica geral. Uma revisão de 2023 realizada por Huang *et al.* [16] revelou um crescimento acentuado no interesse por CDSS na gestão da diabetes, onde estas ferramentas são utilizadas não apenas por endocrinologistas, mas crescentemente por médicos de cuidados primários e farmacêuticos para recomendações de tratamento e ajuste de doses de insulina.

3.5.1 Evolução e Tipologia

Historicamente, os CDSS começaram com o desenvolvimento de sistemas baseados em regras, evoluindo posteriormente para abordagens baseadas em dados. A literatura classifica esta evolução em duas categorias principais:

3.5.1.1 CDSS Baseados em Conhecimento (*Knowledge-Based*)

Estes sistemas baseiam-se em regras codificadas manualmente ("Se-Então"), capturadas a partir de diretrizes clínicas ou entrevistas com especialistas. O MYCIN foi o primeiro sistema especialista de IA, desenvolvido em 1976, e tinha como objetivo sugerir regimes antibióticos para infeções bacterianas graves. Atualmente, esta tipologia continua a ser predominante na prática clínica devido à sua transparência [15].

Uma *scoping review* de Armando *et al.* [17], publicada em 2023, analisou 42 estudos de CDSS para prescrição de medicamentos e constatou que a vasta maioria (83,3%) ainda se baseia em regras (*knowledge-based*), utilizando critérios validados como os critérios de *Beers* ou *Screening Tool of Older Persons' Prescriptions* (STOPP) para detetar prescrições potencialmente não adequadas a idosos. Apesar de serem explicáveis e rigorosos, estes sistemas apresentam limitações de escalabilidade e rigidez na manutenção de bases de conhecimento complexas [15].

3.5.1.2 CDSS Não-Baseados em Conhecimento (*Data-Driven*):

Para superar as restrições dos sistemas baseados em regras, surgiram abordagens baseadas em *Machine Learning* (ML). Numa revisão de 60 sistemas para doenças infecciosas, verificou-se que 97% utilizam aprendizagem supervisionada [15]. Huang *et al.* [16] validam esta afirmação,

notando um aumento recente de sistemas "não-baseados em conhecimento" na diabetes, com a utilização de algoritmos de IA para transformar dados de larga escala em informações acionáveis.

No entanto, Pinsky *et al.* [18], numa análise crítica publicada em 2024 sobre o uso de IA em cuidados intensivos, alertam que a implementação destas ferramentas na medicina tem sido lenta e desigual. O principal obstáculo reside na natureza inerente da "caixa preta" de muitos algoritmos preditivos, o que dificulta a confiabilidade e a aceitação pela comunidade médica. Logisticamente, a compilação em tempo real de fluxos de dados multidimensionais de várias fontes necessárias para informar os algoritmos e, em última análise, exibir decisões clínicas relevantes, são frequentemente ignoradas durante os esforços iniciais de validação. Da mesma forma, as barreiras legais e comerciais ao acesso a muitas bases de dados clínicas existentes limitam os estudos para abordar a equidade e a generalização de modelos preditivos e ferramentas de gestão.

3.5.2 Barreiras à Adoção e Desafios Éticos

Apesar do potencial demonstrado, a implementação de CDSS baseados em IA enfrenta barreiras significativas que impedem a sua tradução para a prática clínica. Pinsky *et al.* [18] identificam um "fosso de implementação" (*implementation gap*), onde modelos com excelente desempenho *in silico* falham quando implantados à beira do leito (*point of care*). Entre os principais obstáculos destacam-se:

1. **Viés Algorítmico e Equidade:** Muitos algoritmos são treinados em bases de dados (como o MIMIC) que podem não refletir a diversidade demográfica da população alvo [18].
2. **Consciência Situacional:** A maioria dos sistemas atuais carece de "consciência situacional", não conseguindo integrar fluxos de dados multidimensionais em tempo real de forma útil para o fluxo de trabalho clínico [18].
3. **Fadiga de Alertas:** A excessiva frequência de alertas irrelevantes continua a ser um problema central, levando os profissionais a ignorar avisos de segurança críticos [17].

3.5.3 Eficácia e Impacto Clínico

A evidência sobre a eficácia dos CDSS é promissora, mas heterogênea. Na gestão da diabetes, Huang *et al.* [16] reportaram que o uso de CDSS resultou em melhorias significativas nos perfis glicêmicos dos pacientes em aprox. 58,7% dos estudos analisados, sem aumentar o risco de hipoglicemia. No contexto geral da prescrição de medicamentos, Armando *et al.* [17] observaram que 59,5% dos estudos analisados demonstraram sucesso no suporte à prática clínica. Um fator determinante para o sucesso destas intervenções parece ser a multidisciplinaridade: estudos que envolveram a participação ativa de farmacêuticos e focaram

em pacientes complexos (com maior multimorbilidade) obtiveram resultados mais positivos na redução de erros de medicação e eventos adversos [17].

3.6 Sistemas de Recomendação

Os Sistemas de Recomendação são ferramentas que surgiram da necessidade de filtrar um volume crescente de informação na *Web* e recomendar conteúdo relevante ao utilizador. Formalmente, a recomendação pode ser definida como a estimativa de uma função de utilidade $R(u, i)$ que prevê o quanto um utilizador “ u ” gostaria de um item “ i ”. Por exemplo, a Amazon utiliza estes sistemas para personalizar a loja virtual de cada cliente, filtrando milhões de produtos de modo a sugerir apenas aqueles com maior probabilidade de compra [19]. Estes sistemas apoiam a tomada de decisão e apresentam diferentes arquiteturas, variando conforme a técnica de filtragem adotada.

Assim sendo, a recomendação pode basear-se em três técnicas de filtragem principais: colaborativa, baseada em conteúdo, etc. e combinações híbridas que procuram beneficiar das vantagens de cada abordagem [20].

3.6.1 Filtragem Colaborativa (*Collaborative Filtering*)

Baseia-se em padrões de preferências partilhados entre utilizadores. Um exemplo desta abordagem é a funcionalidade de sugestão de vídeos no YouTube, onde o sistema utiliza dados de co-visualização (padrões de “quem viu X também viu Y”) para gerar sugestões, com base no comportamento histórico da comunidade [21]. Pode seguir métodos baseados em memória ou em modelos. Oferece recomendações personalizadas e permite ao utilizador descobrir novos interesses, mas depende de muitos dados. Desta forma, sofre com *sparsity*, em que um conjunto de dados contém muitos zeros ou valores nulos (ineficiência) e apresenta também dificuldades no *coldstart*, quando no arranque de um sistema este está “frio”, sem dados relevantes de preparação sobre o utilizador [20].

3.6.2 Filtragem Baseada em Conteúdo (*Content-Based*)

Recomenda itens semelhantes às preferências prévias do utilizador, através da análise das características dos itens e da construção de um perfil do utilizador. Um exemplo prático é o Spotify, que para além das playlists colaborativas, analisa sinais de áudio e metadados de artistas para recomendar músicas novas que correspondem ao perfil sonoro do utilizador, permitindo a descoberta de faixas de áudio com poucas reproduções [22]. Desta forma, adapta-se bem para muitos utilizadores e reduz, o *cold-start*, mas exige conhecimento do domínio, limita a diversidade das recomendações e não escala adequadamente para bases alargadas de itens [20].

3.6.3 Filtragem Baseada em Conhecimento (*Knowledge-Based*)

Diferente das abordagens anteriores, a Filtragem Baseada em Conhecimento não depende de históricos de interações, mas sim de uma base de conhecimento explícita sobre o domínio e regras de inferência lógica. Esta técnica é especialmente adequada para domínios complexos ou para itens que são adquiridos com pouca frequência (como casas, carros ou produtos financeiros), onde o sistema deve responder a requisitos específicos do utilizador, frequentemente através de um processo conversacional ou de diálogo explícito onde as preferências são captadas, e não apenas as tendências populares [23].

Subdivide-se em duas categorias principais:

- **Baseada em Restrições (*Constraint-based*):** Utiliza regras para filtrar itens que não cumprem os requisitos explícitos do utilizador. Um exemplo prático são as plataformas de imobiliário, onde o utilizador define regras como "Preço < 200.000€" e "Tipologia > T2", e o sistema exclui todas as opções que violem estas restrições [23].
- **Raciocínio Baseado em Casos (*Case-Based Reasoning*):** Resolve novos problemas recuperando soluções de casos passados semelhantes. É frequentemente utilizado em serviços de suporte técnico (*helpdesks*) automatizados, onde o sistema recomenda uma solução para uma avaria baseando-se na resolução de problemas técnicos anteriores com características semelhantes [23].

3.6.4 Filtragem Demográfica

Esta filtragem fundamenta-se na premissa de que utilizadores com atributos demográficos semelhantes tendem a partilhar preferências comuns. Esta técnica utiliza dados explícitos do perfil do utilizador, nomeadamente idade, género, código postal ou profissão, para criar grupos ou *clusters* de utilizadores estereotipados [24].

Uma aplicação comum reside na publicidade direcionada (*targeted advertising*) e em sistemas de recomendação de *e-commerce*, onde o conteúdo é sugerido com base no segmento populacional do utilizador, permitindo gerar recomendações mesmo na ausência de histórico comportamental prévio. Esta característica torna a filtragem demográfica significativamente relevante para mitigar o problema do *cold start* em novos utilizadores. Contudo, o estudo de Nabil *et al.* [24] demonstra que esta técnica, quando utilizada isoladamente ou com poucos atributos demográficos, pode carecer de precisão. Os resultados experimentais revelam que a utilização de um único atributo demográfico 'género' resulta num erro quadrático médio de 0.749. Em contrapartida, ao enriquecer o perfil do utilizador com os atributos 'género' e 'idade', o sistema reduz significativamente o erro para 0.587, comprovando que uma maior subdivisão demográfica é essencial para a eficácia da recomendação [24]. Consequentemente, a tendência atual consiste na sua integração em sistemas híbridos (ex: combinação com filtragem colaborativa), onde a segmentação demográfica prévia reduz a complexidade computacional e melhora significativamente a diversidade e a precisão das recomendações finais [24].

3.6.5 Sistemas Sensíveis ao Contexto (*Context-Aware*)

Os Sistemas de Recomendação Sensíveis ao Contexto representam uma evolução significativa face às técnicas tradicionais, transicionando de um modelo bidimensional (Utilizador * Item) para uma modelação multidimensional (Utilizador * Item * Contexto). Deste modo, a previsão da preferência não depende apenas de quem é o utilizador, mas também das circunstâncias específicas em que a recomendação é solicitada, tais como o tempo, a localização ou o estado emocional [25]. Exemplos incluem:

- **Restauração e Turismo (ex: Google Maps, TripAdvisor):** Estas plataformas aplicam técnicas de pré-filtragem contextual para adaptar as sugestões. Estudos recentes, como o de Abusair *et al.* [26], demonstram que as preferências gastronómicas são altamente variáveis conforme o contexto temporal e ambiental. O sistema pode, por exemplo, recomendar "cafés" ou refeições leves se o contexto for "manhã/temperatura moderada", e "restaurantes" ou refeições quentes se for "noite/frio", ignorando restaurantes com altas classificações se não se adequarem ao momento específico [26].
- **Streaming de Multimédia (ex: Spotify):** Para além do histórico de áudio, a plataforma apresenta contextos dinâmicos para adaptar as recomendações à atividade do utilizador. Isto permite sugerir *playlists* distintas para "Fazer Exercício" ou "Dormir", reconhecendo que a utilidade de um item musical varia consoante a atividade momentânea do utilizador [25].

3.6.6 Filtragem Comunitária (*Community-Based*)

Também conhecida como Filtragem Social, esta abordagem baseia-se nas relações sociais, sejam elas explícitas, como listas de amigos, ou implícitas, inferidas por interesses comuns. Ao contrário da filtragem colaborativa tradicional, que procura utilizadores desconhecidos com gostos semelhantes, esta técnica prioriza as preferências dos amigos ou conexões da rede de confiança do utilizador [27].

Esta metodologia é particularmente eficaz para mitigar problemas de *cold start* e escassez de dados, pois utiliza a estrutura social para gerar recomendações mesmo quando o histórico individual do utilizador é limitado. O exemplo mais evidente encontra-se nas redes sociais como o Facebook (funcionalidade "Pessoas que talvez conheça") ou LinkedIn, que recomendam conexões ou conteúdos baseando-se nas interações do utilizador e nas interações da sua rede de contactos diretos.

3.6.7 Filtragem Híbrida

A filtragem híbrida combina as duas ou mais técnicas de recomendação mencionadas anteriormente, com o objetivo de superar as limitações associadas ao uso isolado de cada técnica [20]. A Netflix exemplifica esta abordagem ao combinar a filtragem colaborativa

(comparando o histórico de visualização entre utilizadores) com a filtragem baseada em conteúdo (com análise de metadados dos filmes como preferências de atores, género e realizador), o que permite recomendações mais robustas e precisas mesmo quando há poucos dados de interação inicial [28].

Deste modo, a sistematização das diferentes técnicas de filtragem permitiu estabelecer uma distinção conceptual fundamental para este projeto: a diferença entre os tradicionais Sistemas de Alerta (CDSS) e os modernos Sistemas de Recomendação. Embora ambos visam o suporte à decisão, operam sob paradigmas computacionais distintos:

- **Sistemas de Alerta:** Baseados em regras/conhecimento, são determinísticos e reativos. Estes sistemas operam sobre uma lógica booleana rígida, onde o conhecimento é codificado explicitamente em regras "Se-Então". Assim sendo, o sistema limita-se a verificar a presença de condições pré-definidas sem geralmente avaliar o contexto envolvente.
 - Vantagem: São excelentes para segurança crítica imediata (ex: alergias conhecidas), onde não pode existir tolerância ao erro.
 - Limitação: Geram um elevado ruído ("fadiga de alertas") e possuem baixa especificidade contextual, pois não conseguem distinguir uma interação teórica de um risco clínico real.
 - Exemplo: "Se Medicamento A (Varfarina) + Medicamento B (Aspirina) forem prescritos, disparar Alerta de Interação Medicamentosa".
- **Sistemas de Recomendação:** Baseados em dados/IA, são probabilísticos, proativos e personalizados. Ao contrário dos sistemas de alerta, estes modelos não se limitam a validar regras, eles utilizam algoritmos de aprendizagem (como filtragem colaborativa ou modelos de linguagem) para inferir padrões complexos a partir do histórico clínico e do perfil do doente. Deste modo, o objetivo não é apenas avisar um erro, mas sugerir a ação terapêutica mais adequada ao contexto do doente.
 - Vantagem: Permitem uma elevada personalização, reduzindo falsos positivos ao "entender" que um determinado risco é aceitável naquele contexto.
 - Exemplo: "Para este doente com insuficiência renal (estádio 3) e histórico de úlcera gástrica, o sistema sugere atenção ao Medicamento X (AINE) por ser contraindicado, recomendando como alternativa o Medicamento Y (Paracetamol) com base em perfis de segurança semelhantes."

De seguida, será apresentada uma tabela sumária de comparação das diferentes técnicas de filtragem usadas em sistemas de recomendação.

3.6.8 Comparação entre Técnicas de Filtragem

A Tabela 4 sintetiza as principais características, vantagens e limitações das técnicas de filtragem abordadas, bem como exemplos da sua aplicação prática.

Tabela 4 - Comparação entre Técnicas de Filtragem em Sistemas de Recomendação.

Técnica de Filtragem	Base de Funcionamento	Principais Vantagens	Principais Limitações	Exemplo de Aplicação
Colaborativa	Padrões de preferências e histórico partilhado entre a comunidade de utilizadores.	• Recomendações personalizadas.	• Problema do arranque a frio (<i>cold-start</i>).	YouTube (Sugestão de vídeos por co-visualização).
		• Permite a descoberta de novos interesses (<i>serendipity</i>).	• Dispersão de dados (<i>sparsity</i>).	
Baseada em Conteúdo	Análise das características intrínsecas dos itens e correspondência com o perfil do utilizador.	• Reduz o impacto do <i>cold-start</i> (para novos itens).	• Exige conhecimento profundo do domínio.	Spotify (Recomendação musical por análise de áudio/metadados).
		• Adapta-se bem a grandes volumes de utilizadores.	• Limita a diversidade das recomendações.	
Baseada em Conhecimento	Regras de inferência lógica e requisitos explícitos fornecidos pelo utilizador (restrições ou casos).	• Ideal para domínios complexos ou compras pouco frequentes.	• Depende de um processo de diálogo explícito ou definição de regras pelo utilizador.	Imobiliário (Filtragem por preço/tipologia); Helpdesks .
		• Independente do histórico de interações.		
Demográfica	Atributos do utilizador (idade, género, localização, profissão) para criar grupos estereotipados.	• Mitigação eficaz do <i>cold-start</i> para novos utilizadores.	• Baixa precisão quando usada isoladamente.	Publicidade Direcionada (<i>Targeted advertising</i>).
		• Simplicidade de implementação.	• Generalização excessiva (falha na captação de gostos individuais).	
Sensível ao Contexto	Modelação multidimensional ($Utilizador \times Item \times Contexto$), considerando tempo, local ou emoção.	• Elevada adaptação à atividade ou necessidade momentânea do utilizador.	• Complexidade na inferência e captura de variáveis contextuais dinâmicas.	TripAdvisor (Restaurantes por hora/tempo); Spotify (<i>Playlists</i> por atividade).
		• Recomendação dinâmica.		
Comunitária (Social)	Relações sociais (explícitas ou implícitas) e redes de confiança entre utilizadores.	• Mitiga problemas de escassez de dados e <i>cold-start</i> .	• Dependência da existência de uma rede de contactos ou grafo social.	Facebook ("Pessoas que talvez conheça"); LinkedIn .
		• Aproveita a estrutura social existente.		
Híbrida	Combinação de duas ou mais abordagens (ex: Colaborativa + Conteúdo).	• Supera as limitações isoladas de cada técnica.	• Maior complexidade arquitetural e de implementação.	Netflix (Histórico de visualização + Metadados dos filmes).
		• Maior robustez e precisão.		

3.7 Sistemas de Recomendação em Saúde

Os Sistemas de Recomendação aplicados à saúde têm apresentado elevada relevância na última década, e podem ser classificados em quatro categorias principais: estilo de vida, nutrição, informação geral sobre saúde e condições específicas de saúde [29],[30]. Deste modo, o sistema que este projeto pretende realizar encontra-se na categoria: condições específicas de saúde.

3.7.1 Trabalhos relacionados

A área dos Sistemas de Recomendação em Saúde tem sido objeto de intensa investigação, dada a necessidade de reduzir erros de prescrição médicos. Para compreender o estado atual da arte e identificar as lacunas que este projeto visa preencher, foram selecionados e analisados ao pormenor cinco trabalhos de referência publicados nos últimos cinco anos. Estes estudos abordam desde a eficácia clínica dos sistemas até aos desafios de implementação da Inteligência Artificial:

1. Evolução dos Sistemas de Alertas em CDSS:

Em 2022, Chien et al. realizaram uma revisão sobre a evolução dos alertas em sistemas de prescrição eletrónica (*computerized physician order entry system* - CPOE) e CDSS ao longo de uma década (2011-2021), analisando 728 publicações indexadas na *Web of Science* [31].

Análise da Bibliografia: Os autores identificaram uma mudança significativa no paradigma de investigação. Enquanto nos primeiros anos a literatura focava-se quase exclusivamente no *design* do sistema e a "segurança do doente" (redução de efeitos adversos), nos últimos três anos do período analisado emergiram termos como "usabilidade", "taxas de rejeição" (*overrides*) e "eficiência do alerta". Esta transição reflete o reconhecimento de que a simples implementação de alertas não garante segurança se a interação da ferramenta com o profissional de saúde não for adequada [31].

Principais Conclusões: A análise dos 24 artigos mais impactantes revelou lacunas estruturais nos sistemas atuais [31]:

1. **Predomínio de Regras Estáticas:** A maioria dos sistemas atuais baseia-se em *designs* baseados em regras rígidas. Isto significa que os alertas são ativados de forma simples, incapazes de interpretar situações diferenciadas, o que limita o seu valor clínico real.
2. **Tipologia de Alertas:** O estudo destaca que os médicos lidam não só com alertas clínicos (interações, alergias), mas também com uma carga elevada de alertas de baixo valor, contribuindo significativamente para a sua fadiga.
3. **Natureza Interruptiva:** A prevalência de alertas do tipo *hard-stop* (que interrompem o fluxo de trabalho) é eficaz para prevenir erros graves, mas, quando usada excessivamente em contextos de baixo risco, gera frustração e dessensibilização.

Os autores recomendam explicitamente que a próxima geração de CDSS deve abandonar a abordagem puramente baseada em regras rígidas. Deste modo, o estudo defende a implementação de soluções sensíveis ao contexto (*context-aware*) que utilizem *Machine Learning* para otimizar os alertas [31].

2. Aplicação dos CDSS no Cuidado à Diabetes:

Uma revisão feita por Huang *et al.* em 2023, analisou 85 estudos sobre a aplicação de CDSS na diabetes, com um foco no panorama da investigação, aplicações clínicas e impacto nos utilizadores [16].

Análise da Bibliografia: A revisão identificou que os CDSS são utilizados por médicos de cuidados primários (51%), endocrinologistas (38%) e até doentes, cobrindo cenários como recomendação de tratamento, ajuste de insulina e rastreio de complicações [16].

Principais Conclusões: A análise dos estudos permitiu concluir sobre a eficácia e as tendências tecnológicas atuais [16]:

- **Eficácia Clínica:** O uso de CDSS demonstrou ser eficaz e seguro. Em 71% dos estudos analisados, observaram-se melhorias significativas nos níveis de glicemia dos doentes, bem como na pressão arterial (67%) e perfis lipídicos (38%), sem aumento do risco de hipoglicemia.
- **Transição Tecnológica:** Embora a maioria dos sistemas (76%) ainda seja baseada em conhecimento (*Knowledge-Based*), ou seja, regras predefinidas, notou-se um aumento consistente de sistemas não-baseados em conhecimento (IA/ML - Machine Learning) nos anos mais recentes, impulsionados pelo *Big Data*.
- **Utilidade para Não-Especialistas:** O artigo destaca que os CDSS são particularmente valiosos para médicos de cuidados primários e outros profissionais não especialistas, que frequentemente lidam com a complexidade da gestão da diabetes sem terem o conhecimento aprofundado das diretrizes mais recentes que um endocrinologista possui.

Os autores apontam como limitações críticas a falta de integração com os Registos de Saúde Eletrónicos (EHR) e o desafio de manter as bases de regras atualizadas [16]. Estas conclusões reforçam a necessidade de transitar para sistemas mais dinâmicos, como os baseados em LLM, capazes de interpretar diretrizes em evolução e integrar dados não estruturados.

3. Desempenho Global de um CDSS em Interações Medicamentosas:

Ao contrário das revisões anteriores, Van De Sijpe *et al.* em 2022 realizou uma avaliação quantitativa de um CDSS num hospital universitário durante um período de 2 anos, analisando mais de 38.409 alertas de interações medicamentosas (DDI) de gravidade considerada "muito severa" [32].

Análise do Estudo: Os investigadores procuraram avaliar o desempenho real de um CDSS baseado em regras, focando-se na "carga de alertas" (*alert burden*), nas taxas de aceitação pelos médicos e na validação farmacêutica posterior. O estudo combinou a análise de *logs* do sistema com inquéritos aos utilizadores para compreender as razões subjacentes à rejeição dos avisos de segurança [32].

Principais Conclusões: Os resultados quantitativos revelaram falhas críticas na especificidade dos algoritmos tradicionais [32]:

- **Taxas de Rejeição Elevada:** O estudo reportou uma taxa de rejeição de alertas (*override rate*) de 88,2%. Isto significa que o sistema interrompeu o médico para avisar de um risco grave e o médico em quase todos os casos optou por ignorar o aviso.
- **Falsos Positivos Técnicos:** A análise detalhada revelou que a maioria destes alertas não correspondia a riscos clínicos reais, mas sim a limitações do *software*. O sistema apresentava alertas baseados em janelas temporais fixas (ex: prescrição nos últimos 14 dias), alertando para interações mesmo quando o doente já tinha suspendido o primeiro fármaco (não havendo co-prescrição real).
- **Falta de Dados Contextuais:** Existiu uma incapacidade do sistema em ler parâmetros clínicos. Por exemplo, alertas sobre o prolongamento do intervalo QT (risco de arritmia) eram gerados indiscriminadamente, mesmo em doentes cujos eletrocardiogramas recentes ou análises laboratoriais estavam normais.

Os autores reforçam que os sistemas baseados puramente em regras temporais e farmacológicas são insuficientes para a prática clínica moderna. O estudo indica que é imperativo evoluir para algoritmos que integrem características específicas do doente (dados laboratoriais e sinais vitais) [32].

4. Utilização da Inteligência Artificial em Cuidados Intensivos:

Pinsky *et al.* em 2024, abordou os desafios e barreiras críticas à implementação de soluções baseadas em Inteligência Artificial em ambientes de alta complexidade, como as unidades de cuidados intensivos (UCI), onde a tomada de decisão é temporalmente crítica [18].

Análise do Estudo: Apesar do desenvolvimento acelerado de modelos preditivos de IA, a sua adoção efetiva tem sido "lenta, intermitente e desigual". O estudo identifica que os CDSS atuais falham não por falta de precisão técnica, mas por falta de integração no fluxo de trabalho e na incapacidade de adaptação dinâmica [18].

Principais Conclusões: O artigo sistematiza três obstáculos fundamentais que impedem a generalização da IA clínica [18]:

1. **Falta de "Consciência Situacional":** A maioria dos modelos de IA opera isoladamente, sem compreender o contexto dinâmico do doente. Falham em integrar fluxos de dados

multidimensionais em tempo real, resultando em alertas desfasados da realidade clínica do momento.

2. **Tendência e Equidade dos Dados:** Muitos algoritmos são treinados em bases de dados (como o MIMIC) que podem não representar adequadamente a diversidade demográfica da população alvo.
3. **Natureza de "Caixa Preta":** A opacidade dos modelos de *Deep Learning* gera desconfiança. Os médicos hesitam em seguir recomendações de sistemas cuja lógica interna não conseguem compreender.

Deste modo, Pinsky *et al.* referem que os CDSS baseados em IA não devem tentar substituir o clínico, mas sim funcionar como ferramentas de apoio e aumento cognitivo [18].

5. Modelo LLM capaz de prevenir erros na administração de medicamentos:

Num estudo de 2024, Pais *et al.* desenvolveram e implementaram o *Medication Direction Copilot* (MEDIC), um sistema baseado em LLM e desenhado para prevenir erros nas instruções de toma de medicamentos em farmácias online [33].

Análise do Estudo: Os autores abordam o problema crítico da transcrição incorreta de prescrições médicas, uma das principais causas de eventos adversos a medicamentos. O sistema MEDIC utiliza uma abordagem híbrida: combina um modelo de linguagem afinado (*fine-tuned LLM*) para extrair componentes clínicos (dose, frequência, via de administração) com um conjunto de "barreiras de segurança" (*safety guardrails*) baseadas em regras farmacológicas determinísticas para prevenir alucinações da IA [33].

Principais Conclusões: A avaliação do sistema, que incluiu testes retrospectivos e uma implementação em ambiente de produção real (*Amazon Pharmacy*), revelou os seguintes resultados [33]:

- **Redução de Erros:** A implementação do MEDIC resultou numa redução de 33% nos eventos de "quase-erro" (*near-miss events*), que são erros detetados e corrigidos por farmacêuticos antes de chegarem ao doente.
- **Modelo Híbrido:** O estudo comparou o MEDIC contra LLM genéricos (como o Claude). O modelo híbrido (IA + Regras) demonstrou ser muito mais seguro, com os modelos genéricos a gerarem até 4,38 vezes mais erros de segurança do que o sistema desenvolvido.
- **Mitigação de Alucinações:** A introdução de camadas de verificação baseadas em conhecimento farmacológico (ex: verificar se a dose extraída é compatível com a forma farmacêutica existente na bula) provou ser eficaz na mitigação de "alucinações" dos modelos de linguagem.

Assim sendo, este trabalho valida a hipótese de que a integração de LLM com bases de conhecimento formal (regras) é mais eficaz em relação a abordagens puramente baseadas em

IA ou puramente manuais. O sucesso do MEDIC demonstra que é possível utilizar LLM em processos críticos de saúde, desde que envolvidos por mecanismos de treino e segurança robustos [33].

3.7.2 Limitações atuais

Nos últimos anos, tem-se verificado um crescimento significativo de sistemas baseados em conteúdo, apoiados em ontologias médicas, bases de conhecimento farmacológicas e diretrizes clínicas [34],[35]. Contudo, estes modelos são particularmente rígidos, dependendo estritamente do conhecimento formalmente codificado de regras, ontologias e diretrizes, apresentando falta de flexibilidade para raciocinar sob incerteza. Assim sendo, a utilização de técnicas híbridas ultrapassa a barreira existente ao combinar técnicas, capazes de aprender padrões a partir de dados, o que melhora a robustez e adaptabilidade a cenários incertos.

No entanto, a implementação destas tecnologias apresenta barreiras significativas. Uma revisão de 2025 [36] destacou que, embora existe diversos modelos preditivos, continua a existir uma escassez de sistemas integrados capazes de gerar alertas em tempo real que sejam clinicamente aplicáveis e não intrusivos. A literatura aponta que a maioria das ferramentas atuais permanece limitada a validações retrospectivas ou ambientes simulados, falhando na demonstração da eficácia em fluxos de trabalho reais e na mitigação da “fadiga de alertas” (*alert fatigue*), o que compromete a sua adoção segura por parte dos farmacêuticos e médicos no momento da prescrição.

3.7.2.1 O Fenómeno da Fadiga de Alertas (*Alert Fatigue*)

Um dos maiores obstáculos à eficácia dos sistemas de decisão clínica atuais é a “fadiga de alertas” (*alert fatigue*). Este fenómeno é definido como um estado de sobrecarga cognitiva e dessensibilização que ocorre quando os profissionais de saúde são expostos a um volume excessivo de avisos de segurança, muitos dos quais irrelevantes ou de baixo risco clínico. Consequentemente, o utilizador tende a ignorar (*override*) os alertas de forma quase automática, sem processar o seu conteúdo, o que pode levar a que avisos críticos sejam negligenciados.

Uma revisão sistemática realizada por Poly *et al.* (2020) [37] identificou em múltiplos hospitais que as taxas de rejeição de alertas de CDSS oscilam entre 46,2% e 96,2%. Sendo que aproximadamente 29,4% a 100% dos alertas ignorados foram classificados como adequados (interação medicamento-alergia 63,4% a 100%, interação medicamento-medicamento 0% a 95%, dose 43,9% a 88,8%), sugerindo que os sistemas atuais têm uma especificidade muito baixa [37].

A análise aprofundada das causas da fadiga de alertas revela falhas estruturais nos algoritmos tradicionais:

- **Falta de Contextualização Clínica:** Van De Sijpe *et al.* (2022) [32] verificaram que 88,2% dos alertas de interações medicamentosas graves foram ignorados pelo profissional de

saúde. A maioria destes alertas eram "falsos positivos", gerados porque o sistema não considerava parâmetros do doente, como valores laboratoriais ou eletrocardiogramas recentes, nem a suspensão prévia de fármacos. Deste modo, o sistema alertava para uma interação teórica, mas que não é real para o estado atual daquele doente.

- **Intrusividade:** Alertas do tipo *pop-up* modal, que bloqueiam o ecrã e interrompem o raciocínio clínico. Quando estes alertas surgem repetidamente para situações de baixo risco (como possíveis reações secundárias), cria-se uma situação onde o médico ignora o apoio da ferramenta de alertas [37].

Desta forma, a persistência deste problema e as elevadas taxas de rejeição justificam a necessidade de transitar para sistemas inteligentes que utilizem Inteligência Artificial para filtrar o ruído. Assim sendo, o objetivo não é apenas alertar, mas sim apresentar apenas os avisos críticos para o perfil individual do doente.

3.8 Sistemas de Recomendação com recurso a LLM

Recentemente a literatura tem mostrado que os Modelos de Linguagem de Grande Escala (LLM), que são sistemas de IA avançados que compreendem e geram linguagem natural, ou texto semelhante ao ser humano, nomeadamente com a utilização do modelo OpenAI's GPT-4 Turbo, estes podem ser integrados em sistemas de apoio à decisão clínica ao traduzir diretrizes clínicas complexas para um formato processável por IA e, a partir daí, gerar recomendações terapêuticas ou orientações de tratamento adaptadas ao contexto do doente. As diretrizes são "reformatadas" para facilitar a leitura por LLM e acompanhadas de técnicas de *retrieval augmented generation* (RAG), uma técnica que permite ao modelo procurar informação fiável antes de gerar a resposta, sendo que a precisão das recomendações pode subir de cerca de 43% para 99% [38],[39].

No entanto, de forma a compreender a arquitetura proposta, é fundamental distinguir as tecnologias envolvidas. A Inteligência Artificial (IA) é o campo vasto da ciência da computação dedicado a criar sistemas capazes de realizar tarefas que normalmente exigiriam inteligência humana. Dentro desta, o *Deep Learning* (DL) é um subcampo que utiliza redes neuronais com múltiplas camadas para aprender padrões complexos. Os LLM, como o GPT-4, são aplicações específicas de DL treinadas em vastos conjuntos de dados, que conseguem se especificar em determinadas áreas. Por fim, RAG é uma arquitetura técnica que combina um LLM com uma base de conhecimento externa de forma a garantir precisão factual e mitigar as alucinações, muito características da IA.

Assim sendo, os LLM demonstram potencial real de produzir recomendações úteis, desde que sujeitos a revisões médicas e refinamentos com *datasets* adequados. A integração de LLM num sistema de recomendação em saúde permite, assim, conciliar o conhecimento formal (diretrizes de medicamentos e dados clínicos) com a flexibilidade e escalabilidade da IA, em sistemas híbridos que oferecem recomendações personalizadas e contextualizadas durante a prática clínica.

3.8.1 Arquitetura Transformer e LLM

Os Grandes Modelos de Linguagem (LLM) atuais, como o GPT-4 ou Llama 3, baseiam-se na arquitetura Transformer, introduzida originalmente por Vaswani *et al.* (2017) e extensivamente analisada na revisão de Zhao *et al.* (2023) [40]. Ao longo da última década, verificou-se uma transição das Redes Neurais Recorrentes (RNN) e *Long Short-Term Memory* (LSTM) para a arquitetura Transformer, o que representa uma mudança de paradigma no processamento de sequências. O componente central desta arquitetura é o mecanismo de "auto-atenção" (*self-attention*), que permite modelar dependências entre elementos de uma sequência independentemente da sua distância posicional.

3.8.1.1 Limitações das Redes Recorrentes (RNN/LSTM):

As arquiteturas anteriores, como as RNN, processam a informação de forma sequencial, por exemplo, para entender um *token* (ex: palavra) no instante “t”, a rede precisa do estado oculto do instante anterior h_{t-1} [40].

Matematicamente, isto implica que a informação tem de percorrer “n” passos para relacionar o primeiro *token* da sequência com o *token* na posição “n”. Este processamento sequencial apresenta dois problemas críticos [40]:

- **Impossibilidade de Paralelização:** O cálculo de h_t depende estritamente de h_{t-1} , o que impede a computação paralela eficiente em *hardware* moderno (GPU), o que torna o treino em sequências longas computacionalmente dispendioso.
- **Perda de Dependências a Longo Prazo:** O "caminho" que o gradiente tem de percorrer durante o treino (retropropagação) é proporcional ao comprimento da sequência ($O(n)$). Desta forma, em sequências extensas, isto causa o problema do desvanecimento do gradiente (*vanishing gradient*), onde a rede perde a capacidade de capturar relações entre *tokens* distantes.

3.8.1.2 Transformer: O Mecanismo de Auto-Atenção (Self-Attention):

A arquitetura *Transformer* supera estas limitações, porque descarta a recorrência sequencial em prol do mecanismo de atenção. Este mecanismo permite que o modelo processe a sequência inteira em paralelo, calculando a relevância de cada *token* em relação a todos os outros, independentemente da sua posição relativa. Assim sendo, o núcleo matemático do *Transformer* é baseado na *Scaled Dot-Product Attention*. Dado uma sequência de entrada, o modelo projeta cada *token* em três vetores: *Query* (Q), *Key* (K) e *Value* (V). A saída é calculada como uma soma ponderada dos valores, onde o peso é determinado pela compatibilidade entre a *query* e as *keys*, conforme a equação [40]:

$$Attention(Q, K, V) = softmax\left(\frac{Q \cdot K^T}{\sqrt{d_k}}\right)V \quad (1)$$

Onde:

- **Q (Queries):** Matriz que representa os itens para os quais se procura contexto.
- **K (Keys):** Matriz que representa os itens que fornecem o contexto.
- **V (Values):** Matriz que contém o conteúdo informacional a ser extraído.
- **d_k :** A dimensão dos vetores chave, utilizada para normalizar o produto escalar. Sem este fator de escala ($\frac{1}{\sqrt{d_k}}$), o produto escalar poderia crescer em magnitude, forçando a função *softmax* para regiões com gradientes extremamente pequenos, o que dificultaria o treino.

A função *Softmax* é aplicada para normalizar os resultados numa distribuição de probabilidade, garantindo que a soma dos pesos de atenção seja igual a 1. Matematicamente, para um vetor "x", a função define-se como:

$$\text{softmax}(x_i) = \frac{e^{x_i}}{\sum_j e^{x_j}} \quad (2)$$

Esta operação permite ao modelo "focar" em partes específicas da sequência de entrada (atribuindo probabilidades mais altas) enquanto ignora outras, reduzindo o caminho do sinal entre qualquer par de palavras para $O(1)$.

3.8.1.3 Aplicação ao Contexto Clínico

A transição desta arquitetura para o domínio da saúde pode viabilizar o presente projeto, porque no contexto clínico, a fórmula de atenção poderá permitir que, ao processar a representação vetorial de um novo fármaco (*Query*), o modelo calcule um "peso de atenção" elevado para *tokens* específicos no histórico do doente (*Keys*), como "Insuficiência Renal" ou "Alergia a Penicilina", mesmo que estes termos estejam separados por milhares de palavras em notas clínicas não estruturadas.

Esta capacidade de "consciência global" do quadro clínico é potenciada por evoluções arquiteturais modernas presentes em LLM como o Llama, que superam as limitações do Transformer original com [40]:

- **RoPE (Rotary Position Embeddings):** Ao contrário dos *embeddings* posicionais absolutos originais, o RoPE codifica a posição absoluta através de uma matriz de rotação, o que preserva matematicamente a informação da posição relativa entre *tokens*. Este mecanismo é crucial para a extrapolação, permitindo que o modelo generalize a deteção de erros para sequências de texto longas (ex: históricos clínicos).
- **SwiGLU (Swish Gated Linear Unit):** Uma função de ativação que combina um mecanismo de porta (*gating*) com a função de ativação não-linear *Swish*, o que melhora a propagação do gradiente e a estabilidade do treino, permitindo ao modelo aprender padrões clínicos mais complexos com maior eficiência.

Desta forma, a implementação destas técnicas permite superar a rigidez dos sistemas baseados apenas em regras, sendo possível oferecer um protótipo robusto e escalável.

3.8.1.4 Limitações dos LLM

Apesar do seu potencial, a utilização de LLM em contextos críticos como a saúde podem apresentar limitações significativas nomeadamente:

- **Desatualização do Conhecimento:** O conhecimento paramétrico de um LLM é estático e limitado à data do fim do seu treino (*training cutoff*). Por exemplo, o modelo não tem conhecimento de novos medicamentos, alertas de segurança recentes ou alterações em diretrizes clínicas que ocorram após a data do treino [41].
- **Alucinações:** Os LLM são modelos probabilísticos desenhados para gerar texto plausível, não necessariamente verdadeiro. Podem gerar factos incorretos, inventar referências bibliográficas ou sugerir dosagens erradas com elevada confiança (*overclaim hallucination*), o que representa um risco grave na prescrição médica [41], [42].
- **Custo Computacional e Latência:** A inferência em modelos de grande escala (ex: GPT-4) exige recursos computacionais elevados [40].
- **Falta de Transparência:** Os dados de treino podem conter enviesamentos demográficos ou clínicos, levando a recomendações discriminatórias, baseadas ao local ou diretriz específica dos dados. Além disso, a natureza de "caixa Preta" das redes neuronais profundas dificulta a explicação lógica passo-a-passo de como o modelo chegou a uma determinada conclusão [18].

3.8.2 Retrieval-Augmented Generation (RAG)

Para mitigar as limitações intrínsecas dos LLM, como a desatualização do conhecimento e alucinações, implementa-se a arquitetura RAG (*Retrieval-Augmented Generation*). O RAG é uma técnica que integra um modelo gerador (o LLM) a um módulo de recuperação de informação baseada em vetores densos (*dense vector retrieval*). O processo baseia-se na representação semântica do texto num espaço vetorial de alta dimensão. Quando uma consulta é submetida, o sistema calcula a similaridade do cosseno entre o vetor da consulta “q” e os vetores dos documentos “d” na base de conhecimento [41]:

$$\text{sim}(q, d) = \frac{q \cdot d}{|q| \cdot |d|} \quad (3)$$

- **sim(q, d):** A pontuação de similaridade entre a consulta “q” e o documento “d”.
- **|q|:** A magnitude do vetor “q”.
- **|d|:** A magnitude do vetor “d”.

Conforme detalhado por Gao *et al.* (2024) [41], este processo divide a inferência em duas fases:

1. **Recuperação (Retrieval):** O sistema converte a consulta clínica (ex: perfil do doente e fármaco prescrito) num vetor numérico (*embedding*) e pesquisa numa base de dados vetorial externa os “k” documentos com maior similaridade semântica (ex: diretrizes da DGS, bulas do Infarmed ou artigos do PubMed).
2. **Geração (Generation):** O LLM recebe a consulta original enriquecida com estes documentos recuperados no contexto (*prompt*), sendo instruído a gerar a resposta exclusivamente com base nessa evidência.

Esta abordagem garante que a resposta gerada é fundamentada (*grounded*) e permite que o sistema forneça citações diretas das fontes, aumentando a confiança da recomendação [41].

3.8.3 Tendências Atuais

Deste modo, a investigação em sistemas de recomendação clínica tem transitado da simples análise de regras para a utilização de representações vetoriais clínicas (*Clinical Embeddings*) e arquiteturas baseadas em *Transformers*. Estas tecnologias permitem capturar relações semânticas complexas entre diagnósticos e medicamentos que escapam aos sistemas tradicionais.

1. Uso de *Embeddings* Clínicos - ClinicalBERT

A aplicação de técnicas de *Deep Learning* em saúde exige que os dados médicos não estruturados sejam convertidos em representações vetoriais (*embeddings*) que têm como finalidade capturar dados significativos sobre cada objeto, preservando o seu significado semântico específico e permitindo encontrar objetos semelhantes. Embora modelos genéricos como o BERT (modelo de IA do Google para processamento de linguagem natural, que usa a arquitetura *Transformer*) ou o BioBERT (treinado em artigos científicos do PubMed) sejam robustos, Alsentzer *et al.* [43] demonstraram que estes falham em capturar os pormenores da linguagem usada em notas clínicas reais (hospitalares), que são frequentemente agramaticais e com abreviaturas específicas.

Metodologia e Arquitetura do ClinicalBERT

De forma a mitigar esta limitação, os autores desenvolveram o ClinicalBERT (e disponibilizaram-no via [GitHub](#)), utilizando uma abordagem de aprendizagem por transferência (*transfer learning*). O modelo foi treinado sobre a base de dados MIMIC-III, processando cerca de 2 milhões de notas clínicas. A inovação metodológica residiu na criação de duas variantes específicas: uma treinada sobre todo o tipo de notas e outra refinada exclusivamente em "sumários de alta" (*Discharge Summaries*). Esta especialização permitiu ao modelo aprender padrões de prescrição e diagnóstico que ocorrem especificamente no momento da alta hospitalar, um ponto crítico para a reconciliação terapêutica [43].

Resultados Quantitativos e Qualitativos

A elevada eficácia desta abordagem foi validada em tarefas de Inferência de Linguagem Natural Médica (MedNLI). Quantitativamente, o modelo Bio+Discharge Summary BERT (inicializado com BioBERT e treinado especificamente em sumários de alta) atingiu uma precisão de 82,7% na tarefa de Inferência de Linguagem Natural Médica (MedNLI), ultrapassando a precisão referida no estado da arte (73,5%) e obteve os melhores *F1-scores* em tarefas de reconhecimento de entidades (ex: 87,8 no *i2b2 2010*), demonstrando uma elevada capacidade de "raciocínio" clínico em comparação com modelos não especializados. Qualitativamente, o estudo comprovou que este modelo captura melhor a semântica hospitalar. Por exemplo, a palavra "Discharge" (Alta) no BioBERT está associada a "admission" (admissão), "wave" (onda) e "sight" (visão), no entanto apenas a primeira (admissão) parece relevante para as operações clínicas. Em contraste, no Clinical BERT, todas as palavras associadas são significativas num contexto de operações clínicas, demonstrando uma compreensão do fluxo operacional hospitalar [43].

Em suma, os autores concluem que os *embeddings* clínicos demonstram uma superioridade robusta face aos modelos genéricos, validando o benefício de utilizar *corpora* específicos como os sumários de alta. Contudo, o estudo aponta limitações relevantes que definem o trabalho futuro: a dependência de dados de uma única instituição (MIMIC - BIDMC), pode restringir a generalização face a diferentes práticas de cuidados; a ausência de testes com arquiteturas de modelo mais avançadas sobre os *embeddings*; e a ineficácia em tarefas de desidentificação (*de-ID*). Para mitigar estas limitações, os autores sugerem a incorporação de notas de múltiplas instituições e a introdução de desidentificação sintética no texto de origem [43].

2. Sistemas de Recomendação baseados em Grafos e Transformers - G-BERT

Shang *et al.* [44] de forma a melhorar a falta de integração da hierarquia do conhecimento médico, desenvolveram o G-BERT (e disponibilizaram-no via [GitHub](#)), o primeiro modelo a combinar Redes Neurais de Grafos (GNN) com a arquitetura do modelo BERT para a recomendação de medicação.

Metodologia e Arquitetura do G-BERT

A inovação técnica do G-BERT reside numa arquitetura de duas fases. Inicialmente, o modelo utiliza Redes de Atenção em Grafos (GAT) para gerar representações vetoriais (*embeddings*) a partir das ontologias médicas (ICD-9 para diagnósticos e ATC para medicamentos). Ao contrário dos métodos lineares, esta abordagem captura a estrutura hierárquica interna, e aprende que certos códigos são "filhos" ou "pais" de outros na árvore clínica (ex: ICD-9, 428 - Insuficiência cardíaca é "pai" de 428.1 - Insuficiência Cardíaca Congestiva). Posteriormente, estes *embeddings* enriquecidos são introduzidos num codificador *Transformer*. Os autores realizaram um treino deste *Transformer* utilizando dados de visitas únicas (geralmente descartados), através de duas tarefas de pré-treino: a *previsão dual* (prever diagnósticos a partir de medicamentos e vice-versa) e a *autoprevisão* (recuperar códigos mascarados), dispensando os *embeddings* de posição visto que a ordem dos códigos numa receita não é relevante [44].

Resultados Quantitativos e Qualitativos

A avaliação experimental, foi realizada sobre a base de dados MIMIC-III e demonstrou que o G-BERT atingiu um *F1-score* de 61,52%, superando ligeiramente o estado da arte anterior, incluindo modelos robustos como o GAMENet (61,26%) e o RETAIN (60, 64%). As variantes do modelo sem a componente de grafos (ontologia) ou sem o pré-treino obtiveram resultados inferiores (ex: G-BERT_{G-}, 59,03% sem ontologia), provando que a integração do conhecimento estruturado (grafos) com a capacidade de generalização do *Transformer* é determinante para a precisão da recomendação [44].

Em suma, os autores concluem que o G-BERT estabelece um esquema de pré-treino de modelos de linguagem ao domínio da saúde, que permite a utilização eficiente de dados que anteriormente não eram considerados. Como trabalho futuro, o estudo sugere o enriquecimento da representação dos códigos médicos através da adição de tarefas estruturais auxiliares e a adaptação do modelo para lidar com *datasets* ainda maiores e com modalidades de dados mais heterogêneas, visando uma robustez ainda maior na prática clínica [44].

3. Codificação Molecular para Melhoria da Interação Medicamentosa - SafeDrug

Yang *et al.* [45] desenvolveram o sistema SafeDrug (e disponibilizaram-no via [GitHub](#)) para mitigar uma limitação crítica dos modelos anteriores: a representação inadequada dos medicamentos. A maioria dos sistemas trata os fármacos apenas como códigos binários (*one-hot encoding*), ignorando que a sua estrutura molecular contém informações vitais sobre eficácia e segurança, o que pode permitir uma melhor recomendação de medicamentos.

Metodologia e Arquitetura do SafeDrug

A inovação do SafeDrug reside na utilização de codificadores duplos de grafos moleculares que capturam tanto padrões globais como locais. Globalmente, o modelo integra uma Rede Neuronal de Passagem de Mensagens (MPNN) para codificar a conectividade átomo-a-átomo de toda a molécula, aprendendo as propriedades farmacológicas macroscópicas. Localmente, e em paralelo, utiliza um codificador bipartidário que segmenta a molécula em subestruturas funcionais (ex: grupos químicos específicos) utilizando o método BRICS. Esta representação local é processada por uma rede com máscara (*masked neural network*), o que permite ao modelo identificar especificamente quais os grupos funcionais que estão associados a interações medicamentosas adversas [54]. Além disso, o sistema integra uma função de perda controlável, inspirada em controladores de derivada integral proporcional (PID), que permite ajustar dinamicamente o equilíbrio entre a precisão da recomendação e a taxa de interações (DDI) tolerada [45].

Resultados Quantitativos e Qualitativos

A avaliação experimental na base de dados MIMIC-III revelou que o SafeDrug alcançou um F1-score de 67,68%, superando também modelos como o GAMENet e o RETAIN. O impacto mais significativo verificou-se na segurança: o modelo conseguiu reduzir a taxa de Interações Medicamentosas (DDI) em 19,43% comparativamente aos *baselines*, sem comprometer a

precisão da recomendação. Adicionalmente, devido à eficiência da sua arquitetura bipartida, o SafeDrug demonstrou ser computacionalmente mais leve, reduzindo o tempo de treino em cerca de 14% e acelerando a inferência em 2 vezes face a abordagens anteriores baseadas em *Deep Learning* [45].

Em suma, os autores concluem que a incorporação explícita da estrutura molecular dos fármacos melhora significativamente a segurança das prescrições. Como trabalho futuro, sugerem a exploração de métodos de segmentação molecular alternativos e a aplicação do modelo a *datasets* que incluam dados genómicos, visando uma personalização ainda mais profunda da terapia [45].

3.9 Interoperabilidade e Normas de Dados Médicos

A eficácia de um sistema de recomendação em ambiente hospitalar depende significativamente da sua capacidade de interpretar dados heterogêneos provenientes de diferentes fontes e de comunicar com outros sistemas. Para garantir a escalabilidade e a futura integração do protótipo, o projeto adotará as seguintes normas internacionais:

- **Anatomical Therapeutic Chemical (ATC):** Sistema de classificação da Organização Mundial da Saúde (OMS) que agrupa fármacos de acordo com o órgão ou sistema sobre o qual atuam e as suas propriedades químicas, farmacológicas e terapêuticas [46]. Esta norma é essencial para a deteção algorítmica de duplicações terapêuticas (ex: detetar que a Sinvastatina e a Atorvastatina pertencem à mesma classe ATC C10AA - Inibidores da HMG-CoA redutase). Exemplificando:
 - Sinvastatina tem o código ATC: C10AA01;
 - Atorvastatina tem o código ATC: C10AA05;
 - O sistema verifica que ambos partilham o nível 4 (C10AA) e dispara o alerta de possível duplicação terapêutica.
- **International Classification of Diseases (ICD-10):** A norma *standard* global para a codificação de diagnósticos médicos e gestão de saúde. O sistema proposto utiliza estes códigos para verificar contraindicações do tipo doença-medicamento, permitindo uma filtragem contextual baseada no perfil clínico do doente, uma prática cuja utilidade na identificação de eventos adversos a medicamentos tem sido validada em estudos recentes [47]. Exemplificando a deteção para um risco de nefrotoxicidade:
 - O Paciente tem o diagnóstico: N18.3 (Doença renal crónica - N18, estágio 3);
 - O Medicamento (ex: Ibuprofeno) é contraindicado à categoria: N18 (Doença renal crónica), por ser um Anti-inflamatório Não Esteroide (AINE), que prejudica a função renal ao reduzir o fluxo sanguíneo para os rins;

- O sistema verifica que o código do paciente (N18.3) é uma subcategoria da restrição do medicamento (N18) e apresenta o alerta da contraindicação.
- **HL7 FHIR (*Fast Healthcare Interoperability Resources*)**: É uma norma de referência para a troca eletrónica de dados em saúde. O FHIR resolve o problema da fragmentação de dados ao utilizar uma abordagem modular baseada em "Recursos" (ex: *Patient*, *MedicationRequest*, *Condition*), acessíveis via API RESTful modernas. O protótipo será desenhado para consumir e produzir dados em formato JSON compatível com a norma FHIR. Esta opção arquitetural assegura que o sistema de recomendação não funciona isoladamente, mas sim como um módulo interoperável capaz de ser acoplado, no futuro, a qualquer Registo de Saúde Eletrónico (EHR) moderno ou utilizado em plataformas de investigação clínica, facilitando a partilha e reutilização de dados para treino de modelos de IA [48].

3.10 Métricas de Avaliação

Para validar a eficácia do sistema proposto, serão adotadas métricas quantitativas e qualitativas, alinhadas com as diretrizes internacionais *DECIDE-AI* [49]. Estas diretrizes recomendam que a avaliação de sistemas de IA em fase inicial não se limite ao desempenho algorítmico, mas integre também a avaliação de fatores humanos (usabilidade) e segurança.

3.10.1 Métricas de Performance

A avaliação da precisão dos alertas pode utilizar métricas objetivas, nomeadamente:

- **Precisão (*Precision*)**: Representa a proporção de alertas gerados pelo sistema que são efetivamente corretos ou clinicamente relevantes (Verdadeiros Positivos - *true positives*). Uma precisão elevada é determinante para mitigar a "fadiga de alertas", o que reduz a sobrecarga cognitiva dos profissionais de saúde causada por avisos irrelevantes [50].
- **Revocação (*Recall*)**: Corresponde à capacidade do sistema em identificar a totalidade dos erros de prescrição existentes (fração dos erros reais detetados). Desta forma, a determinação da revocação é fundamental para assegurar que erros com potencial de dano grave não ficam por detetar (evita falsos negativos - *false negatives*) [50].
- **F1-Score**: Definido como a média harmónica entre a Precisão e a Revocação. Esta métrica identifica o desempenho global do modelo, prejudicando sistemas que apresentam uma destas métricas muito baixa em detrimento da outra. É calculada pela seguinte fórmula [50]:

$$○ F1 = \frac{2 * Precision * Recall}{Precision + Recall} \quad (4)$$

3.10.2 Métricas de Usabilidade e Aceitação

As métricas de usabilidade e aceitação do profissional de saúde ao protótipo, podem ser avaliadas através de:

- **SUS (*System Usability Scale*):** Um questionário padronizado de 10 itens que avalia a usabilidade percebida pelo profissional de saúde [51].
- **TAM (*Technology Acceptance Model*):** Avalia a "Utilidade Percebida" e a "Facilidade de Uso Percebida", que são os maiores preditores da intenção de um profissional de saúde a adotar uma nova tecnologia na sua prática diária [52].

3.11 Conclusão da Revisão da Literatura

A revisão da literatura evidenciou que os sistemas tradicionais baseados em regras atingiram um limite de eficácia e relevância, contribuindo para a "fadiga de alertas" devido à sua incapacidade de interpretar o contexto clínico. Em contrapartida, os sistemas baseados em dados, nomeadamente sistemas de recomendação treinados através de técnicas baseadas em conhecimento e contexto, e com LLM) oferecem uma contextualização superior, mas apresentam riscos como a "alucinação" e a opacidade quando utilizados isoladamente. A análise comparativa revelou que nenhuma destas abordagens resolve, por si só, o equilíbrio entre precisão, segurança e usabilidade.

Conclui-se que a abordagem mais promissora reside numa arquitetura híbrida avançada. Esta solução não se limitará apenas à integração de regras robustas para validações críticas e LLM otimizado pela técnica RAG para aumento da flexibilidade cognitiva, mitigando alucinações e filtrando alertas irrelevantes; integrará também representações vetoriais clínicas (*Clinical Embeddings*) para capturar a semântica do histórico do doente, prevendo-se uma melhoria da capacidade de interpretação estruturada dos fármacos.

Assim sendo, esta conclusão fundamenta o desenvolvimento do protótipo na fase seguinte (DIMEI), de modo a não substituir o julgamento clínico, mas a atuar como uma ajuda e "segunda opinião" inteligente e contextualizada, respondendo às necessidades de eficiência identificadas na revisão da literatura.

4 Conclusões

Este capítulo apresenta uma síntese dos principais resultados obtidos ao longo da fase de preparação (PREPD), analisando as contribuições do trabalho desenvolvido, as limitações identificadas e as direções futuras para a continuidade da investigação na unidade curricular de Dissertação.

A estrutura do capítulo é composta por três secções: a primeira resume os resultados alcançados, destacando o planeamento e a fundamentação teórica; a segunda discute as limitações e restrições que emergiram durante o estudo; e a última secção aborda as potenciais melhorias para o desenvolvimento e validação do sistema proposto.

4.1 Resumo dos Resultados

O presente documento centrou-se no desenvolvimento de um planeamento rigoroso e na fundamentação teórica necessária para a criação de um Sistema de Recomendação e Alertas focado no apoio à prescrição médica. As fases de definição do problema, planeamento do projeto e revisão da literatura foram concluídas com êxito, estabelecendo uma base sólida para a implementação técnica na etapa seguinte.

Através de uma revisão sistemática da literatura, foi possível validar a pertinência do problema, devido aos erros de prescrição continuarem a representar uma carga significativa para os

sistemas de saúde, e as soluções tecnológicas atuais sofrerem de "fadiga de alertas" devido à falta de contextualização e especificidade. Deste modo, esta análise permitiu concluir que uma integração de abordagens híbridas, combinando regras clínicas com a flexibilidade dos LLM e técnicas de RAG, poderá ser a proposta mais promissora para mitigar estas falhas.

O planeamento efetuado, no *Project Charter*, na EAP e no diagrama de *Gantt*, definiu com clareza o caminho a seguir, foi também identificado riscos críticos como as "alucinações" da IA e as restrições de privacidade, para os quais foram referidas estratégias de mitigação.

4.2 Limitações do Estudo

Apesar da robustez do planeamento e da revisão teórica, é essencial reconhecer as limitações inerentes à fase atual e ao contexto do projeto. A ausência de dados clínicos locais e reais constitui a restrição mais significativa. Devido a questões éticas e legais de proteção de dados (RGPD), o projeto não terá acesso a históricos de pacientes reais nesta fase, baseando-se essencialmente em *datasets* sintéticos (ex: *Synthea*) e bases de dados públicas anonimizadas. Esta limitação impede, até à data, a validação do modelo com a complexidade e o "ruído" típicos dos dados hospitalares reais.

Outra limitação reside na dependência de recursos computacionais e API de terceiros (para execução dos LLM), o que poderá impactar a latência do protótipo e exige uma gestão cuidadosa de tempo, custos e otimização durante a fase de desenvolvimento.

4.3 Trabalhos Futuros

A próxima etapa do projeto (DIMEI) não se limita apenas à implementação prática, mas envolve a integração crítica das normas de interoperabilidade (FHIR, ATC, ICD-10) com a arquitetura do sistema. O objetivo primordial será o desenvolvimento do protótipo funcional que permita validar a hipótese de que um sistema de recomendação híbrido consegue ser útil no apoio à redução de erros de prescrição, mantendo a segurança clínica.

Deste modo, após a implementação, será conduzida uma fase de experimentação focada em dois eixos: a avaliação técnica (precisão e revocação na deteção de erros) e a avaliação de usabilidade com profissionais de saúde (escala SUS e modelo TAM).

4.3.1 Melhorias à Metodologia

Espera-se que a fase de desenvolvimento do protótipo conduza a uma revisão iterativa da metodologia, especialmente no que toca à engenharia de *prompts* e à configuração do módulo RAG. A integração de *feedback* contínuo da equipa de orientação será fundamental para refinar a melhoria continua e garantir que as recomendações geradas estão estritamente alinhadas com as normas estabelecidas.

4.3.2 Extensão da Abordagem

Numa fase posterior, será pertinente explorar a escalabilidade da solução desenvolvida, com a sua adaptação a diferentes contextos clínicos. Adicionalmente, integração de outras fontes de dados, como notas clínicas não estruturadas, poderá revelar novas oportunidades para demonstrar o valor dos LLM na interpretação de narrativas médicas complexas.

Assim sendo, a continuidade deste trabalho apresentará potencial para contribuir significativamente para a segurança do doente e para a modernização do apoio aos processos de prescrição médica.

Referências

- [1] R. A. Elliott *et al.*, "Economic analysis of the prevalence and clinical and economic burden of medication error in England," *BMJ Qual. Saf.*, vol. 30, no. 2, pp. 96-105, Jun. 2020, doi: 10.1136/bmjqs-2019-010206.
- [2] Ministério da Saúde, "Sobre os Sistemas de Informação," Serviços Partilhados do Ministério da Saúde. [Online]. Disponível: <https://www.spms.min-saude.pt/sobre-os-sistemas-deinformacao/> [Acedido: 22-Nov-2025].
- [3] J. Graafsma *et al.*, "The use of artificial intelligence to optimize medication alerts generated by clinical decision support systems: a scoping review," *J. Am. Med. Inform. Assoc.*, vol. 31, no. 6, pp. 1411-1422, Mai. 2024, doi: 10.1093/jamia/ocae076.
- [4] H. Y. Jang *et al.*, "Machine learning-based quantitative prediction of drug exposure in drugdrug interactions using drug label information," *npj Digit. Med.*, vol. 5, no. 1, p. 88, Jul. 2022, doi: 10.1038/s41746-022-00639-0.
- [5] M. Felisberto *et al.*, "Override rate of drug-drug interaction alerts in clinical decision support systems: A brief systematic review and meta-analysis," *Health Informatics Journal*, vol. 30, no. 2, Apr. 2024, doi: 10.1177/14604582241263242.
- [6] C. Nebeker *et al.*, "Building the case for actionable ethics in digital health research supported by artificial intelligence," *BMC Med.*, vol. 17, no. 137, Jul. 2019, doi: 10.1186/s12916-019-1377-7.
- [7] M. Ienca *et al.*, "Considerations for ethics review of big data health research: A scoping review," *PLoS ONE*, vol. 13, no. 10, Out. 2018, doi: 10.1371/journal.pone.0204937.
- [8] Association for Computing Machinery, "ACM Code of Ethics and Professional Conduct," Jun. 2018. [Online]. Disponível: <https://www.acm.org/code-of-ethics> [Acedido: 15-Dez-2025].
- [9] Association for Computing Machinery and IEEE Computer Society, "Software Engineering Code of Ethics and Professional Practice," 1999. [Online]. Disponível: <https://www.acm.org/code-of-ethics/software-engineering-code> [Acedido: 15-Dez-2025].
- [10] A. Hanson and L. M. Haddad, "Nursing rights of medication administration," *StatPearls*, Treasure Island (FL), 2023. [Online]. Disponível: <https://www.ncbi.nlm.nih.gov/books/NBK560654/> [Acedido: 04-Jan-2026].
- [11] Autoridade Nacional do Medicamento e Produtos de Saúde (INFARMED), "Resumo das Características do Medicamento (RCM): Ben-U-Ron 1000 mg," *Infomed - Base de Dados Nacional de Medicamentos*, 26 Fev. 2025. [Online]. Disponível:

<https://extranet.infarmed.pt/INFOMED-fo/pesquisa-avancada.xhtml> [Acedido: 03-Jan-2026].

- [12] A. M. Jambrina *et al.*, "Detection and prevention of medication errors by the network of sentinel pharmacies in a Southern European region," *J. Clin. Med.*, vol. 12, no. 1, p. 194, 2023, doi: 10.3390/jcm12010194.
- [13] M. Anzan *et al.*, "Prescribing errors and associated factors in discharge prescriptions in the emergency department: A prospective cross-sectional study," *PLoS ONE*, vol. 16, no. 1, Jan. 2021, doi: 10.1371/journal.pone.0245321.
- [14] G. F. Bonella *et al.*, "Prescribing errors in a Brazilian teaching hospital: Causes and underlying factors from the perspective of junior doctors," *PLoS ONE*, vol. 18, no. 4, Abr. 2023. doi: 10.1371/journal.pone.0284071.
- [15] N. Peiffer-Smadja *et al.*, "Machine learning for clinical decision support in infectious diseases: a narrative review of current applications," *Clinical Microbiology and Infection*, vol. 26, no. 5, pp. 584-595, Mai. 2020. doi: 10.1016/j.cmi.2019.09.009.
- [16] S. Huang *et al.*, "Applications of Clinical Decision Support Systems in Diabetes Care: Scoping Review," *Journal of Medical Internet Research*, vol. 25, Dez. 2023. doi: 10.2196/51024.
- [17] L. G. Armando *et al.*, "Clinical decision support systems to improve drug prescription and therapy optimisation in clinical practice: a scoping review," *BMJ Health & Care Informatics*, vol. 30, no. 1, Mai. 2023. doi: 10.1136/bmjhci-2022-100683.
- [18] M. R. Pinsky *et al.*, "Use of artificial intelligence in critical care: opportunities and obstacles," *Critical Care*, vol. 28, no. 1, p. 113, Abr. 2024. doi: 10.1186/s13054-024-04860-z.
- [19] Z. Fayyaz *et al.*, "Recommendation Systems: Algorithms, Challenges, Metrics, and Business Opportunities," *Applied Sciences*, vol. 10, no. 21, Nov. 2020. doi: 10.3390/app10217748.
- [20] F. Pinelas, "Sistema de recomendação para alívio de stress," Dissertação de Mestrado, ISEP, Porto, Portugal, 2022. [Online]. Disponível: <https://recipp.ipp.pt/entities/publication/0cfdd272-1e84-4a72-9b7c-1af341d1a557> [Acedido: 15-Dez-2025].
- [21] S. Lubos *et al.*, "An overview of video recommender systems: state-of-the-art and research issues," *Frontiers in big data*, vol. 6, Out. 2023. doi: 10.3389/fdata.2023.1281614.

- [22] O. Fouad *et al.*, "A comprehensive review of music recommendation systems," *Advanced Sciences and Technology Journal*, vol. 2, no. 1, pp. 1-18, Jan. 2025. doi: 10.21608/astj.2025.342474.1017.
- [23] M. Uta *et al.*, "Knowledge-based recommender systems: overview and research directions," *Frontiers in Big Data*, vol. 7, Feb. 2024, doi: 10.3389/fdata.2024.1304439.
- [24] S. Nabil *et al.*, "Demographic information combined with collaborative filtering for an efficient recommendation system," *International Journal of Electrical and Computer Engineering (IJECE)*, vol. 14, no. 5, Out. 2024, doi: 10.11591/ijece.v14i5.pp5916-5925.
- [25] S. Kulkarni and S. F. Rodd, "Context Aware Recommendation Systems: A review of the state of the art techniques," *Computer Science Review*, vol. 37, Mai. 2020, doi: 10.1016/j.cosrev.2020.100255.
- [26] M. Abusair *et al.*, "Context-Aware Recommender System based on Content Filtering," *2021 IEEE 15th International Conference on Application of Information and Communication Technologies (AICT)*, p. 1-6, Out. 2021, doi: 10.1109/AICT52784.2021.9620478.
- [27] Y. Li and X. Lin, "Study of collaborative filtering recommendation with user clustering incorporating implicit social relationships and trust relationships," *PLOS ONE*, vol. 20, no. 10, p. 1-15, Out. 2025, doi: 10.1371/journal.pone.0332998.
- [28] Z. Yao, "Review of movie recommender systems based on deep learning," *SHS Web of Conferences*, vol. 159, Fev. 2023. doi: 10.1051/shsconf/202315902010.
- [29] R. De Croon *et al.*, "Health recommender systems: Systematic review," *J. Med. Internet Res.*, vol. 23, no. 6, Jun. 2021, doi: 10.2196/18035.
- [30] Z. Sadeghi *et al.*, "A review of explainable artificial intelligence in healthcare," *Comput. Electr. Eng.*, vol. 118, Jun. 2024, doi: 10.1016/j.compeleceng.2024.109370.
- [31] S.-C. Chien *et al.*, "Alerts in Clinical Decision Support Systems (CDSS): A Bibliometric Review and Content Analysis," *Healthcare*, vol. 10, no. 4, p. 601, Mar. 2022. doi: 10.3390/healthcare10040601.
- [32] G. Van De Sijpe *et al.*, "Overall performance of a drug-drug interaction clinical decision support system: quantitative evaluation and end-user survey," *BMC Medical Informatics and Decision Making*, vol. 22, no. 1, p. 48, Fev. 2022. doi: 10.1186/s12911-022-01783-z.
- [33] C. Pais *et al.*, "Large language models for preventing medication direction errors in online pharmacies," *Nature Medicine*, vol. 30, pp. 1574-1582, Abr. 2024. doi: 10.1038/s41591-024-02933-8.

- [34] Y. Shen *et al.*, "An ontology-driven clinical decision support system (IDDAP) for infectious disease diagnosis and antibiotic prescription," *Artif. Intell. Med.*, vol. 86, pp. 20-32, Fev. 2018, doi: 10.1016/j.artmed.2018.01.003.
- [35] M. Gholamzadeh *et al.*, "The application of knowledge-based clinical decision support systems to enhance adherence to evidence-based medicine in chronic disease," *J. Healthc. Eng.*, Mai. 2023, doi: 10.1155/2023/8550905.
- [36] S. S. Alqahtani *et al.*, "Artificial intelligence in clinical pharmacy—A systematic review of current scenario and future perspectives," *Digital Health*, vol. 11, pp. 1-23, Out. 2025. doi: 10.1177/20552076251388145.
- [37] T. N. Poly *et al.*, "Appropriateness of Overridden Alerts in Computerized Physician Order Entry: Systematic Review," *JMIR Medical Informatics*, vol. 8, no. 7, Jul. 2020. doi: 10.2196/15653.
- [38] S. Kresevic *et al.*, "Optimization of hepatological clinical guidelines interpretation by large language models: A retrieval augmented generation-based framework," *npj Digit. Med.*, vol. 7, no. 102, Abr. 2024, doi: 10.1038/s41746-024-01091-y.
- [39] T. I. Wilhelm *et al.*, "Large language models for therapy recommendations across 3 clinical specialties: Comparative study," *J. Med. Internet Res.*, vol. 25, Out. 2023, doi: 10.2196/49324.
- [40] W. X. Zhao *et al.*, "A Survey of Large Language Models," *arXiv*, 2023. doi: 10.48550/arXiv.2303.18223
- [41] Y. Gao *et al.*, "Retrieval-Augmented Generation for Large Language Models: A Survey," *arXiv*, 2024. doi: 10.48550/arXiv.2312.10997.
- [42] Z. Ji *et al.*, "Survey of Hallucination in Natural Language Generation," *ACM Computing Surveys*, vol. 55, no. 12, pp. 1-38, Mar. 2023. doi: 10.1145/3571730.
- [43] E. Alsentzer *et al.*, "Publicly Available Clinical BERT Embeddings," *arXiv*, Jun. 2019. doi: 10.48550/arXiv.1904.03323.
- [44] J. Shang *et al.*, "Pre-training of Graph Augmented Transformers for Medication Recommendation," *arXiv*, Nov. 2019. doi: 10.48550/arXiv.1906.00346.
- [45] C. Yang *et al.*, "SafeDrug: Dual Molecular Graph Encoders for Safe Drug Recommendation," *arXiv*, Jul. 2022. doi: 10.48550/arXiv.2105.02711.
- [46] S. A. Hollingworth and T. Kairuz, "Measuring medicine use: applying ATC/DDD methodology to real-world data," *Pharmacy*, vol. 9, no. 1, pp. 60, Mar. 2021. doi: 10.3390/pharmacy9010060.

- [47] Z. Juhásová *et al.*, "The use of international classification of diseases codes to identify hospital admissions linked with adverse drug events: Validation study," *British Journal of Clinical Pharmacology*, vol. 91, no. 10, pp. 2910-2918, 2025. doi: 10.1002/bcp.70116.
- [48] N. Pimenta *et al.*, "Interoperability of Clinical Data through FHIR: A review," *Procedia Computer Science*, vol. 220, pp. 856-861, 2023. doi: 10.1016/j.procs.2023.03.115.
- [49] B. Vasey *et al.*, "Reporting guideline for the early-stage clinical evaluation of decision support systems driven by artificial intelligence: DECIDE-AI," *Nature Medicine*, vol. 28, pp. 924-933, Mai. 2022. doi: 10.1038/s41591-022-01772-9.
- [50] J. C. L. Ong *et al.*, "Large language model as clinical decision support system augments medication safety in 16 clinical specialties," *Cell Reports Medicine*, vol. 6, no. 10, Out. 2025. doi: 10.1016/j.xcrm.2025.102323.
- [51] J. Brooke, "SUS: A retrospective," *J. Usability Stud.*, vol. 8, no. 2, pp. 29-40, Fev. 2013. [Online]. Disponível: https://www.researchgate.net/publication/285811057_SUS_a_retrospective [Acedido: 15-Dez-2025].
- [52] S.-C. Chien *et al.*, "Using technology acceptance model to explore physicians' perspectives of clinical decision support system alerts," *BMJ Health & Care Informatics*, vol. 32, no. 1, Jun. 2025. doi: 10.1136/bmjhci-2024-101128.
- [53] K. Seden *et al.*, "Cross-sectional study of prescribing errors in patients admitted to nine hospitals across North West England," *BMJ Open*, vol. 3, no. 1, Jan. 2013, doi: 10.1136/bmjopen-2012-002036.
- [54] A. Avery *et al.*, "The prevalence and nature of prescribing and monitoring errors in English general practice: a retrospective case note review," *British Journal of General Practice*, Jul. 2013, doi: 10.3399/bjgp13X670679.

Anexos

Anexo A - Project Charter

1. Informação geral				
Nome do Projeto:		Sistema de Recomendação e Alertas para Identificar e Prevenir Erros de Prescrição de Medicamentos		
Sponsor:		Orientador: Dulce Mota; Coorientador: Constantino Martins		
Instituição / Departamento		ISEP/GECAD - Research Group on Intelligent Engineering and Computing for Advanced Innovation and Development		
2. Equipa do Projeto				
Cargo	Nome	Departamento	Contact Tel	E-mail
Estudante	Pedro Domingues	DEI	-	1211492@isep.ipp.pt
Orientadora	Dulce Mota	DEI	-	mdm@isep.ipp.pt
Coorientador	Constantino Martins	DEI/GECAD	-	acm@isep.ipp.pt
3. Stakeholders				
Nome		Poder	Interesse	
Médicos		Alto	Alto	
Farmacêuticos		Alto	Médio	
Gestores Hospitalares		Médio	Médio	
Instituições de saúde		Médio	Alto	
Programadores/desenvolvedores de software		Médio	Baixo	
4. Âmbito				

Problema / justificação
Existir um elevado número de erros de prescrição. A prescrição de medicamentos é uma das etapas mais críticas do processo terapêutico, estando frequentemente associada a erros que podem comprometer a eficácia do tratamento e a segurança do paciente. Estudos indicam taxas elevadas de erro na prescrição, variando entre 5% em cuidados de saúde primários e 44% em centros hospitalares [53],[54]. A utilização de sistemas inteligentes de recomendação e alerta tem vindo a assumir um papel central na prevenção destes erros, permitindo apoiar os profissionais de saúde na tomada de decisão clínica. Este projeto propõe o desenvolvimento de um Sistema de Recomendação e Alertas capaz de identificar potenciais incompatibilidades, interações medicamentosas, doses incorretas e duplicação de terapias, fornecendo recomendações personalizadas e em tempo real.
Objetivos do projeto
Diminuir o número de erros de prescrição médica (no mínimo 50%) com o desenvolvimento e validação de um sistema de recomendação e alertas que identifique e previna erros de prescrição de medicamentos, contribuindo para a melhoria da segurança do paciente e para o apoio à decisão clínica.
Benefícios
Valor que o clientes ou utilizadores retirarão no futuro com esta dissertação, exemplos: Redução do número de erros de prescrição (no mínimo 50%). Redução de custo (≈17,262,640 € por ano): [1].
Entregáveis
Prototipo funcional Código fonte Relatório de Dissertação Apresentação final
5. Tempo
Milestones / Datas

Datas que eu me comprometo (podem alterar) Draft: Resumo, Introdução, Contexto e Estado da Arte: 10 de Dezembro 2026. Primeiro Protótipo: 28 de Fevereiro Protótipo Final: 31 de Março Datas obrigatórias (deadlines, que não podem mudar) Extended abstract: 15 de Dezembro 2025; Introdução, Contexto e Estado da Arte: 7 de Janeiro 2026.	
6. Custo	
Fontes de custo	
Pode não existir mas deve ser previsto mesmo para futuro, alguns exemplos: Licenças de bases de dados Licenças de software	
7. Pressupostos	8. Restrições
Utilização de bases de dados Americanas: Sintéticas - Synthea. Reais - mas com formação ética prévia, MIMIC.	Prazos académicos. Escassez de datasets portugueses.
Notas	

Anexo B - Estrutura Analítica do Projeto




Figura 2 - Estrutura Analítica do Projeto (EAP)

A Figura 2 está disponível em:

https://www.canva.com/design/DAG50BCVImA/ylqeU03FMkH_hrypXknmw/edit?utm_content=DAG50BCVImA&utm_campaign=designshare&utm_medium=link2&utm_source=sharebutton

Anexo C - Diagrama de *Gantt*

A Figura 1 (Diagrama de *Gantt*) está disponível em: https://myisepipp-my.sharepoint.com/:u:/g/personal/1211492_isepp_pt/EZhp0xi9TkZlrSPWc-7vBZQBY-57iRYe9QMA7qUizbRK1A?e=M7HzF9

Anexo D - Diagrama de *PRISMA*




Figura 4 - Digrama de *PRISMA*