

SISTEMA DE RECOMENDAÇÃO E ALERTAS PARA IDENTIFICAR E PREVENIR ERROS DE PRESCRIÇÃO DE MEDICAMENTOS

Pedro Miguel Almeida Domingues

**Dissertação para obtenção do Grau de Mestre em
Engenharia Informática, Área de Especialização em
Jogos, Sistemas Gráficos e Interativos**

Orientadora: Dulce Mota

Co-orientador: Constantino Martins

Porto, janeiro 2026

Declaração de Integridade

Declaro ter conduzido este trabalho académico com integridade.

Não plagiei ou apliquei qualquer forma de uso indevido de informações ou falsificação de resultados ao longo do processo que levou à sua elaboração.

Portanto, o trabalho apresentado neste documento é original e de minha autoria, não tendo sido utilizado anteriormente para nenhum outro fim.

Declaro ainda que tenho pleno conhecimento do Código de Conduta Ética do P.PORTO.

ISEP, Porto, x de junho de 2026

Resumo

Os erros de prescrição médica representam um desafio crítico de saúde pública, com impacto direto na segurança do doente e nos custos hospitalares. Este trabalho propõe a investigação e o desenvolvimento de um sistema de apoio à decisão clínica com recomendação e alertas para identificar e prevenir estes erros.

A revisão da literatura abordou os erros de prescrição, os sistemas de apoio à decisão clínica, os sistemas de recomendação em saúde e a utilização de inteligência artificial para explicação e apoio à decisão. A partir dessa análise, foi adotada uma abordagem híbrida que combina um motor de segurança clínica baseado em regras determinísticas, responsável pela deteção de interações, contraindicações, duplicações terapêuticas e riscos associados ao perfil do utente, com um motor de recomendação baseado em conhecimento, contexto clínico e aprendizagem supervisionada. Adicionalmente, foi integrado um módulo de explicação baseado em LLM, utilizado para gerar explicações em linguagem natural a partir dos alertas e recomendações previamente produzidos pelo sistema. Para reduzir riscos associados à utilização de IA generativa, foram implementados mecanismos de validação linguística, validação estrutural e *fallback* determinístico.

A dissertação foi desenvolvida no âmbito do Mestrado em Engenharia Informática - Jogos, Sistemas Gráficos e Interativos (PREPD / DIMEI) do Instituto Superior de Engenharia do Porto (ISEP), juntamente com o GECAD.

A investigação efetuada apresenta as oportunidades e os desafios éticos e técnicos inerentes à aplicação de IA na área da saúde, sendo uma base sólida para o desenvolvimento e validação futura de um protótipo flexível, eficaz e seguro.

Palavras-chave: Sistemas de Recomendação, Erros de Prescrição, Sistemas de Recomendação em Saúde, Grandes Modelos de Linguagem (LLM), Apoio à Decisão Clínica, Segurança do Utente.

Abstract

Prescription errors represent a critical public health challenge, with a direct impact on patient safety and hospital costs. This work proposes the research and development of an intelligent recommendation and alert system to identify and prevent these errors.

The literature review addressed prescription errors, clinical decision support systems, recommender systems in healthcare, and the use of artificial intelligence for explanation and decision support. Based on this analysis, a hybrid approach was adopted, combining a deterministic clinical safety engine, responsible for detecting drug interactions, contraindications, therapeutic duplications and risks associated with the patient profile, with a recommendation engine based on knowledge, clinical context and supervised learning. Additionally, an LLM-based explanation module was integrated, used only to generate natural language explanations from the alerts and recommendations previously produced by the system. To reduce risks associated with generative AI, linguistic validation, structural validation and deterministic fallback mechanisms were implemented.

This dissertation was developed within the scope of the Master in Informatics Engineering - Games, Graphics, and Interactive Systems (PREPD / DIMEI) at the School of Engineering of the Polytechnic of Porto (ISEP), in collaboration with the GECAD research group.

The conducted research presents the opportunities as well as the ethical and technical challenges inherent to the application of AI in healthcare, providing a solid foundation for the future development and validation of a flexible, effective, and safe prototype.

Keywords: Recommender Systems, Prescription Errors, Health Recommender Systems, Large Language Models (LLM), Clinical Decision Support, Patient Safety.

Agradecimentos

Em primeiro lugar, gostaria de agradecer à minha família e à minha namorada. A vossa presença constante e o apoio incansável ajudaram imenso para o sucesso deste trabalho, dando-me a força e o ânimo necessários para superar os desafios, tanto académicos como pessoais, que surgiram ao longo deste percurso.

Aos meus orientadores, Dulce Mota e Constantino Martins, e docentes do ISEP expresso um agradecimento especial. A vossa orientação científica, aliada a uma disponibilidade constante e crítica construtiva, foi determinante para melhorar este projeto e enriquecer a minha aprendizagem.

Um agradecimento também aos meus colegas de turma do mestrado, pelo espírito de entreajuda e pelo companheirismo que tornou este percurso académico mais enriquecedor.

Por fim, quero expressar a minha gratidão a todos os que, direta ou indiretamente, ajudaram na concretização deste trabalho. O vosso contributo foi essencial para alcançar este objetivo.

Índice

1	Introdução	1
1.1	Enquadramento.....	1
1.2	Problema de Investigação.....	2
1.2.1	Descrição	2
1.2.2	Restrições	3
1.2.3	Desafios.....	3
1.3	Objetivos	4
1.4	Metodologia	5
1.5	Abordagem	6
1.6	Contributos	7
1.7	Considerações Éticas	8
1.7.1	Interpretação Analítica.....	8
1.7.2	Interpretação Crítica	8
1.7.3	Interpretação Ética	9
1.8	Estrutura do Documento	10
2	Estado da Arte	13
	Introdução.....	13
2.1	Metodologia de Revisão da Literatura.....	13
2.1.1	Questões de Pesquisa	13
2.1.2	Fontes e conjuntos de dados	14
2.1.3	Termos de pesquisa e estratégia PRISMA	15
2.1.4	Critérios de elegibilidade e seleção	15
2.1.5	Procedimento de recolha e síntese de dados	15
2.2	Erros de Prescrição e Segurança do Doente	15
2.2.1	Erros de Prescrição	16
2.2.2	Tipos de Erros de Prescrição	16
2.3	Sistemas de Apoio à Decisão Clínica.....	17
2.3.1	Evolução e Tipologia.....	17
2.3.2	Barreiras à Adoção e Desafios Éticos	18
2.3.3	Eficácia e Impacto Clínico	19
2.4	Sistemas de Recomendação	19
2.4.1	Filtragem Colaborativa (<i>Collaborative Filtering</i>).....	19
2.4.2	Filtragem Baseada em Conteúdo (<i>Content-Based</i>)	20
2.4.3	Filtragem Baseada em Conhecimento (<i>Knowledge-Based</i>)	20
2.4.4	Filtragem Demográfica	20
2.4.5	Sistemas Sensíveis ao Contexto (<i>Context-Aware</i>)	21
2.4.6	Filtragem Comunitária (<i>Community-Based</i>)	21
2.4.7	Filtragem Híbrida	22
2.4.8	Comparação entre Técnicas de Filtragem	24

2.5	Sistemas de Recomendação em Saúde	25
2.5.1	Trabalhos relacionados	25
2.5.2	Limitações atuais.....	29
2.6	Inteligência Artificial na Saúde.....	30
2.6.1	Arquitetura Transformer e LLM	31
2.6.2	<i>Retrieval-Augmented Generation</i> (RAG).....	33
2.6.3	Tendências Atuais	34
2.7	Interoperabilidade e Normas	37
2.8	Métricas de Avaliação	38
2.8.1	Métricas de Performance.....	38
2.8.2	Métricas de Usabilidade e Aceitação	39
2.9	Síntese Crítica e Lacunas.....	39
3	Análise e Design do Sistema.....	40
3.1	Visão Geral do Sistema	40
3.2	Requisitos Funcionais	42
3.3	Requisitos Não Funcionais.....	43
3.4	Casos de Uso	45
3.5	Modelo de Domínio.....	45
3.6	Cenários de Utilização.....	47
4	Arquitetura do Sistema	50
4.1	Visão Geral	50
4.2	Arquitetura Global	51
4.3	Componentes do Sistema	53
4.3.1	Módulo de Orquestração	53
4.3.2	Motor de Segurança Clínica	54
4.3.3	Motor de Recomendação	55
4.3.4	Módulo de Aprendizagem Supervisionada.....	56
4.3.5	Módulo de Explicação LLM	57
4.3.6	Camada de Persistência e Dados.....	59
4.3.7	Interface de Utilizador	59
4.4	Fluxo de Dados Online	59
4.5	Fluxo Offline de Treino e Validação	61
4.6	Decisões Arquiteturais.....	62
5	Implementação	64
5.1	Tecnologias Utilizadas	64
5.2	Backend.....	65
5.2.1	Modelos de Dados (schemas.py).....	66
5.2.2	Base de Conhecimento Farmacológico (knowledge_base.json).....	66

5.2.3	Normalização de Entradas (normalization.py)	67
5.2.4	Motor de Segurança Clínica (rules_engine.py)	68
5.2.5	Motor de Recomendação (recommender.py)	69
5.2.6	Camada de Persistência (database.py)	70
5.3	Frontend	70
5.3.1	Estrutura e Modos de Operação	70
5.3.2	Apresentação de Resultados e Mecanismo de Feedback	71
5.4	Integração de LLM	72
5.4.1	Construção do Prompt Clínico	72
5.4.2	Validação da Resposta e Mecanismo de Fallback	73
5.5	Integração de Dados Clínicos	73
5.5.1	Geração de Dados com Synthea	73
5.5.2	Construção do Índice de Contextos Clínicos	73
5.5.3	Construção do Dataset de Treino (Silver e Golden Labels)	74
5.5.4	Treino, Avaliação e Seleção do Modelo	75
5.5.5	Testes Clínicos de Regressão	76
6	Avaliação e Validação	77
6.1	Objetivos da Avaliação	77
6.2	Metodologia Experimental	77
6.3	Cenários Clínicos de Regressão	77
6.4	Métricas	77
6.5	Resultados do Motor de Segurança Clínica	77
6.6	Resultados do Modelo Supervisionado	77
6.7	Resultados da Explicação LLM	78
6.8	Discussão	78
7	Conclusão	80
7.1	Conclusões	80
7.2	Contributos	80
7.3	Limitações	80
7.4	Trabalho Futuro	80
Anexos		88
Anexo A	- Project Charter	88
Anexo B	- Estrutura Analítica do Projeto	91
Anexo C	- Diagrama de <i>Gantt</i>	92
Anexo D	- Diagrama de <i>PRISMA</i>	93
Anexo E	- Planeamento	94
E.1	Gestão de Riscos	94

E.1.1 Principais Riscos Identificados	94
E.1.2 Plano de Mitigação	95
E.1.3 Impacto dos Riscos	95
E.1.4 Análise Geral dos Riscos	96
E.2 Gestão de Competências	97
E.2.1 Competências Necessárias	97
E.2.3 Desenvolvimento de Competências	97
E.3.4 Plano de Desenvolvimento de Competências	99
E.3 Plano de Desenvolvimento	101
E.4 Planeamento do Projeto	101
E.4.1 <i>Project Charter</i>	101
E.4.1 Estrutura Analítica do Projeto (EAP)	102
E.1.3 Cronograma e Entregáveis	102
E.4.3 Gestão de Recursos	104
E.4.4 Monitorização e Controlo	105
E.5 Conclusões do Planeamento	106

Lista de Figuras

Figura 1 - Diagrama de <i>Gantt</i> do projeto.	104
Figura 2 - Estrutura Analítica do Projeto (EAP)	91
Figura 4 - Diagrama de <i>PRISMA</i>	93

Lista de Tabelas

Tabela 1 - Matriz de Riscos e Mitigação	96
Tabela 2 - Matriz de Diagnóstico de Competências	98
Tabela 3 - Lista de entregáveis da unidade curricular de PREPD	103
Tabela 4 - Comparação entre Técnicas de Filtragem em Sistemas de Recomendação.	24

Acrónimos e Símbolos

Lista de Acrónimos e Definições

ACM	<i>Association for Computing Machinery</i> - Organização internacional científica e educativa dedicada à computação.
AINE	Anti-Inflamatórios Não Esteroides - Classe de medicamentos utilizados para tratar a dor e inflamação, frequentemente associados a contraindicações renais.
API	<i>Application Programming Interface (Interface de Programação de Aplicações)</i> - Conjunto de protocolos que permite a comunicação e troca de dados entre diferentes sistemas de software.
ATC	<i>Anatomical Therapeutic Chemical</i> - Sistema de classificação internacional de fármacos, divididos em grupos de acordo com o órgão ou sistema sobre o qual atuam.
Backend	A camada de acesso a dados e lógica de um sistema, responsável pelo processamento, invisível ao utilizador final.
Big Data	Conjuntos de dados extremamente grandes e complexos que exigem ferramentas avançadas para captura, gestão e processamento.
CDSS	<i>Clinical Decision Support Systems</i> (Sistemas de Apoio à Decisão Clínica) - Ferramentas informáticas desenhadas para auxiliar profissionais de saúde na tomada de decisões clínicas.
CPOE	<i>Computerized Physician Order Entry</i> - Ferramentas informáticas desenhadas para auxiliar profissionais de saúde na tomada de decisões clínicas.
DDI	<i>Drug-Drug Interactions</i> (Interações Medicamentosas) - Alteração do efeito de um fármaco devido à administração simultânea de outro.
DIMEI	Dissertação do Mestrado em Engenharia Informática - Unidade curricular final do curso onde se desenvolve o projeto prático.
DL	<i>Deep Learning</i> - Subcampo da Inteligência Artificial que utiliza redes neuronais com múltiplas camadas para aprender padrões complexos a partir de grandes volumes de dados.
EAP	Estrutura Analítica do Projeto - Decomposição hierárquica do trabalho a ser executado pela autor do projeto para cumprir os objetivos.
EHR	<i>Electronic Health Record</i> (Registo de Saúde Eletrónico) - Versão digital do histórico médico de um utente, mantido pelo prestador de cuidados de saúde.

<i>Embeddings</i>	Representações vetoriais de dados (como palavras ou códigos médicos) num espaço multidimensional, capturando o seu significado semântico.
EM	Erro de Medicação - Qualquer evento medicamentoso evitável que possa causar ou levar ao uso inadequado do medicamento ou a danos no doente.
FHIR	<i>Fast Healthcare Interoperability Resources</i> - Norma para a troca de informações de saúde eletrónicas, facilitando a interoperabilidade entre sistemas distintos.
<i>Frontend</i>	A interface gráfica de uma aplicação com a qual o utilizador interage diretamente.
GAT	<i>Graph Attention Networks</i> (Redes de Atenção em Grafos) - Tipo de rede neuronal que opera em dados estruturados em grafos, utilizando mecanismos de atenção.
GECAD	<i>Research Group on Intelligent Engineering and Computing for Advanced Innovation and Development</i> - Grupo de investigação do ISEP onde o projeto se insere.
GNN	<i>Graph Neural Networks</i> (Redes Neurais de Grafos) - Classe de redes neurais desenhadas para realizar inferências sobre dados descritos por grafos.
GPU	<i>Graphics Processing Unit</i> (Unidade de Processamento Gráfico) - Hardware especializado utilizado para acelerar o treino de modelos de Inteligência Artificial.
IA	Inteligência Artificial - Ramo da ciência da computação que se dedica ao desenvolvimento de sistemas capazes de realizar tarefas que requerem inteligência humana.
ICD	<i>International Classification of Diseases</i> (Classificação Internacional de Doenças) - Sistema global de categorização de doenças e problemas relacionados com a saúde.
IEEE	<i>Institute of Electrical and Electronics Engineers</i> - Organização profissional técnica dedicada ao avanço da tecnologia e engenharia.
ISEP	Instituto Superior de Engenharia do Porto - Instituição de ensino superior onde o mestrado é lecionado.
JSON	<i>JavaScript Object Notation</i> - Formato estruturado de intercâmbio de dados, fácil de ler e escrever por humanos e máquinas.

LLM	<i>Large Language Models</i> (Grandes Modelos de Linguagem) - Modelos de IA treinados em vastas quantidades de texto capazes de compreender e gerar linguagem natural.
LSTM	<i>Long Short-Term Memory</i> - Arquitetura de rede neuronal recorrente capaz de aprender dependências de longo prazo em sequências de dados.
MEI	Mestrado em Engenharia Informática
MIMIC	<i>Medical Information Mart for Intensive Care</i> - Base de dados pública de cuidados intensivos utilizada para investigação em informática médica.
ML	<i>Machine Learning</i> (Aprendizagem Automática) - Campo da IA que permite aos sistemas aprenderem e melhorarem a partir da experiência sem serem explicitamente programados.
MPNN	<i>Message Passing Neural Network</i> (Rede Neuronal de Passagem de Mensagens) - Arquitetura de rede neuronal para grafos onde os “nós” trocam informações (mensagens) com os seus vizinhos.
MVP	<i>Minimum Viable Product</i> (Produto Mínimo Viável) - Versão de um produto com funcionalidades suficientes para satisfazer os primeiros utilizadores e obter feedback.
NHS	<i>National Health Service</i> - Serviço Nacional de Saúde do Reino Unido.
PID	<i>Proportional-Integral-Derivative</i> (Derivada-Integral-Proporcional) - Mecanismo de controlo por realimentação utilizado em sistemas industriais e adaptado para otimização de funções de perda em IA.
PREPD	Preparação para Dissertação - Unidade curricular focada no planeamento e revisão bibliográfica do projeto de mestrado.
PRISMA	<i>Preferred Reporting Items for Systematic Reviews and Meta-Analyses</i> - Conjunto de diretrizes para reportar revisões sistemáticas e meta-análises.
Prompt	Instrução textual fornecida a um modelo de linguagem para guiar a sua resposta ou tarefa.
RAG	<i>Retrieval-Augmented Generation</i> - Técnica que otimiza a saída (<i>output</i>) de um LLM ao referenciar uma base de conhecimento externa fidedigna antes de gerar a resposta.
RAM	Reações Adversas a Medicamentos - Efeitos nocivos e não intencionais resultantes da utilização de um medicamento.

RCM	Resumo das Características do Medicamento - Documento oficial aprovado, geralmente pelo INFARMED, que descreve as propriedades e as condições de utilização segura de um medicamento.
RGPD	Regulamento Geral sobre a Proteção de Dados - Legislação sobre a proteção de dados e privacidade para todos os cidadãos da União Europeia.
RNN	<i>Recurrent Neural Network</i> (Redes Neurais Recorrentes) - Classe de redes neurais artificiais onde as conexões entre nós formam um grafo direcionado ao longo de uma sequência temporal.
RSE	Registo de Saúde Eletrónico - Repositório digital de informações de saúde de um utente.
SPMS	Serviços Partilhados do Ministério da Saúde - Entidade responsável pelos sistemas de informação da saúde em Portugal.
Sprint	Período de tempo fixo (geralmente quinzenal) durante o qual tarefas específicas devem ser completadas, no contexto de metodologias ágeis.
STOPP	<i>Screening Tool of Older Persons' Prescriptions</i> - Ferramenta de rastreio para detetar prescrições potencialmente inapropriadas em idosos.
SUS	<i>System Usability Scale</i> - Escala com um conjunto de 10 questões para avaliação da usabilidade de sistemas.
Synthea	Ferramenta de acesso aberto para a geração de registos de utentes sintéticos e realistas.
TAM	<i>Technology Acceptance Model</i> - Teoria que modela como os utilizadores aceitam e usam uma tecnologia.
Transformer	Arquitetura de <i>Deep Learning</i> baseada em mecanismos de atenção, que serve de base para a maioria dos LLM modernos.
UCI	Unidades de Cuidados Intensivos - Secção hospitalar especializada no tratamento de doentes graves.
UX	<i>User Experience</i> (Experiência do Utilizador) - O conjunto de sentimentos e interações de uma pessoa ao utilizar um sistema ou produto.

Lista de Símbolos

$\approx$	Aproximadamente
$>$	Maior que
$\geq$	Maior ou igual que
$\mathbf{d}$	Vetor do documento
$\mathbf{d}_k$	Dimensão dos vetores chave (<i>Keys</i>)
$\mathbf{h}_t$	Estado oculto no instante t
$\mathbf{K}$	Matriz de Chaves (<i>Keys</i>)
n	Tamanho da sequência ou número de amostras
$O(n)$	Notação <i>Big O</i> (Complexidade temporal)
$\mathbf{Q}$	Matriz de Consultas (<i>Queries</i>)
$\mathbf{q}$	Vetor da consulta
$\mathbf{V}$	Matriz de <i>Values</i> (Valores)
$\text{sim}(\mathbf{q}, \mathbf{d})$	Pontuação de similaridade entre a consulta e o documento

1 Introdução

Este capítulo tem como objetivo apresentar uma contextualização do projeto a desenvolver na área de sistemas de recomendação relacionados com a identificação e prevenção de erros de prescrição de medicamentos.

Inicia-se com a contextualização do problema, seguida da caracterização do problema de investigação e da explicitação dos objetivos que orientam a sua conceção. São ainda descritas a metodologia de investigação adotada, a abordagem técnica proposta e os contributos esperados, concluindo com as considerações éticas inerentes a um projeto na área da saúde digital e com a descrição da estrutura deste documento.

1.1 Enquadramento

Este relatório de dissertação do Mestrado em Engenharia Informática (MEI) do Instituto Superior de Engenharia do Porto (ISEP) teve uma duração de 1 ano, com o apoio do *Research Group on Intelligent Engineering and Computing for Advanced Innovation and Development* (GECAD).

A prescrição de medicamentos constitui uma das etapas mais críticas do processo terapêutico, desempenhando um papel crucial na eficácia dos tratamentos e na segurança dos utentes.

Na última década, diversos estudos mostram que os erros de prescrição continuam a ser um problema persistente e de grande impacto nos sistemas de saúde. A revisão de Elliott *et al.* [1] estimou que 237 milhões de erros de medicação ocorrem anualmente durante o processo de medicação em Inglaterra, sendo que 38,4% acontecem nos cuidados primários e 72% têm pouco ou nenhum potencial de dano, no entanto, 66 milhões são potencialmente significativos clinicamente. As reações adversas evitáveis custaram ao *National Health Service* (NHS) cerca de 98.462.582 libras por ano ($\approx 111.582.228,74$ €), com a utilização de 181.626 dias de internamento, provocando cerca de 1.708 mortes. Destas incluem eventos adversos nos cuidados primários que levam a internamento hospitalar (83,7 milhões de libras, provocando

627 mortes) e eventos adversos nos cuidados secundários que levam a internamentos hospitalares mais longos (14,8 milhões de libras, provocando 1.081 mortes).

Atualmente verifica-se uma crescente digitalização dos sistemas de informação em saúde, gerido em Portugal pelos Serviços Partilhados do Ministério da Saúde (SPMS) [2], e a adoção generalizada de registos clínicos eletrónicos, o que permite emergir novas oportunidades para o desenvolvimento de ferramentas inteligentes capazes de apoiar os profissionais de saúde no processo de prescrição. Em particular, os Sistemas de Recomendação têm sido amplamente adotados em múltiplos setores, nomeadamente no entretenimento e e-commerce, demonstrando elevada eficácia na personalização de decisões complexas, e começam a ser aplicados ao domínio da saúde, o que pode incluir a prescrição médica, quanto à deteção de interações medicamentosas, contraindicações e terapias duplicadas [3],[4].

1.2 Problema de Investigação

1.2.1 Descrição

O problema de investigação deste projeto foca-se na elevada prevalência de erros de prescrição de medicação e na insuficiência das ferramentas atuais para mitigar este risco de forma eficaz e personalizada. Esta situação resulta num risco elevado de morbimortalidade para os utentes e em custos para as instituições de saúde e para a economia geral.

A causa principal deste problema não se limita apenas ao erro do profissional de saúde, mas estende-se à escassez de *software* inteligente capaz de oferecer recomendações contextualizadas em tempo real.

Este problema tem-se tornado mais evidente devido a vários fatores, nomeadamente:

- **Complexidade Farmacológica:** Os medicamentos possuem características específicas e múltiplas variáveis (grupo farmacológico, princípio ativo, dosagem, via de administração, indicações, contraindicações, interações medicamentosas), tornando o processo de prescrição e administração mais complexo, sendo por vezes difícil para o profissional de saúde considerar todas as permutações possíveis durante uma consulta rápida.
- **Limitações dos Sistemas Atuais:** A maioria das ferramentas de suporte à decisão baseia-se em regras rígidas, faltando flexibilidade para lidar com a incerteza ou para fornecer sugestões baseadas em evidência de forma proativa.
- **Impacto Transversal nos Stakeholders:** O erro afeta diretamente médicos, farmacêuticos e utentes, bem como as entidades reguladoras e instituições de saúde, que lidam com as consequências clínicas, operacionais e financeiras dos eventos adversos associados aos erros de prescrição.

Estes fatores agravam a discrepância entre a necessidade de apoio à prática médica segura e a capacidade de resposta dos sistemas de informação tradicionais, comprometendo a qualidade do serviço prestado ao doente.

1.2.2 Restrições

A realização deste projeto encontra-se condicionada pelas seguintes restrições:

- **Privacidade:** Devido a questões éticas e legais do Regulamento Geral sobre a Proteção de Dados (RGPD), não será possível aceder a dados reais de utentes ou históricos clínicos hospitalares nesta fase, recorrendo-se exclusivamente a *datasets* públicos anonimizados (ex: *MIMIC-IV*) ou dados sintéticos (ex: *Synthea*).
- **Validação Clínica:** A validação do sistema não poderá ser realizada em ambiente clínico real com utentes (ensaios clínicos), limitando-se a simulações e à avaliação por utilizadores como médicos e farmacêuticos.
- **Recursos Computacionais:** O treino e a execução do sistema de recomendação com Grandes Modelos de Linguagem (LLM) exige elevado poder computacional, o que pode constituir uma limitação técnica dependendo do *hardware* disponível ou dos custos de *Application Programming Interface* (API) externas.
- **Tempo de Desenvolvimento:** O projeto deve ser concluído no prazo académico estabelecido, sendo necessária uma gestão do tempo rigorosa de modo a garantir a entrega de um protótipo funcional.

1.2.3 Desafios

Os principais desafios deste problema incluem:

- **Alucinações da IA:** A utilização de LLM em contexto clínico necessita de uma mitigação do risco de alucinações, geração de informações falsas ou imprecisas, sendo fundamental que o sistema apenas forneça recomendações baseadas em evidência científica validada.
- **Privacidade dos Dados:** O treinamento e validação de modelos com dados clínicos reais apresenta restrições éticas e legais de proteção de dados (RGPD). O desafio para este projeto reside na utilização de técnicas de anonimização ou *datasets* sintéticos que mantenham a representatividade clínica sem comprometer a privacidade.
- **Evitar a Fadiga de Alertas:** Desenvolver um sistema que seja capaz de minimizar alertas irrelevantes para evitar a dessensibilização dos profissionais de saúde (*alert fatigue*). O desafio é equilibrar a sensibilidade do sistema (detetar erros) com a especificidade (não incomodar o profissional de saúde com falsos positivos ou avisos triviais).

- **Integração e Usabilidade:** Assegurar que a nova ferramenta seja integrada de forma fluida nos fluxos de trabalho existentes, sem aumentar a carga cognitiva ou o tempo de consulta dos profissionais de saúde.

A resolução deste problema passa pela implementação de uma arquitetura híbrida que combine regras clínicas robustas com a flexibilidade da Inteligência Artificial (IA), assegurando precisão, segurança e aceitação por parte dos utilizadores.

1.3 Objetivos

O presente trabalho tem como objetivo principal o desenvolvimento de um sistema de recomendação e alertas capaz de identificar erros de prescrição, nomeadamente doses incorretas, interações medicamentosas, contraindicações e duplicação de terapias.

Este projeto deverá demonstrar a relevância clínica da solução através de uma avaliação quantitativa e qualitativa, incluindo métricas de desempenho do sistema e feedback de profissionais de saúde (SUS score > 85).

Para a concretização do objetivo geral, foram definidos os seguintes objetivos específicos:

- **Análise do Estado da Arte e Sistematização de Requisitos:**
 - a. Realizar uma revisão sistemática da literatura sobre a prevalência de erros de prescrição e as limitações dos sistemas de apoio à decisão clínica atuais;
 - b. Investigar a aplicação de Inteligência Artificial, especificamente LLM, na área da saúde e segurança na prescrição de medicação;
 - c. Identificar e analisar *datasets* públicos de farmacologia e interações medicamentosas adequados para o treino e validação do sistema.
- **Conceção da Arquitetura do Sistema:**
 - a. Projetar uma arquitetura de sistema híbrida que integre:
 - i. Um módulo baseado em regras para verificações determinísticas críticas de segurança clínica (alergias, interações medicamentosas, contraindicações e duplicações terapêuticas);
 - ii. Um motor de recomendação com modelo de aprendizagem supervisionada para ordenação de alternativas terapêuticas, complementado por um módulo de explicação em linguagem natural por LLM.
- **Desenvolvimento do Protótipo:**

- Implementar *backend* do sistema capaz de sincronizar os dados e treinar eficazmente o modelo de IA;
- Implementar uma interface (*frontend*) intuitiva para o profissional de saúde, com ênfase na apresentação clara de alertas e recomendações;
- Integrar técnicas de mitigação de alucinações, garantindo que as recomendações sejam suportadas por evidências fidedignas.
- Avaliação e Validação do Sistema:
 - Analisar o desempenho técnico do modelo com a utilização de métricas de recuperação de informação, tais como Precisão (*Precision*), Revocação (*Recall*) e *F1-Score*;
 - Executar testes de usabilidade com potenciais utilizadores (profissionais de saúde) de modo a avaliar a aceitação do sistema, com a utilização do *System Usability Scale* (SUS), com uma meta de SUS score > 85;
 - Validar o comportamento do motor de segurança clínica através de cenários clínicos de regressão.
- Perspetivas de Evolução e Generalização:
 - Avaliar a viabilidade da integração do protótipo desenvolvido com os sistemas de Registo de Saúde Eletrónico (RSE) existentes.
 - Avaliar a escalabilidade da solução para incluir novas classes terapêuticas e diretrizes clínicas atualizadas.

Assim sendo, os objetivos definidos respondem diretamente à necessidade de diminuir os erros de prescrição, oferecendo uma solução tecnológica que não só alerta o erro, mas também apoia a decisão do médico através de explicações claras, que visam um cuidado médico mais eficiente e seguro.

1.4 Metodologia

A investigação seguiu uma abordagem orientada ao *Design Science Research* (DSR), paradigma que privilegia a construção e avaliação de artefactos inovadores como resposta a problemas práticos bem definidos. Esta abordagem é reconhecida como adequada para investigação em sistemas de informação e engenharia informática quando o objetivo central é a conceção, implementação e validação de um protótipo funcional, como é o caso do presente projeto.

O processo foi conduzido de forma iterativa e faseada, articulando quatro fases principais que se refletem na estrutura do presente documento:

A primeira fase consistiu na revisão sistemática e narrativa da literatura, com recurso à metodologia PRISMA. Esta revisão visou compreender o estado da arte nos domínios dos erros de prescrição médica, dos Sistemas de Apoio à Decisão Clínica (CDSS), dos sistemas de recomendação em saúde e da integração de LLM em contexto clínico. A análise da literatura orientou a formulação dos requisitos do sistema e a identificação das lacunas existentes nas abordagens atuais, fundamentando as decisões técnicas subsequentes.

A segunda fase correspondeu à análise e design do sistema, englobando a definição dos requisitos funcionais (expressos como histórias de utilizador) e não funcionais, a modelação do domínio através de diagramas UML e a especificação da arquitetura. Nesta fase foram tomadas as decisões arquiteturais fundamentais, nomeadamente a adoção de uma abordagem híbrida em cascata que separa o fluxo *online* de análise clínica em tempo real, do fluxo *offline* de preparação de dados e treino supervisionado, garantindo que processos de aprendizagem automática não interfiram diretamente com as decisões clínicas.

A terceira fase compreendeu a implementação do protótipo, seguindo uma abordagem incremental. O desenvolvimento foi organizado em ciclos que permitiram validar progressivamente cada componente do sistema, motor de segurança clínica, motor de recomendação, modelo supervisionado de *ranking* e módulo de explicação por LLM, antes de os integrar na *pipeline* completa.

Por fim, a quarta fase correspondeu à avaliação e validação do protótipo, através de cenários clínicos de regressão, métricas de desempenho do modelo supervisionado e análise qualitativa das explicações geradas. Esta fase inclui ainda a avaliação da usabilidade com profissionais de saúde, com recurso ao *System Usability Scale* (SUS).

1.5 Abordagem

O sistema proposto organiza-se segundo uma abordagem híbrida e modular, integrando um *frontend* para interação com o profissional de saúde, um *backend* responsável pela orquestração da análise, um motor de segurança clínica baseado em regras determinísticas, um motor de recomendação baseado em conhecimento e contexto clínico, e um modelo supervisionado de *ranking* treinado offline a partir de exemplos revistos.

A arquitetura separa dois fluxos de processamento. O fluxo *online* é executado durante a análise de uma prescrição: recebe o contexto clínico do utente (medicação ativa, alergias, condições de saúde), verifica a prescrição proposta através do motor de segurança clínica, detetando alergias, interações medicamentosas, contraindicações e duplicações terapêuticas, gera alertas classificados por severidade, e produz recomendações de alternativas terapêuticas ordenadas pelo modelo supervisionado. O fluxo *offline*, por sua vez, é responsável pela preparação de dados de treino a partir de cenários sintéticos, pela geração e revisão de rótulos, e pelo treino

periódico do modelo de *ranking*, garantindo que a aprendizagem automática não afeta diretamente as decisões clínicas em tempo real.

O módulo LLM é utilizado numa fase posterior à decisão do sistema, com a função exclusiva de gerar uma explicação textual em linguagem natural dos alertas e recomendações já produzidos pelo motor de segurança clínica e pelo motor de recomendação. Esta separação permite preservar a rastreabilidade das decisões, reduzir o risco de alucinação e assegurar que as recomendações permanecem subordinadas ao motor de segurança clínica. Para mitigar os riscos inerentes à geração de linguagem natural, foram implementados mecanismos de validação linguística, validação estrutural e *fallback* determinístico.

A escolha desta abordagem híbrida justifica-se pela necessidade de conciliar dois requisitos fundamentais: a segurança clínica, garantida pelo carácter determinístico e auditável do motor de regras, e a inteligência adaptativa, proporcionada pelo modelo supervisionado que aprende a ordenar alternativas terapêuticas com base no perfil clínico do utente e nos padrões históricos observados.

1.6 Contributos

Com o desenvolvimento deste sistema, espera-se reduzir significativamente a ocorrência de erros de prescrição, oferecendo aos profissionais de saúde um apoio à decisão robusto e eficaz. O sistema deverá demonstrar alta precisão na deteção de erros e elevada aceitação pelos utilizadores finais, contribuindo para uma prática clínica mais segura e informatizada.

De forma mais específica, os contributos esperados incluem:

- melhoria da segurança do utente através da identificação precoce de riscos de interações medicamentosas, contraindicações e duplicações terapêuticas;
- redução de efeitos adversos associados à medicação, mediante a geração de alertas clínicos contextualizados e priorizados por severidade;
- aumento da eficiência e confiança no processo terapêutico, com recomendações de alternativas terapêuticas ordenadas e justificadas;
- disponibilização de explicações em linguagem natural que apoiem o profissional de saúde na compreensão dos alertas e na tomada de decisão fundamentada;
- contribuição para a investigação na área de sistemas de recomendação em saúde, através da proposta e validação de uma arquitetura híbrida que combina regras determinísticas, aprendizagem supervisionada e LLM;
- integração harmoniosa com fluxos de trabalho clínicos já existentes, minimizando a carga cognitiva e o fenómeno de fadiga de alertas.

A redução de erros de prescrição evitáveis na prática clínica, através do desenvolvimento de uma ferramenta flexível para uso em ambientes clínicos reais, que alerte e apoie o profissional de saúde durante o processo de prescrição, poderá melhorar significativamente a segurança do doente ao prevenir eventos adversos, garantir a adequação terapêutica e reduzir a probabilidade de interações medicamentosas.

1.7 Considerações Éticas

A natureza sensível do domínio da saúde exige que o desenvolvimento de sistemas de informação não se limite à componente técnica, o que requer uma reflexão profunda sobre as implicações morais da automatização em contexto clínico.

1.7.1 Interpretação Analítica

Do ponto de vista analítico, o problema dos erros de prescrição não deve ser apenas interpretado como uma falha humana, mas sim como uma consequência sistémica da crescente complexidade farmacológica e da sobrecarga laboral e cognitiva a que os profissionais de saúde estão sujeitos. O estado da arte demonstra no Capítulo 2 que os sistemas de suporte à decisão clínica (CDSS) tradicionais, baseados apenas em regras estáticas ("se-então"), apresentam limitações em relação à sua eficácia. Deste forma, a análise do problema estabelece duas lacunas principais que este projeto visa melhorar:

- **A lacuna da contextualização:** Os sistemas atuais, mais à frente discutidos no Estado da Arte, analisam interações de forma isolada, não sendo eficazes em relação à incerteza e à variabilidade do contexto clínico individual.
- **A lacuna da interoperabilidade semântica:** A informação médica encontra-se dispersa e muitas vezes não estruturada, dificultando a sua análise automática. Portanto, a solução proposta não deve ser apenas uma digitalização de características farmacológicas, mas sim um sistema capaz de analisar a condição do utente, o histórico terapêutico e as diretrizes clínicas vigentes.

1.7.2 Interpretação Crítica

Numa perspetiva crítica, é relevante reconhecer as limitações e os riscos inerentes à implementação de IA, especificamente LLM, na área da prescrição médica. A crítica ao Estado da Arte atual foca-se no fenómeno de fadiga de alertas (*Alert Fatigue*). Estudos indicam que os médicos ignoram uma grande parte dos alertas de segurança devido à sua irrelevância ou excessiva frequência. Desat forma, um novo sistema que apenas aumente o volume de notificações, sem melhorar a sua precisão (especificidade), será contraproducente e rejeitado pelos utilizadores.

Simultaneamente, a adoção de IA generativa levanta a questão crítica das alucinações (geração de factos incorretos). Assim, este projeto adota uma postura crítica de que a IA não deve substituir o juízo clínico, mas sim aumentá-lo, funcionando como um apoio e "segunda opinião" validada [5]. Esta postura está refletida na arquitetura do sistema, onde o LLM é utilizado exclusivamente para geração de explicações e nunca como ator de decisão clínica.

1.7.3 Interpretação Ética

O projeto segue os princípios de integridade, rigor, transparência e responsabilidade definidos pelo *European Code of Conduct for Research Integrity* e pelas orientações éticas apresentadas no contexto de investigação da unidade curricular de Preparação para Dissertação (PREPD). Na sua fase atual, o trabalho não pretende envolver dados clínicos identificáveis, nem a participação direta de utentes, sendo desenvolvido exclusivamente com bases de conhecimento farmacológicas, dados públicos anonimizados e *datasets* sintéticos. Desta maneira, está em conformidade com o princípio de proteção e gestão de dados (*data protection and stewardship*), o que garante que qualquer informação utilizada é tratada de forma responsável e de acordo com o Regulamento Geral sobre a Proteção de Dados (RGPD), reduzindo riscos de reidentificação e assegurando práticas de gestão de dados transparentes e auditáveis.

Foram igualmente consideradas as recomendações internacionais relativas à utilização ética de sistemas de IA, incluindo a necessidade de divulgar o uso de ferramentas automáticas, assegurar transparência algorítmica, promover reprodutibilidade e avaliar potenciais enviesamentos que possam produzir recomendações discriminatórias ou clinicamente inadequadas. A análise ética do projeto enquadra-se na categoria de investigação de baixo risco, não envolvendo intervenções clínicas nem manipulação de dados sensíveis, mas ainda assim respeitando os princípios de honestidade, fiabilidade e responsabilidade exigidos em investigação em saúde digital [6],[7].

Qualquer interação prevista com profissionais de saúde será realizada mediante consentimento informado, garantindo confidencialidade, participação voluntária e minimização de riscos, conforme recomendado para estudos exploratórios com utilizadores. O projeto adota ainda práticas de documentação rigorosa, registo explícito de contributos, mecanismos de controlo para evitar má conduta científica (como falsificação, omissão de métodos ou uso oculto de IA) e medidas preventivas contra erros de interpretação ou utilização indevida de resultados.

Desta forma, garante-se que o sistema proposto é desenvolvido de forma responsável, equitativa e alinhada com os padrões internacionais para investigação segura e íntegra em tecnologias digitais aplicadas à saúde.

Complementarmente à ética na investigação, o projeto rege-se pelos princípios de Ética em Engenharia, alinhando-se com o *ACM Code of Ethics and Professional Conduct* [8] e o *ACM/IEEE-CS Software Engineering Code* [9]. Dado que o sistema de recomendação opera num domínio crítico (saúde), assume-se o compromisso com o princípio da segurança e bem-estar público

como prioridade máxima. Isto implica não só a garantia da privacidade, mas também a responsabilidade técnica de assegurar a robustez do *software*, a mitigação de *bugs* que possam levar a erros e a validação rigorosa das sugestões geradas pelo sistema, evitando a entrega de funcionalidades que não tenham sido devidamente testadas ou que apresentem riscos injustificados para os utilizadores finais.

1.8 Estrutura do Documento

O presente documento encontra-se organizado em sete capítulos. Segue-se uma descrição do conteúdo de cada um.

O **Capítulo 1 - Introdução**, apresenta o enquadramento do projeto no contexto dos erros de prescrição médica e dos sistemas de apoio à decisão clínica. São descritos o problema de investigação, os objetivos, a metodologia adotada, a abordagem técnica proposta e os contributos esperados, concluindo com considerações éticas relevantes para um projeto na área da saúde digital.

O **Capítulo 2 - Estado da Arte**, apresenta a revisão sistemática e narrativa da literatura, conduzida segundo a metodologia PRISMA. São analisados os principais conceitos relacionados com os erros de prescrição médica, os Sistemas de Apoio à Decisão Clínica (CDSS), os sistemas de recomendação em saúde, a integração de Inteligência Artificial e de Grandes Modelos de Linguagem (LLM) na saúde, as normas de interoperabilidade e as métricas de avaliação relevantes. O capítulo conclui com uma síntese crítica das lacunas identificadas na literatura que o presente projeto visa endereçar.

O **Capítulo 3 - Análise e Design do Sistema**, descreve a visão geral do sistema e os seus requisitos funcionais, expressos sob a forma de histórias de utilizador, e os requisitos não funcionais. São apresentados o modelo de domínio, representado através de um diagrama UML de classes, e os cenários de utilização do sistema, ilustrados com diagramas de sequência que cobrem os fluxos principais de análise de prescrições.

O **Capítulo 4 - Arquitetura do Sistema**, detalha a arquitetura do sistema proposto, descrevendo os componentes principais e as suas interações através de diagramas de componentes. São explicados os fluxos de dados *online* (análise de prescrições em tempo real) e *offline* (treino supervisionado), bem como as principais decisões arquiteturais e as suas justificações técnicas.

O **Capítulo 5 – Implementação**, descreve o desenvolvimento do protótipo, incluindo as tecnologias e ferramentas utilizadas, a organização do *backend*, a implementação de cada módulo do sistema: motor de segurança clínica, motor de recomendação, modelo supervisionado de ranking, módulo de explicação por LLM e *frontend*, os mecanismos de teste e controlo de versões adotados.

O **Capítulo 6 - Avaliação e Validação**, apresenta os resultados da avaliação experimental do protótipo. São descritos os objetivos da avaliação, a metodologia experimental, os cenários clínicos de regressão utilizados e as métricas de desempenho. São ainda apresentados e discutidos os resultados obtidos para cada componente do sistema, incluindo a avaliação de usabilidade com profissionais de saúde.

O **Capítulo 7 - Conclusões e Trabalho Futuro**, sintetiza os principais contributos do trabalho desenvolvido, discute as limitações identificadas e apresenta perspectivas de evolução futura do sistema, nomeadamente no que respeita à integração com sistemas de informação clínica reais, à expansão da base de conhecimento farmacológico e à validação clínica em ambiente hospitalar.

2 Estado da Arte

Introdução

Este capítulo apresenta a fundamentação teórica que suporta o desenvolvimento do projeto proposto, contextualizando o problema dos erros de prescrição e analisando as tecnologias existentes para a sua mitigação. A revisão abrange a definição e taxonomia dos erros de medicação, as características farmacológicas relevantes para a segurança do doente e a evolução dos sistemas de recomendação na área da saúde. Enfatiza-se que existe uma integração recente de LLM e técnicas híbridas, sendo também identificadas as lacunas que este projeto visa melhorar.

Adicionalmente, descreve-se a metodologia utilizada para a condução desta revisão, garantindo a reprodutibilidade e o rigor científico da análise.

2.1 Metodologia de Revisão da Literatura

A investigação realizada para este projeto baseou-se na análise sistemática e narrativa da literatura científica, com o objetivo de compreender o estado atual dos sistemas de recomendação aplicados à prescrição médica e à prevenção de erros medicamentosos.

2.1.1 Questões de Pesquisa

A formulação da questão principal de pesquisa orienta todo o processo de revisão da literatura e desenvolvimento da solução. Deste modo, esta questão de investigação define-se:

Como pode um sistema de apoio à decisão clínica com recomendação e alertas, baseado em inteligência artificial, ajudar na identificação e prevenção de erros de prescrição de medicamentos em contexto clínico?

Para implementar a questão principal de pesquisa no contexto prático e orientar a análise das diferentes dimensões do problema, foram definidas três questões específicas de investigação que pretendem guiar a revisão da literatura:

Q1: Que tipos de erros de prescrição podem ser identificados de forma eficaz através de sistemas de recomendação e alertas baseados em IA? (ex: interações medicamentosas, doses inadequadas, contraindicações clínicas)

Q2: Que técnicas de inteligência artificial e de recomendação apresentam melhor desempenho e adequação para apoiar decisões de prescrição, minimizando falsos alertas e fadiga do utilizador?

Q3: De que forma a integração do sistema nos fluxos de trabalho clínicos influencia a utilidade percebida e a aceitação por parte dos profissionais de saúde?

2.1.2 Fontes e conjuntos de dados

A recolha bibliográfica foi realizada através de diferentes bases de dados científicas e repositórios académicos relevantes para as áreas da informática médica, inteligência artificial aplicada à saúde e sistemas de apoio à decisão clínica.

Foram utilizadas principalmente as seguintes fontes:

- EBSCO;
- ScienceDirect;
- PubMed;
- ResearchGate;
- MDPI;
- Repositório P.Porto;
- SpringerLink;
- Google Scholar.

Relativamente aos conjuntos de dados utilizados na componente experimental do protótipo, foi adotado o *dataset* sintético *Synthea*. O *Synthea* é uma plataforma de geração de dados clínicos sintéticos amplamente utilizada em investigação e desenvolvimento de sistemas clínicos, permitindo criar perfis de utentes com condições clínicas, medicação ativa, alergias e histórico médico coerente.

A utilização de dados sintéticos permitiu:

- evitar problemas relacionados com privacidade e proteção de dados clínicos reais;
- gerar cenários clínicos diversificados;
- criar exemplos supervisionados para treino do modelo de recomendação;
- e validar o comportamento do sistema em diferentes contextos clínicos.

Os dados gerados pelo Synthea foram posteriormente processados e normalizados para integração no motor de recomendação e no pipeline experimental do sistema.

2.1.3 Termos de pesquisa e estratégia PRISMA

A estratégia de pesquisa seguiu uma combinação da metodologia PRISMA (Anexo D), *snowballing* e narrativa (Consensus: AI e Google Scholar) nas bases de dados. As seguintes palavras-chave em inglês foram introduzidas na EBSCO: ("prescription error*" OR "medication error*") AND ("alert system" OR "clinical decision support" OR "recommendation system") AND ("machine learning" OR "artificial intelligence" OR "deep learning" OR "neural network*" OR "predictive model*"). Os critérios de inclusão privilegiaram artigos *peer-reviewed*, escritos em inglês e português e nos últimos 5 anos.

2.1.4 Critérios de elegibilidade e seleção

- **Sem critérios de inclusão:** 3,950 publicações
- **Após critérios de inclusão:**
 1. Últimos 10 anos: 2,908 publicações
 2. Peer Review: 1,154 publicações
 3. Inglês ou Português: 1,114 publicações
 4. Últimos 5 anos: 861 publicações

Excluíram-se artigos sem validação experimental e publicações sem relevância direta para as questões de investigação anteriormente referidas.

2.1.5 Procedimento de recolha e síntese de dados

2.2 Erros de Prescrição e Segurança do Doente

A prescrição de medicamentos exige a consideração simultânea de múltiplas características farmacológicas e clínicas. Entre os elementos mais relevantes encontram-se o princípio ativo, a classe terapêutica, as indicações terapêuticas, a posologia, as contraindicações, as interações medicamentosas, os efeitos indesejáveis e as advertências aplicáveis a populações específicas

[10]. Estes elementos não devem ser analisados isoladamente, uma vez que a adequação de um medicamento depende da relação entre o fármaco, o problema clínico principal, a medicação ativa, as alergias, a idade e as condições clínicas do utente.

A literatura define o erro de medicação (EM) como “sendo qualquer evento evitável que possa causar ou levar ao uso inadequado do medicamento ou a danos no doente enquanto o medicamento estiver sob o controlo do profissional de saúde ou do doente” [12]. As causas do EM podem ser durante a prescrição, verificação, dispensa, administração, semelhança da embalagem, nomes semelhantes, rotulagem incorreta, dose incorreta, preparação incorreta, falta de informação, erros do sistema, não adesão do doente, duplicação terapêutica, entre outros [12].

2.2.1 Erros de Prescrição

Um dos tipos de EM mais comum é o erro de prescrição, definido como o “EM iniciado durante o processo de prescrição, que inclui a seleção incorreta do medicamento (contra-indicações e interações), dose errada (dosagem terapêutica excessiva ou insuficiente), concentração errada, frequência errada, via de administração incorreta, instruções inadequadas para a utilização do medicamento e forma farmacêutica errada” [13].

2.2.2 Tipos de Erros de Prescrição

Deste modo, os erros de prescrição podem ser classificados nas seguintes categorias [14]:

a) Erros de Seleção do Medicamento

Ocorrem quando o medicamento escolhido não é adequado ao diagnóstico, ao estado clínico do doente ou às suas características fisiológicas.

b) Erros de Dosagem

Incluem a prescrição de doses demasiado baixas (ineficazes) ou demasiado elevadas (potencialmente tóxicas), bem como erros na frequência ou duração do tratamento.

c) Erros de Contra-indicação

Relacionam-se com a prescrição de medicamentos inadequados devido ao historial clínico, intolerâncias, alergias ou condições fisiológicas específicas.

d) Erros por Interações Medicamentosas

Podem ocorrer entre dois ou mais medicamentos, entre medicamentos e alimentos ou entre medicamentos e condições clínicas. Estas interações podem alterar a eficácia do tratamento ou causar efeitos adversos significativos.

e) Erros de Duplicação Terapêutica

Quando dois medicamentos com o mesmo mecanismo de ação ou finalidade terapêutica são prescritos em simultâneo sem indicação clínica justificada.

f) Erros de Via de Administração

Envolvem a seleção incorreta da forma farmacêutica ou da via de administração, impactando a eficácia ou segurança do medicamento.

2.3 Sistemas de Apoio à Decisão Clínica

Os Sistemas de Apoio à Decisão Clínica (CDSS) são definidos como *software* que utiliza as características individuais de um utente para apresentar avaliações ou recomendações específicas ao profissional de saúde, com o intuito de apoiar a tomada de decisão [15]. Com o aumento exponencial da disponibilidade de dados de saúde (*Big Data*) provenientes de registos eletrónicos, o foco destes sistemas transitou da simples digitalização de protocolos para uma análise complexa de dados. Peiffer-Smadja *et al.* [15] destacam que, no contexto das doenças infecciosas e prescrição de antimicrobianos, estas ferramentas têm sido aplicadas predominantemente no diagnóstico (33%), na previsão de sépsis (30%) e na previsão de resposta ao tratamento (22%).

A aplicação de CDSS estende-se a outras áreas da saúde nomeadamente a gestão da diabetes e a otimização da terapêutica geral. Uma revisão de 2023 realizada por Huang *et al.* [16] revelou um crescimento acentuado no interesse por CDSS na gestão da diabetes, onde estas ferramentas são utilizadas não apenas por endocrinologistas, mas crescentemente por médicos de cuidados primários e farmacêuticos para recomendações de tratamento e ajuste de doses de insulina.

2.3.1 Evolução e Tipologia

Historicamente, os CDSS começaram com o desenvolvimento de sistemas baseados em regras, evoluindo posteriormente para abordagens baseadas em dados. A literatura classifica esta evolução em duas categorias principais:

2.3.1.1 CDSS Baseados em Conhecimento (*Knowledge-Based*)

Estes sistemas baseiam-se em regras codificadas manualmente ("Se-Então"), capturadas a partir de diretrizes clínicas ou entrevistas com especialistas. O MYCIN foi o primeiro sistema especialista de IA, desenvolvido em 1976, e tinha como objetivo sugerir regimes antibióticos para infeções bacterianas graves. Atualmente, esta tipologia continua a ser predominante na prática clínica devido à sua transparência [15].

Uma *scoping review* de Armando *et al.* [17], publicada em 2023, analisou 42 estudos de CDSS para prescrição de medicamentos e constatou que a vasta maioria (83,3%) ainda se baseia em regras (*knowledge-based*), utilizando critérios validados como os critérios de *Beers* ou *Screening*

Tool of Older Persons' Prescriptions (STOPP) para detetar prescrições potencialmente não adequadas a idosos. Apesar de serem explicáveis e rigorosos, estes sistemas apresentam limitações de escalabilidade e rigidez na manutenção de bases de conhecimento complexas [15].

2.3.1.2 CDSS Não-Baseados em Conhecimento (*Data-Driven*):

Para superar as restrições dos sistemas baseados em regras, surgiram abordagens baseadas em *Machine Learning* (ML). Numa revisão de 60 sistemas para doenças infecciosas, verificou-se que 97% utilizam aprendizagem supervisionada [15]. Huang *et al.* [16] validam esta afirmação, notando um aumento recente de sistemas "não-baseados em conhecimento" na diabetes, com a utilização de algoritmos de IA para transformar dados de larga escala em informações acionáveis.

No entanto, Pinsky *et al.* [18], numa análise crítica publicada em 2024 sobre o uso de IA em cuidados intensivos, alertam que a implementação destas ferramentas na medicina tem sido lenta e desigual. O principal obstáculo reside na natureza inerente da "caixa preta" de muitos algoritmos preditivos, o que dificulta a confiabilidade e a aceitação pela comunidade médica. Logisticamente, a compilação em tempo real de fluxos de dados multidimensionais de várias fontes necessárias para informar os algoritmos e, em última análise, exibir decisões clínicas relevantes, são frequentemente ignoradas durante os esforços iniciais de validação. Da mesma forma, as barreiras legais e comerciais ao acesso a muitas bases de dados clínicas existentes limitam os estudos para abordar a equidade e a generalização de modelos preditivos e ferramentas de gestão.

2.3.2 Barreiras à Adoção e Desafios Éticos

Apesar do potencial demonstrado, a implementação de CDSS baseados em IA enfrenta barreiras significativas que impedem a sua tradução para a prática clínica. Pinsky *et al.* [18] identificam um "fosso de implementação" (*implementation gap*), onde modelos com excelente desempenho *in silico* falham quando implantados à beira do leito (*point of care*). Entre os principais obstáculos destacam-se:

1. **Viés Algorítmico e Equidade:** Muitos algoritmos são treinados em bases de dados (como o MIMIC) que podem não refletir a diversidade demográfica da população alvo [18].
2. **Consciência Situacional:** A maioria dos sistemas atuais carece de "consciência situacional", não conseguindo integrar fluxos de dados multidimensionais em tempo real de forma útil para o fluxo de trabalho clínico [18].
3. **Fadiga de Alertas:** A excessiva frequência de alertas irrelevantes continua a ser um problema central, levando os profissionais a ignorar avisos de segurança críticos [17].

2.3.3 Eficácia e Impacto Clínico

A evidência sobre a eficácia dos CDSS é promissora, mas heterogênea. Na gestão da diabetes, Huang *et al.* [16] reportaram que o uso de CDSS resultou em melhorias significativas nos perfis glicêmicos dos utentes em aprox. 58,7% dos estudos analisados, sem aumentar o risco de hipoglicemia. No contexto geral da prescrição de medicamentos, Armando *et al.* [17] observaram que 59,5% dos estudos analisados demonstraram sucesso no suporte à prática clínica. Um fator determinante para o sucesso destas intervenções parece ser a multidisciplinaridade: estudos que envolveram a participação ativa de farmacêuticos e focaram em utentes complexos (com maior multimorbilidade) obtiveram resultados mais positivos na redução de erros de medicação e eventos adversos [17].

2.4 Sistemas de Recomendação

Os Sistemas de Recomendação são ferramentas que surgiram da necessidade de filtrar um volume crescente de informação na *Web* e recomendar conteúdo relevante ao utilizador. Formalmente, a recomendação pode ser definida como a estimativa de uma função de utilidade $R(u, i)$ que prevê o quanto um utilizador “u” gostaria de um item “i”. Por exemplo, a Amazon utiliza estes sistemas para personalizar a loja virtual de cada cliente, filtrando milhões de produtos de modo a sugerir apenas aqueles com maior probabilidade de compra [19]. Estes sistemas apoiam a tomada de decisão e apresentam diferentes arquiteturas, variando conforme a técnica de filtragem adotada.

Assim sendo, a recomendação pode basear-se em três técnicas de filtragem principais: colaborativa, baseada em conteúdo, etc. e combinações híbridas que procuram beneficiar das vantagens de cada abordagem [20].

2.4.1 Filtragem Colaborativa (*Collaborative Filtering*)

Baseia-se em padrões de preferências partilhados entre utilizadores. Um exemplo desta abordagem é a funcionalidade de sugestão de vídeos no YouTube, onde o sistema utiliza dados de co-visualização (padrões de “quem viu X também viu Y”) para gerar sugestões, com base no comportamento histórico da comunidade [21]. Pode seguir métodos baseados em memória ou em modelos. Oferece recomendações personalizadas e permite ao utilizador descobrir novos interesses, mas depende de muitos dados. Desta forma, sofre com *sparsity*, em que um conjunto de dados contém muitos zeros ou valores nulos (ineficiência) e apresenta também dificuldades no *coldstart*, quando no arranque de um sistema este está “frio”, sem dados relevantes de preparação sobre o utilizador [20].

2.4.2 Filtragem Baseada em Conteúdo (*Content-Based*)

Recomenda itens semelhantes às preferências prévias do utilizador, através da análise das características dos itens e da construção de um perfil do utilizador. Um exemplo prático é o Spotify, que para além das playlists colaborativas, analisa sinais de áudio e metadados de artistas para recomendar músicas novas que correspondem ao perfil sonoro do utilizador, permitindo a descoberta de faixas de áudio com poucas reproduções [22]. Desta forma, adapta-se bem para muitos utilizadores e reduz, o *cold-start*, mas exige conhecimento do domínio, limita a diversidade das recomendações e não escala adequadamente para bases alargadas de itens [20].

2.4.3 Filtragem Baseada em Conhecimento (*Knowledge-Based*)

Diferente das abordagens anteriores, a Filtragem Baseada em Conhecimento não depende de históricos de interações, mas sim de uma base de conhecimento explícita sobre o domínio e regras de inferência lógica. Esta técnica é especialmente adequada para domínios complexos ou para itens que são adquiridos com pouca frequência (como casas, carros ou produtos financeiros), onde o sistema deve responder a requisitos específicos do utilizador, frequentemente através de um processo conversacional ou de diálogo explícito onde as preferências são captadas, e não apenas a tendências populares [23].

Subdivide-se em duas categorias principais:

- **Baseada em Restrições (*Constraint-based*):** Utiliza regras para filtrar itens que não cumprem os requisitos explícitos do utilizador. Um exemplo prático são as plataformas de imobiliário, onde o utilizador define regras como "Preço < 200.000€" e "Tipologia > T2", e o sistema exclui todas as opções que violem estas restrições [23].
- **Raciocínio Baseado em Casos (*Case-Based Reasoning*):** Resolve novos problemas recuperando soluções de casos passados semelhantes. É frequentemente utilizado em serviços de suporte técnico (*helpdesks*) automatizados, onde o sistema recomenda uma solução para uma avaria baseando-se na resolução de problemas técnicos anteriores com características semelhantes [23].

2.4.4 Filtragem Demográfica

Esta filtragem fundamenta-se na premissa de que utilizadores com atributos demográficos semelhantes tendem a partilhar preferências comuns. Esta técnica utiliza dados explícitos do perfil do utilizador, nomeadamente idade, género, código postal ou profissão, para criar grupos ou *clusters* de utilizadores estereotipados [24].

Uma aplicação comum reside na publicidade direcionada (*targeted advertising*) e em sistemas de recomendação de *e-commerce*, onde o conteúdo é sugerido com base no segmento populacional do utilizador, permitindo gerar recomendações mesmo na ausência de histórico

comportamental prévio. Esta característica torna a filtragem demográfica significativamente relevante para mitigar o problema do *cold start* em novos utilizadores. Contudo, o estudo de Nabil *et al.* [24] demonstra que esta técnica, quando utilizada isoladamente ou com poucos atributos demográficos, pode carecer de precisão. Os resultados experimentais revelam que a utilização de um único atributo demográfico 'género' resulta num erro quadrático médio de 0.749. Em contrapartida, ao enriquecer o perfil do utilizador com os atributos 'género' e 'idade', o sistema reduz significativamente o erro para 0.587, comprovando que uma maior subdivisão demográfica é essencial para a eficácia da recomendação [24]. Consequentemente, a tendência atual consiste na sua integração em sistemas híbridos (ex: combinação com filtragem colaborativa), onde a segmentação demográfica prévia reduz a complexidade computacional e melhora significativamente a diversidade e a precisão das recomendações finais [24].

2.4.5 Sistemas Sensíveis ao Contexto (*Context-Aware*)

Os Sistemas de Recomendação Sensíveis ao Contexto representam uma evolução significativa face às técnicas tradicionais, transicionando de um modelo bidimensional (Utilizador * Item) para uma modelação multidimensional (Utilizador * Item * Contexto). Deste modo, a previsão da preferência não depende apenas de quem é o utilizador, mas também das circunstâncias específicas em que a recomendação é solicitada, tais como o tempo, a localização ou o estado emocional [25]. Exemplos incluem:

- **Restauração e Turismo (ex: Google Maps, TripAdvisor):** Estas plataformas aplicam técnicas de pré-filtragem contextual para adaptar as sugestões. Estudos recentes, como o de Abusair *et al.* [26], demonstram que as preferências gastronómicas são altamente variáveis conforme o contexto temporal e ambiental. O sistema pode, por exemplo, recomendar "cafés" ou refeições leves se o contexto for "manhã/temperatura moderada", e "restaurantes" ou refeições quentes se for "noite/frio", ignorando restaurantes com altas classificações se não se adequarem ao momento específico [26].
- **Streaming de Multimédia (ex: Spotify):** Para além do histórico de áudio, a plataforma apresenta contextos dinâmicos para adaptar as recomendações à atividade do utilizador. Isto permite sugerir *playlists* distintas para "Fazer Exercício" ou "Dormir", reconhecendo que a utilidade de um item musical varia consoante a atividade momentânea do utilizador [25].

2.4.6 Filtragem Comunitária (*Community-Based*)

Também conhecida como Filtragem Social, esta abordagem baseia-se nas relações sociais, sejam elas explícitas, como listas de amigos, ou implícitas, inferidas por interesses comuns. Ao contrário da filtragem colaborativa tradicional, que procura utilizadores desconhecidos com gostos semelhantes, esta técnica prioriza as preferências dos amigos ou conexões da rede de confiança do utilizador [27].

Esta metodologia é particularmente eficaz para mitigar problemas de *cold start* e escassez de dados, pois utiliza a estrutura social para gerar recomendações mesmo quando o histórico individual do utilizador é limitado. O exemplo mais evidente encontra-se nas redes sociais como o Facebook (funcionalidade "Pessoas que talvez conheça") ou LinkedIn, que recomendam conexões ou conteúdos baseando-se nas interações do utilizador e nas interações da sua rede de contactos diretos.

2.4.7 Filtragem Híbrida

A filtragem híbrida combina as duas ou mais técnicas de recomendação mencionadas anteriormente, com o objetivo de superar as limitações associadas ao uso isolado de cada técnica [20]. A Netflix exemplifica esta abordagem ao combinar a filtragem colaborativa (comparando o histórico de visualização entre utilizadores) com a filtragem baseada em conteúdo (com análise de metadados dos filmes como preferências de atores, género e realizador), o que permite recomendações mais robustas e precisas mesmo quando há poucos dados de interação inicial [28].

Deste modo, a sistematização das diferentes técnicas de filtragem permitiu estabelecer uma distinção conceptual fundamental para este projeto: a diferença entre os tradicionais Sistemas de Alerta (CDSS) e os modernos Sistemas de Recomendação. Embora ambos visam o suporte à decisão, operam sob paradigmas computacionais distintos:

- **Sistemas de Alerta:** Baseados em regras/conhecimento, são determinísticos e reativos. Estes sistemas operam sobre uma lógica booleana rígida, onde o conhecimento é codificado explicitamente em regras "Se-Então". Assim sendo, o sistema limita-se a verificar a presença de condições pré-definidas sem geralmente avaliar o contexto envolvente.
 - Vantagem: São excelentes para segurança crítica imediata (ex: alergias conhecidas), onde não pode existir tolerância ao erro.
 - Limitação: Geram um elevado ruído ("fadiga de alertas") e possuem baixa especificidade contextual, pois não conseguem distinguir uma interação teórica de um risco clínico real.
 - Exemplo: "Se Medicamento A (Varfarina) + Medicamento B (Aspirina) forem prescritos, disparar Alerta de Interação Medicamentosa".
- **Sistemas de Recomendação:** Baseados em dados/IA, são probabilísticos, proativos e personalizados. Ao contrário dos sistemas de alerta, estes modelos não se limitam a validar regras, eles utilizam algoritmos de aprendizagem (como filtragem colaborativa ou modelos de linguagem) para inferir padrões complexos a partir do histórico clínico e do perfil do doente. Deste modo, o objetivo não é apenas avisar um erro, mas sugerir a ação terapêutica mais adequada ao contexto do doente.

- Vantagem: Permitem uma elevada personalização, reduzindo falsos positivos ao "entender" que um determinado risco é aceitável naquele contexto.
- Exemplo: "Para este doente com insuficiência renal (estádio 3) e histórico de úlcera gástrica, o sistema sugere atenção ao Medicamento X (AINE) por ser contraindicado, recomendando como alternativa o Medicamento Y (Paracetamol) com base em perfis de segurança semelhantes."

De seguida, será apresentada uma tabela sumária de comparação das diferentes técnicas de filtragem usadas em sistemas de recomendação.

2.4.8 Comparação entre Técnicas de Filtragem

A Tabela 4 sintetiza as principais características, vantagens e limitações das técnicas de filtragem abordadas, bem como exemplos da sua aplicação prática.

Tabela 1 - Comparação entre Técnicas de Filtragem em Sistemas de Recomendação.

Técnica de Filtragem	Base de Funcionamento	Principais Vantagens	Principais Limitações	Exemplo de Aplicação
Colaborativa	Padrões de preferências e histórico partilhado entre a comunidade de utilizadores.	• Recomendações personalizadas.	• Problema do arranque a frio (<i>cold-start</i>).	YouTube (Sugestão de vídeos por co-visualização).
		• Permite a descoberta de novos interesses (<i>serendipity</i>).	• Dispersão de dados (<i>sparsity</i>).	
Baseada em Conteúdo	Análise das características intrínsecas dos itens e correspondência com o perfil do utilizador.	• Reduz o impacto do <i>cold-start</i> (para novos itens).	• Exige conhecimento profundo do domínio.	Spotify (Recomendação musical por análise de áudio/metadados).
		• Adapta-se bem a grandes volumes de utilizadores.	• Limita a diversidade das recomendações.	
Baseada em Conhecimento	Regras de inferência lógica e requisitos explícitos fornecidos pelo utilizador (restrições ou casos).	• Ideal para domínios complexos ou compras pouco frequentes.	• Depende de um processo de diálogo explícito ou definição de regras pelo utilizador.	Imobiliário (Filtragem por preço/tipologia); Helpdesks .
		• Independente do histórico de interações.		
Demográfica	Atributos do utilizador (idade, género, localização, profissão) para criar grupos estereotipados.	• Mitigação eficaz do <i>cold-start</i> para novos utilizadores.	• Baixa precisão quando usada isoladamente.	Publicidade Direcionada (<i>Targeted advertising</i>).
		• Simplicidade de implementação.	• Generalização excessiva (falha na captação de gostos individuais).	
Sensível ao Contexto	Modelação multidimensional (<i>Utilizador</i> × <i>Item</i> × <i>Contexto</i>), considerando tempo, local ou emoção.	• Elevada adaptação à atividade ou necessidade momentânea do utilizador.	• Complexidade na inferência e captura de variáveis contextuais dinâmicas.	TripAdvisor (Restaurantes por hora/tempo); Spotify (<i>Playlists</i> por atividade).
		• Recomendação dinâmica.		
Comunitária (Social)	Relações sociais (explícitas ou implícitas) e redes de confiança entre utilizadores.	• Mitiga problemas de escassez de dados e <i>cold-start</i> .	• Dependência da existência de uma rede de contactos ou grafo social.	Facebook ("Pessoas que talvez conheça"); LinkedIn .
		• Aproveita a estrutura social existente.		
Híbrida	Combinação de duas ou mais abordagens (ex: Colaborativa + Conteúdo).	• Supera as limitações isoladas de cada técnica.	• Maior complexidade arquitetural e de implementação.	Netflix (Histórico de visualização + Metadados dos filmes).
		• Maior robustez e precisão.		

2.5 Sistemas de Recomendação em Saúde

Os Sistemas de Recomendação aplicados à saúde têm apresentado elevada relevância na última década, e podem ser classificados em quatro categorias principais: estilo de vida, nutrição, informação geral sobre saúde e condições específicas de saúde [29],[30]. Deste modo, o sistema que este projeto pretende realizar encontra-se na categoria: condições específicas de saúde.

2.5.1 Trabalhos relacionados

A área dos Sistemas de Recomendação em Saúde tem sido objeto de intensa investigação, dada a necessidade de reduzir erros de prescrição médicos. Para compreender o estado atual da arte e identificar as lacunas que este projeto visa preencher, foram selecionados e analisados ao pormenor cinco trabalhos de referência publicados nos últimos cinco anos. Estes estudos abordam desde a eficácia clínica dos sistemas até aos desafios de implementação da Inteligência Artificial:

1. Evolução dos Sistemas de Alertas em CDSS:

Em 2022, Chien et al. realizaram uma revisão sobre a evolução dos alertas em sistemas de prescrição eletrónica (*computerized physician order entry system* - CPOE) e CDSS ao longo de uma década (2011-2021), analisando 728 publicações indexadas na *Web of Science* [31].

Análise da Bibliografia: Os autores identificaram uma mudança significativa no paradigma de investigação. Enquanto nos primeiros anos a literatura focava-se quase exclusivamente no *design* do sistema e a "segurança do doente" (redução de efeitos adversos), nos últimos três anos do período analisado emergiram termos como "usabilidade", "taxas de rejeição" (*overrides*) e "eficiência do alerta". Esta transição reflete o reconhecimento de que a simples implementação de alertas não garante segurança se a interação da ferramenta com o profissional de saúde não for adequada [31].

Principais Conclusões: A análise dos 24 artigos mais impactantes revelou lacunas estruturais nos sistemas atuais [31]:

1. **Predomínio de Regras Estáticas:** A maioria dos sistemas atuais baseia-se em *designs* baseados em regras rígidas. Isto significa que os alertas são ativados de forma simples, incapazes de interpretar situações diferenciadas, o que limita o seu valor clínico real.
2. **Tipologia de Alertas:** O estudo destaca que os médicos lidam não só com alertas clínicos (interações, alergias), mas também com uma carga elevada de alertas de baixo valor, contribuindo significativamente para a sua fadiga.
3. **Natureza Interruptiva:** A prevalência de alertas do tipo *hard-stop* (que interrompem o fluxo de trabalho) é eficaz para prevenir erros graves, mas, quando usada excessivamente em contextos de baixo risco, gera frustração e dessensibilização.

Os autores recomendam explicitamente que a próxima geração de CDSS deve abandonar a abordagem puramente baseada em regras rígidas. Deste modo, o estudo defende a implementação de soluções sensíveis ao contexto (*context-aware*) que utilizem *Machine Learning* para otimizar os alertas [31].

2. Aplicação dos CDSS no Cuidado à Diabetes:

Uma revisão feita por Huang *et al.* em 2023, analisou 85 estudos sobre a aplicação de CDSS na diabetes, com um foco no panorama da investigação, aplicações clínicas e impacto nos utilizadores [16].

Análise da Bibliografia: A revisão identificou que os CDSS são utilizados por médicos de cuidados primários (51%), endocrinologistas (38%) e até doentes, cobrindo cenários como recomendação de tratamento, ajuste de insulina e rastreio de complicações [16].

Principais Conclusões: A análise dos estudos permitiu concluir sobre a eficácia e as tendências tecnológicas atuais [16]:

- **Eficácia Clínica:** O uso de CDSS demonstrou ser eficaz e seguro. Em 71% dos estudos analisados, observaram-se melhorias significativas nos níveis de glicemia dos doentes, bem como na pressão arterial (67%) e perfis lipídicos (38%), sem aumento do risco de hipoglicemia.
- **Transição Tecnológica:** Embora a maioria dos sistemas (76%) ainda seja baseada em conhecimento (*Knowledge-Based*), ou seja, regras predefinidas, notou-se um aumento consistente de sistemas não-baseados em conhecimento (IA/ML - Machine Learning) nos anos mais recentes, impulsionados pelo *Big Data*.
- **Utilidade para Não-Especialistas:** O artigo destaca que os CDSS são particularmente valiosos para médicos de cuidados primários e outros profissionais não especialistas, que frequentemente lidam com a complexidade da gestão da diabetes sem terem o conhecimento aprofundado das diretrizes mais recentes que um endocrinologista possui.

Os autores apontam como limitações críticas a falta de integração com os Registos de Saúde Eletrónicos (EHR) e o desafio de manter as bases de regras atualizadas [16]. Estas conclusões reforçam a necessidade de transitar para sistemas mais dinâmicos, como os baseados em LLM, capazes de interpretar diretrizes em evolução e integrar dados não estruturados.

3. Desempenho Global de um CDSS em Interações Medicamentosas:

Ao contrário das revisões anteriores, Van De Sijpe *et al.* em 2022 realizou uma avaliação quantitativa de um CDSS num hospital universitário durante um período de 2 anos, analisando mais de 38.409 alertas de interações medicamentosas (DDI) de gravidade considerada "muito severa" [32].

Análise do Estudo: Os investigadores procuraram avaliar o desempenho real de um CDSS baseado em regras, focando-se na "carga de alertas" (*alert burden*), nas taxas de aceitação pelos médicos e na validação farmacêutica posterior. O estudo combinou a análise de *logs* do sistema com inquéritos aos utilizadores para compreender as razões subjacentes à rejeição dos avisos de segurança [32].

Principais Conclusões: Os resultados quantitativos revelaram falhas críticas na especificidade dos algoritmos tradicionais [32]:

- **Taxas de Rejeição Elevada:** O estudo reportou uma taxa de rejeição de alertas (*override rate*) de 88,2%. Isto significa que o sistema interrompeu o médico para avisar de um risco grave e o médico em quase todos os casos optou por ignorar o aviso.
- **Falsos Positivos Técnicos:** A análise detalhada revelou que a maioria destes alertas não correspondia a riscos clínicos reais, mas sim a limitações do *software*. O sistema apresentava alertas baseados em janelas temporais fixas (ex: prescrição nos últimos 14 dias), alertando para interações mesmo quando o doente já tinha suspendido o primeiro fármaco (não havendo co-prescrição real).
- **Falta de Dados Contextuais:** Existiu uma incapacidade do sistema em ler parâmetros clínicos. Por exemplo, alertas sobre o prolongamento do intervalo QT (risco de arritmia) eram gerados indiscriminadamente, mesmo em doentes cujos eletrocardiogramas recentes ou análises laboratoriais estavam normais.

Os autores reforçam que os sistemas baseados puramente em regras temporais e farmacológicas são insuficientes para a prática clínica moderna. O estudo indica que é imperativo evoluir para algoritmos que integrem características específicas do doente (dados laboratoriais e sinais vitais) [32].

4. Utilização da Inteligência Artificial em Cuidados Intensivos:

Pinsky *et al.* em 2024, abordou os desafios e barreiras críticas à implementação de soluções baseadas em Inteligência Artificial em ambientes de alta complexidade, como as unidades de cuidados intensivos (UCI), onde a tomada de decisão é temporalmente crítica [18].

Análise do Estudo: Apesar do desenvolvimento acelerado de modelos preditivos de IA, a sua adoção efetiva tem sido "lenta, intermitente e desigual". O estudo identifica que os CDSS atuais falham não por falta de precisão técnica, mas por falta de integração no fluxo de trabalho e na incapacidade de adaptação dinâmica [18].

Principais Conclusões: O artigo sistematiza três obstáculos fundamentais que impedem a generalização da IA clínica [18]:

1. **Falta de "Consciência Situacional":** A maioria dos modelos de IA opera isoladamente, sem compreender o contexto dinâmico do doente. Falham em integrar fluxos de dados

multidimensionais em tempo real, resultando em alertas desfasados da realidade clínica do momento.

2. **Tendência e Equidade dos Dados:** Muitos algoritmos são treinados em bases de dados (como o MIMIC) que podem não representar adequadamente a diversidade demográfica da população alvo.
3. **Natureza de "Caixa Preta":** A opacidade dos modelos de *Deep Learning* gera desconfiança. Os médicos hesitam em seguir recomendações de sistemas cuja lógica interna não conseguem compreender.

Deste modo, Pinsky *et al.* referem que os CDSS baseados em IA não devem tentar substituir o clínico, mas sim funcionar como ferramentas de apoio e aumento cognitivo [18].

5. Modelo LLM capaz de prevenir erros na administração de medicamentos:

Num estudo de 2024, Pais *et al.* desenvolveram e implementaram o *Medication Direction Copilot* (MEDIC), um sistema baseado em LLM e desenhado para prevenir erros nas instruções de toma de medicamentos em farmácias online [33].

Análise do Estudo: Os autores abordam o problema crítico da transcrição incorreta de prescrições médicas, uma das principais causas de eventos adversos a medicamentos. O sistema MEDIC utiliza uma abordagem híbrida: combina um modelo de linguagem afinado (*fine-tuned LLM*) para extrair componentes clínicos (dose, frequência, via de administração) com um conjunto de "barreiras de segurança" (*safety guardrails*) baseadas em regras farmacológicas determinísticas para prevenir alucinações da IA [33].

Principais Conclusões: A avaliação do sistema, que incluiu testes retrospectivos e uma implementação em ambiente de produção real (*Amazon Pharmacy*), revelou os seguintes resultados [33]:

- **Redução de Erros:** A implementação do MEDIC resultou numa redução de 33% nos eventos de "quase-erro" (*near-miss events*), que são erros detetados e corrigidos por farmacêuticos antes de chegarem ao doente.
- **Modelo Híbrido:** O estudo comparou o MEDIC contra LLM genéricos (como o Claude). O modelo híbrido (IA + Regras) demonstrou ser muito mais seguro, com os modelos genéricos a gerarem até 4,38 vezes mais erros de segurança do que o sistema desenvolvido.
- **Mitigação de Alucinações:** A introdução de camadas de verificação baseadas em conhecimento farmacológico (ex: verificar se a dose extraída é compatível com a forma farmacêutica existente na bula) provou ser eficaz na mitigação de "alucinações" dos modelos de linguagem.

Assim sendo, este trabalho valida a hipótese de que a integração de LLM com bases de conhecimento formal (regras) é mais eficaz em relação a abordagens puramente baseadas em

IA ou puramente manuais. O sucesso do MEDIC demonstra que é possível utilizar LLM em processos críticos de saúde, desde que envolvidos por mecanismos de treino e segurança robustos [33].

2.5.2 Limitações atuais

Nos últimos anos, tem-se verificado um crescimento significativo de sistemas baseados em conteúdo, apoiados em ontologias médicas, bases de conhecimento farmacológicas e diretrizes clínicas [34],[35]. Contudo, estes modelos são particularmente rígidos, dependendo estritamente do conhecimento formalmente codificado de regras, ontologias e diretrizes, apresentando falta de flexibilidade para raciocinar sob incerteza. Assim sendo, a utilização de técnicas híbridas ultrapassa a barreira existente ao combinar técnicas, capazes de aprender padrões a partir de dados, o que melhora a robustez e adaptabilidade a cenários incertos.

No entanto, a implementação destas tecnologias apresenta barreiras significativas. Uma revisão de 2025 [36] destacou que, embora existe diversos modelos preditivos, continua a existir uma escassez de sistemas integrados capazes de gerar alertas em tempo real que sejam clinicamente aplicáveis e não intrusivos. A literatura aponta que a maioria das ferramentas atuais permanece limitada a validações retrospectivas ou ambientes simulados, falhando na demonstração da eficácia em fluxos de trabalho reais e na mitigação da “fadiga de alertas” (*alert fatigue*), o que compromete a sua adoção segura por parte dos farmacêuticos e médicos no momento da prescrição.

2.5.2.1 O Fenómeno da Fadiga de Alertas (*Alert Fatigue*)

Um dos maiores obstáculos à eficácia dos sistemas de decisão clínica atuais é a “fadiga de alertas” (*alert fatigue*). Este fenómeno é definido como um estado de sobrecarga cognitiva e dessensibilização que ocorre quando os profissionais de saúde são expostos a um volume excessivo de avisos de segurança, muitos dos quais irrelevantes ou de baixo risco clínico. Consequentemente, o utilizador tende a ignorar (*override*) os alertas de forma quase automática, sem processar o seu conteúdo, o que pode levar a que avisos críticos sejam negligenciados.

Uma revisão sistemática realizada por Poly *et al.* (2020) [37] identificou em múltiplos hospitais que as taxas de rejeição de alertas de CDSS oscilam entre 46,2% e 96,2%. Sendo que aproximadamente 29,4% a 100% dos alertas ignorados foram classificados como adequados (interação medicamento-alergia 63,4% a 100%, interação medicamento-medicamento 0% a 95%, dose 43,9% a 88,8%), sugerindo que os sistemas atuais têm uma especificidade muito baixa [37].

A análise aprofundada das causas da fadiga de alertas revela falhas estruturais nos algoritmos tradicionais:

- **Falta de Contextualização Clínica:** Van De Sijpe *et al.* (2022) [32] verificaram que 88,2% dos alertas de interações medicamentosas graves foram ignorados pelo profissional de

saúde. A maioria destes alertas eram "falsos positivos", gerados porque o sistema não considerava parâmetros do doente, como valores laboratoriais ou eletrocardiogramas recentes, nem a suspensão prévia de fármacos. Deste modo, o sistema alertava para uma interação teórica, mas que não é real para o estado atual daquele doente.

- **Intrusividade:** Alertas do tipo *pop-up* modal, que bloqueiam o ecrã e interrompem o raciocínio clínico. Quando estes alertas surgem repetidamente para situações de baixo risco (como possíveis reações secundárias), cria-se uma situação onde o médico ignora o apoio da ferramenta de alertas [37].

Desta forma, a persistência deste problema e as elevadas taxas de rejeição justificam a necessidade de transitar para sistemas inteligentes que utilizem Inteligência Artificial para filtrar o ruído. Assim sendo, o objetivo não é apenas alertar, mas sim apresentar apenas os avisos críticos para o perfil individual do doente.

2.6 Inteligência Artificial na Saúde

Recentemente a literatura tem mostrado que os Modelos de Linguagem de Grande Escala (LLM), que são sistemas de IA avançados que compreendem e geram linguagem natural, ou texto semelhante ao ser humano, nomeadamente com a utilização do modelo OpenAI's GPT-4 Turbo, estes podem ser integrados em sistemas de apoio à decisão clínica ao traduzir diretrizes clínicas complexas para um formato processável por IA e, a partir daí, gerar recomendações terapêuticas ou orientações de tratamento adaptadas ao contexto do doente. As diretrizes são "reformatadas" para facilitar a leitura por LLM e acompanhadas de técnicas de *retrieval augmented generation* (RAG), uma técnica que permite ao modelo procurar informação fiável antes de gerar a resposta, sendo que a precisão das recomendações pode subir de cerca de 43% para 99% [38],[39].

No entanto, de forma a compreender a arquitetura proposta, é fundamental distinguir as tecnologias envolvidas. A Inteligência Artificial (IA) é o campo vasto da ciência da computação dedicado a criar sistemas capazes de realizar tarefas que normalmente exigiriam inteligência humana. Dentro desta, o *Deep Learning* (DL) é um subcampo que utiliza redes neuronais com múltiplas camadas para aprender padrões complexos. Os LLM, como o GPT-4, são aplicações específicas de DL treinadas em vastos conjuntos de dados, que conseguem se especificar em determinadas áreas. Por fim, RAG é uma arquitetura técnica que combina um LLM com uma base de conhecimento externa de forma a garantir precisão factual e mitigar as alucinações, muito características da IA.

Assim sendo, os LLM demonstram potencial real de produzir recomendações úteis, desde que sujeitos a revisões médicas e refinamentos com *datasets* adequados. A integração de LLM num sistema de recomendação em saúde permite, assim, conciliar o conhecimento formal (diretrizes de medicamentos e dados clínicos) com a flexibilidade e escalabilidade da IA, em sistemas híbridos que oferecem recomendações personalizadas e contextualizadas durante a prática clínica.

2.6.1 Arquitetura Transformer e LLM

Os Grandes Modelos de Linguagem (LLM) atuais, como o GPT-4 ou Llama 3, baseiam-se na arquitetura Transformer, introduzida originalmente por Vaswani *et al.* (2017) e extensivamente analisada na revisão de Zhao *et al.* (2023) [40]. Ao longo da última década, verificou-se uma transição das Redes Neurais Recorrentes (RNN) e *Long Short-Term Memory* (LSTM) para a arquitetura Transformer, o que representa uma mudança de paradigma no processamento de sequências. O componente central desta arquitetura é o mecanismo de "auto-atenção" (*self-attention*), que permite modelar dependências entre elementos de uma sequência independentemente da sua distância posicional.

2.6.1.1 Limitações das Redes Recorrentes (RNN/LSTM):

As arquiteturas anteriores, como as RNN, processam a informação de forma sequencial, por exemplo, para entender um *token* (ex: palavra) no instante “t”, a rede precisa do estado oculto do instante anterior h_{t-1} [40].

Matematicamente, isto implica que a informação tem de percorrer “n” passos para relacionar o primeiro *token* da sequência com o *token* na posição “n”. Este processamento sequencial apresenta dois problemas críticos [40]:

- **Impossibilidade de Paralelização:** O cálculo de h_t depende estritamente de h_{t-1} , o que impede a computação paralela eficiente em *hardware* moderno (GPU), o que torna o treino em sequências longas computacionalmente dispendioso.
- **Perda de Dependências a Longo Prazo:** O "caminho" que o gradiente tem de percorrer durante o treino (retropropagação) é proporcional ao comprimento da sequência ($O(n)$). Desta forma, em sequências extensas, isto causa o problema do desvanecimento do gradiente (*vanishing gradient*), onde a rede perde a capacidade de capturar relações entre *tokens* distantes.

2.6.1.2 Transformer: O Mecanismo de Auto-Atenção (Self-Attention):

A arquitetura *Transformer* supera estas limitações, porque descarta a recorrência sequencial em prol do mecanismo de atenção. Este mecanismo permite que o modelo processe a sequência inteira em paralelo, calculando a relevância de cada *token* em relação a todos os outros, independentemente da sua posição relativa. Assim sendo, o núcleo matemático do *Transformer* é baseado na *Scaled Dot-Product Attention*. Dado uma sequência de entrada, o modelo projeta cada *token* em três vetores: *Query* (Q), *Key* (K) e *Value* (V). A saída é calculada como uma soma ponderada dos valores, onde o peso é determinado pela compatibilidade entre a *query* e as *keys*, conforme a equação [40]:

$$Attention(Q, K, V) = softmax\left(\frac{Q \cdot K^T}{\sqrt{d_k}}\right) V \quad (1)$$

Onde:

- **Q (Queries):** Matriz que representa os itens para os quais se procura contexto.
- **K (Keys):** Matriz que representa os itens que fornecem o contexto.
- **V (Values):** Matriz que contém o conteúdo informacional a ser extraído.
- **d_k :** A dimensão dos vetores chave, utilizada para normalizar o produto escalar. Sem este fator de escala ($\frac{1}{\sqrt{d_k}}$), o produto escalar poderia crescer em magnitude, forçando a função *softmax* para regiões com gradientes extremamente pequenos, o que dificultaria o treino.

A função *Softmax* é aplicada para normalizar os resultados numa distribuição de probabilidade, garantindo que a soma dos pesos de atenção seja igual a 1. Matematicamente, para um vetor "x", a função define-se como:

$$\text{softmax}(x_i) = \frac{e^{x_i}}{\sum_j e^{x_j}} \quad (2)$$

Esta operação permite ao modelo "focar" em partes específicas da sequência de entrada (atribuindo probabilidades mais altas) enquanto ignora outras, reduzindo o caminho do sinal entre qualquer par de palavras para $O(1)$.

2.6.1.3 Aplicação ao Contexto Clínico

A transição desta arquitetura para o domínio da saúde pode viabilizar o presente projeto, porque no contexto clínico, a fórmula de atenção poderá permitir que, ao processar a representação vetorial de um novo fármaco (*Query*), o modelo calcule um "peso de atenção" elevado para *tokens* específicos no histórico do doente (*Keys*), como "Insuficiência Renal" ou "Alergia a Penicilina", mesmo que estes termos estejam separados por milhares de palavras em notas clínicas não estruturadas.

Esta capacidade de "consciência global" do quadro clínico é potenciada por evoluções arquiteturais modernas presentes em LLM como o Llama, que superam as limitações do Transformer original com [40]:

- **RoPE (Rotary Position Embeddings):** Ao contrário dos *embeddings* posicionais absolutos originais, o RoPE codifica a posição absoluta através de uma matriz de rotação, o que preserva matematicamente a informação da posição relativa entre *tokens*. Este mecanismo é crucial para a extrapolação, permitindo que o modelo generalize a deteção de erros para sequências de texto longas (ex: históricos clínicos).
- **SwiGLU (Swish Gated Linear Unit):** Uma função de ativação que combina um mecanismo de porta (*gating*) com a função de ativação não-linear *Swish*, o que melhora a propagação do gradiente e a estabilidade do treino, permitindo ao modelo aprender padrões clínicos mais complexos com maior eficiência.

Desta forma, a implementação destas técnicas permite superar a rigidez dos sistemas baseados apenas em regras, sendo possível oferecer um protótipo robusto e escalável.

2.6.1.4 Limitações dos LLM

Apesar do seu potencial, a utilização de LLM em contextos críticos como a saúde podem apresentar limitações significativas nomeadamente:

- **Desatualização do Conhecimento:** O conhecimento paramétrico de um LLM é estático e limitado à data do fim do seu treino (*training cutoff*). Por exemplo, o modelo não tem conhecimento de novos medicamentos, alertas de segurança recentes ou alterações em diretrizes clínicas que ocorram após a data do treino [41].
- **Alucinações:** Os LLM são modelos probabilísticos desenhados para gerar texto plausível, não necessariamente verdadeiro. Podem gerar factos incorretos, inventar referências bibliográficas ou sugerir dosagens erradas com elevada confiança (*overclaim hallucination*), o que representa um risco grave na prescrição médica [41], [42].
- **Custo Computacional e Latência:** A inferência em modelos de grande escala (ex: GPT-4) exige recursos computacionais elevados [40].
- **Falta de Transparência:** Os dados de treino podem conter enviesamentos demográficos ou clínicos, levando a recomendações discriminatórias, baseadas ao local ou diretriz específica dos dados. Além disso, a natureza de "caixa Preta" das redes neuronais profundas dificulta a explicação lógica passo-a-passo de como o modelo chegou a uma determinada conclusão [18].

2.6.2 Retrieval-Augmented Generation (RAG)

Para mitigar as limitações intrínsecas dos LLM, como a desatualização do conhecimento e alucinações, a literatura tem explorado arquiteturas de *Retrieval-Augmented Generation* (RAG). O RAG é uma técnica que integra um modelo gerador (o LLM) a um módulo de recuperação de informação baseada em vetores densos (*dense vector retrieval*). O processo baseia-se na representação semântica do texto num espaço vetorial de alta dimensão. Quando uma consulta é submetida, o sistema calcula a similaridade do cosseno entre o vetor da consulta “q” e os vetores dos documentos “d” na base de conhecimento [41]:

$$\text{sim}(q, d) = \frac{q \cdot d}{|q| \cdot |d|} \quad (3)$$

- **sim(q, d):** A pontuação de similaridade entre a consulta “q” e o documento “d”.
- **|q|:** A magnitude do vetor “q”.
- **|d|:** A magnitude do vetor “d”.

Conforme detalhado por Gao *et al.* (2024) [41], este processo divide a inferência em duas fases:

1. **Recuperação (Retrieval):** O sistema converte a consulta clínica (ex: perfil do doente e fármaco prescrito) num vetor numérico (*embedding*) e pesquisa numa base de dados vetorial externa os “k” documentos com maior similaridade semântica (ex: diretrizes da DGS, bulas do Infarmed ou artigos do PubMed).
2. **Geração (Generation):** O LLM recebe a consulta original enriquecida com estes documentos recuperados no contexto (*prompt*), sendo instruído a gerar a resposta exclusivamente com base nessa evidência.

Esta abordagem garante que a resposta gerada é fundamentada (*grounded*) e permite que o sistema forneça citações diretas das fontes, aumentando a confiança da recomendação [41].

2.6.3 Tendências Atuais

Deste modo, a investigação em sistemas de recomendação clínica tem transitado da simples análise de regras para a utilização de representações vetoriais clínicas (*Clinical Embeddings*) e arquiteturas baseadas em *Transformers*. Estas tecnologias permitem capturar relações semânticas complexas entre diagnósticos e medicamentos que escapam aos sistemas tradicionais.

1. Uso de *Embeddings* Clínicos - ClinicalBERT

A aplicação de técnicas de *Deep Learning* em saúde exige que os dados médicos não estruturados sejam convertidos em representações vetoriais (*embeddings*) que têm como finalidade capturar dados significativos sobre cada objeto, preservando o seu significado semântico específico e permitindo encontrar objetos semelhantes. Embora modelos genéricos como o BERT (modelo de IA do Google para processamento de linguagem natural, que usa a arquitetura *Transformer*) ou o BioBERT (treinado em artigos científicos do PubMed) sejam robustos, Alsentzer *et al.* [43] demonstraram que estes falham em capturar os pormenores da linguagem usada em notas clínicas reais (hospitalares), que são frequentemente agramaticais e com abreviaturas específicas.

Metodologia e Arquitetura do ClinicalBERT

De forma a mitigar esta limitação, os autores desenvolveram o ClinicalBERT (e disponibilizaram-no via [GitHub](#)), utilizando uma abordagem de aprendizagem por transferência (*transfer learning*). O modelo foi treinado sobre a base de dados MIMIC-III, processando cerca de 2 milhões de notas clínicas. A inovação metodológica residiu na criação de duas variantes específicas: uma treinada sobre todo o tipo de notas e outra refinada exclusivamente em "sumários de alta" (*Discharge Summaries*). Esta especialização permitiu ao modelo aprender padrões de prescrição e diagnóstico que ocorrem especificamente no momento da alta hospitalar, um ponto crítico para a reconciliação terapêutica [43].

Resultados Quantitativos e Qualitativos

A elevada eficácia desta abordagem foi validada em tarefas de Inferência de Linguagem Natural Médica (MedNLI). Quantitativamente, o modelo Bio+Discharge Summary BERT (inicializado com BioBERT e treinado especificamente em sumários de alta) atingiu uma precisão de 82,7% na tarefa de Inferência de Linguagem Natural Médica (MedNLI), ultrapassando a precisão referida no estado da arte (73,5%) e obteve os melhores *F1-scores* em tarefas de reconhecimento de entidades (ex: 87,8 no *i2b2 2010*), demonstrando uma elevada capacidade de "raciocínio" clínico em comparação com modelos não especializados. Qualitativamente, o estudo comprovou que este modelo captura melhor a semântica hospitalar. Por exemplo, a palavra "Discharge" (Alta) no BioBERT está associada a "admission" (admissão), "wave" (onda) e "sight" (visão), no entanto apenas a primeira (admissão) parece relevante para as operações clínicas. Em contraste, no Clinical BERT, todas as palavras associadas são significativas num contexto de operações clínicas, demonstrando uma compreensão do fluxo operacional hospitalar [43].

Em suma, os autores concluem que os *embeddings* clínicos demonstram uma superioridade robusta face aos modelos genéricos, validando o benefício de utilizar *corpora* específicos como os sumários de alta. Contudo, o estudo aponta limitações relevantes que definem o trabalho futuro: a dependência de dados de uma única instituição (MIMIC - BIDMC), pode restringir a generalização face a diferentes práticas de cuidados; a ausência de testes com arquiteturas de modelo mais avançadas sobre os *embeddings*; e a ineficácia em tarefas de desidentificação (*de-ID*). Para mitigar estas limitações, os autores sugerem a incorporação de notas de múltiplas instituições e a introdução de desidentificação sintética no texto de origem [43].

2. Sistemas de Recomendação baseados em Grafos e Transformers - G-BERT

Shang *et al.* [44] de forma a melhorar a falta de integração da hierarquia do conhecimento médico, desenvolveram o G-BERT (e disponibilizaram-no via [GitHub](#)), o primeiro modelo a combinar Redes Neurais de Grafos (GNN) com a arquitetura do modelo BERT para a recomendação de medicação.

Metodologia e Arquitetura do G-BERT

A inovação técnica do G-BERT reside numa arquitetura de duas fases. Inicialmente, o modelo utiliza Redes de Atenção em Grafos (GAT) para gerar representações vetoriais (*embeddings*) a partir das ontologias médicas (ICD-9 para diagnósticos e ATC para medicamentos). Ao contrário dos métodos lineares, esta abordagem captura a estrutura hierárquica interna, e aprende que certos códigos são "filhos" ou "pais" de outros na árvore clínica (ex: ICD-9, 428 - Insuficiência cardíaca é "pai" de 428.1 - Insuficiência Cardíaca Congestiva). Posteriormente, estes *embeddings* enriquecidos são introduzidos num codificador *Transformer*. Os autores realizaram um treino deste *Transformer* utilizando dados de visitas únicas (geralmente descartados), através de duas tarefas de pré-treino: a *previsão dual* (prever diagnósticos a partir de medicamentos e vice-versa) e a *autoprevisão* (recuperar códigos mascarados), dispensando os *embeddings* de posição visto que a ordem dos códigos numa receita não é relevante [44].

Resultados Quantitativos e Qualitativos

A avaliação experimental, foi realizada sobre a base de dados MIMIC-III e demonstrou que o G-BERT atingiu um *F1-score* de 61,52%, superando ligeiramente o estado da arte anterior, incluindo modelos robustos como o GAMENet (61,26%) e o RETAIN (60, 64%). As variantes do modelo sem a componente de grafos (ontologia) ou sem o pré-treino obtiveram resultados inferiores (ex: G-BERT_{G-}, 59,03% sem ontologia), provando que a integração do conhecimento estruturado (grafos) com a capacidade de generalização do *Transformer* é determinante para a precisão da recomendação [44].

Em suma, os autores concluem que o G-BERT estabelece um esquema de pré-treino de modelos de linguagem ao domínio da saúde, que permite a utilização eficiente de dados que anteriormente não eram considerados. Como trabalho futuro, o estudo sugere o enriquecimento da representação dos códigos médicos através da adição de tarefas estruturais auxiliares e a adaptação do modelo para lidar com *datasets* ainda maiores e com modalidades de dados mais heterogêneas, visando uma robustez ainda maior na prática clínica [44].

3. Codificação Molecular para Melhoria da Interação Medicamentosa - SafeDrug

Yang *et al.* [45] desenvolveram o sistema SafeDrug (e disponibilizaram-no via [GitHub](#)) para mitigar uma limitação crítica dos modelos anteriores: a representação inadequada dos medicamentos. A maioria dos sistemas trata os fármacos apenas como códigos binários (*one-hot encoding*), ignorando que a sua estrutura molecular contém informações vitais sobre eficácia e segurança, o que pode permitir uma melhor recomendação de medicamentos.

Metodologia e Arquitetura do SafeDrug

A inovação do SafeDrug reside na utilização de codificadores duplos de grafos moleculares que capturam tanto padrões globais como locais. Globalmente, o modelo integra uma Rede Neuronal de Passagem de Mensagens (MPNN) para codificar a conectividade átomo-a-átomo de toda a molécula, aprendendo as propriedades farmacológicas macroscópicas. Localmente, e em paralelo, utiliza um codificador bipartidário que segmenta a molécula em subestruturas funcionais (ex: grupos químicos específicos) utilizando o método BRICS. Esta representação local é processada por uma rede com máscara (*masked neural network*), o que permite ao modelo identificar especificamente quais os grupos funcionais que estão associados a interações medicamentosas adversas [54]. Além disso, o sistema integra uma função de perda controlável, inspirada em controladores de derivada integral proporcional (PID), que permite ajustar dinamicamente o equilíbrio entre a precisão da recomendação e a taxa de interações (DDI) tolerada [45].

Resultados Quantitativos e Qualitativos

A avaliação experimental na base de dados MIMIC-III revelou que o SafeDrug alcançou um F1-score de 67,68%, superando também modelos como o GAMENet e o RETAIN. O impacto mais significativo verificou-se na segurança: o modelo conseguiu reduzir a taxa de Interações Medicamentosas (DDI) em 19,43% comparativamente aos *baselines*, sem comprometer a precisão da recomendação. Adicionalmente, devido à eficiência da sua arquitetura bipartida, o SafeDrug demonstrou ser computacionalmente mais leve, reduzindo o tempo de treino em

cerca de 14% e acelerando a inferência em 2 vezes face a abordagens anteriores baseadas em *Deep Learning* [45].

Em suma, os autores concluem que a incorporação explícita da estrutura molecular dos fármacos melhora significativamente a segurança das prescrições. Como trabalho futuro, sugerem a exploração de métodos de segmentação molecular alternativos e a aplicação do modelo a *datasets* que incluam dados genómicos, visando uma personalização ainda mais profunda da terapia [45].

2.7 Interoperabilidade e Normas

A eficácia de um sistema de recomendação em ambiente hospitalar depende significativamente da sua capacidade de interpretar dados heterogéneos provenientes de diferentes fontes e de comunicar com outros sistemas. Para garantir a escalabilidade e a futura integração do protótipo, o projeto adotará as seguintes normas internacionais:

- **Anatomical Therapeutic Chemical (ATC):** Sistema de classificação da Organização Mundial da Saúde (OMS) que agrupa fármacos de acordo com o órgão ou sistema sobre o qual atuam e as suas propriedades químicas, farmacológicas e terapêuticas [46]. Esta norma é essencial para a deteção algorítmica de duplicações terapêuticas (ex: detetar que a Sinvastatina e a Atorvastatina pertencem à mesma classe ATC C10AA - Inibidores da HMG-CoA redutase). Exemplificando:
 - Sinvastatina tem o código ATC: C10AA01;
 - Atorvastatina tem o código ATC: C10AA05;
 - O sistema verifica que ambos partilham o nível 4 (C10AA) e dispara o alerta de possível duplicação terapêutica.
- **International Classification of Diseases (ICD-10):** A norma *standard* global para a codificação de diagnósticos médicos e gestão de saúde. O sistema proposto utiliza estes códigos para verificar contraindicações do tipo doença-medicamento, permitindo uma filtragem contextual baseada no perfil clínico do doente, uma prática cuja utilidade na identificação de eventos adversos a medicamentos tem sido validada em estudos recentes [47]. Exemplificando a deteção para um risco de nefrotoxicidade:
 - O Utente tem o diagnóstico: N18.3 (Doença renal crónica - N18, estágio 3);
 - O Medicamento (ex: Ibuprofeno) é contraindicado à categoria: N18 (Doença renal crónica), por ser um Anti-inflamatório Não Esteroide (AINE), que prejudica a função renal ao reduzir o fluxo sanguíneo para os rins;
 - O sistema verifica que o código do utente (N18.3) é uma subcategoria da restrição do medicamento (N18) e apresenta o alerta da contraindicação.

- **HL7 FHIR (*Fast Healthcare Interoperability Resources*)**: É uma norma de referência para a troca eletrônica de dados em saúde. O FHIR resolve o problema da fragmentação de dados ao utilizar uma abordagem modular baseada em "Recursos" (ex: *Patient, MedicationRequest, Condition*), acessíveis via API RESTful modernas. O protótipo será desenhado para consumir e produzir dados em formato JSON compatível com a norma FHIR. Esta opção arquitetural assegura que o sistema de recomendação não funciona isoladamente, mas sim como um módulo interoperável capaz de ser acoplado, no futuro, a qualquer Registo de Saúde Eletrónico (EHR) moderno ou utilizado em plataformas de investigação clínica, facilitando a partilha e reutilização de dados para treino de modelos de IA [48].

2.8 Métricas de Avaliação

Para validar a eficácia do sistema proposto, serão adotadas métricas quantitativas e qualitativas, alinhadas com as diretrizes internacionais *DECIDE-AI* [49]. Estas diretrizes recomendam que a avaliação de sistemas de IA em fase inicial não se limite ao desempenho algorítmico, mas integre também a avaliação de fatores humanos (usabilidade) e segurança.

2.8.1 Métricas de Performance

A avaliação da precisão dos alertas pode utilizar métricas objetivas, nomeadamente:

- **Precisão (*Precision*)**: Representa a proporção de alertas gerados pelo sistema que são efetivamente corretos ou clinicamente relevantes (Verdadeiros Positivos - *true positives*). Uma precisão elevada é determinante para mitigar a "fadiga de alertas", o que reduz a sobrecarga cognitiva dos profissionais de saúde causada por avisos irrelevantes [50].
- **Revocação (*Recall*)**: Corresponde à capacidade do sistema em identificar a totalidade dos erros de prescrição existentes (fração dos erros reais detetados). Desta forma, a determinação da revocação é fundamental para assegurar que erros com potencial de dano grave não ficam por detetar (evita falsos negativos - *false negatives*) [50].
- **F1-Score**: Definido como a média harmónica entre a Precisão e a Revocação. Esta métrica identifica o desempenho global do modelo, prejudicando sistemas que apresentam uma destas métricas muito baixa em detrimento da outra. É calculada pela seguinte fórmula [50]:

$$\circ \quad F1 = \frac{2 * Precision * Recall}{Precision + Recall} \quad (4)$$

2.8.2 Métricas de Usabilidade e Aceitação

As métricas de usabilidade e aceitação do profissional de saúde ao protótipo, podem ser avaliadas através de:

- **SUS (*System Usability Scale*):** Um questionário padronizado de 10 itens que avalia a usabilidade percebida pelo profissional de saúde [51].
- **TAM (*Technology Acceptance Model*):** Avalia a "Utilidade Percebida" e a "Facilidade de Uso Percebida", que são os maiores preditores da intenção de um profissional de saúde a adotar uma nova tecnologia na sua prática diária [52].

2.9 Síntese Crítica e Lacunas

A revisão da literatura evidencia que os sistemas tradicionais baseados em regras continuam a ser relevantes em domínios críticos, devido à sua transparência, auditabilidade e previsibilidade. Contudo, quando aplicados isoladamente, estes sistemas podem tornar-se rígidos, difíceis de manter e propensos à geração excessiva de alertas, contribuindo para a fadiga de alertas. Por outro lado, abordagens baseadas em dados e aprendizagem automática podem melhorar a contextualização e a priorização das recomendações, mas introduzem desafios associados à interpretabilidade, generalização e validação clínica.

Neste contexto, a lacuna identificada não reside apenas na ausência de sistemas capazes de detetar interações ou contraindicações, mas na dificuldade de combinar segurança clínica, recomendação contextual, explicabilidade e controlo humano num fluxo coerente. Assim, o presente trabalho propõe uma abordagem híbrida em que as decisões críticas são controladas por um motor de regras clínicas, as alternativas terapêuticas são ordenadas através de conhecimento, contexto e aprendizagem supervisionada, e as explicações são produzidas por um módulo LLM condicionado pelos resultados previamente gerados pelo sistema.

Esta abordagem não pretende substituir o juízo clínico, mas apoiar o profissional de saúde através de alertas estruturados, recomendações justificadas e mecanismos de feedback. Técnicas como RAG, *embeddings* clínicos e integração com *guidelines* documentais são reconhecidas como relevantes, mas são enquadradas como possibilidades de evolução futura, e não como componentes centrais da versão atual do protótipo.

3 Análise e Design do Sistema

O presente capítulo descreve a análise e o design do sistema proposto para apoiar a identificação e prevenção de erros de prescrição de medicamentos. Após a revisão do estado da arte e a caracterização do problema de investigação, torna-se necessário definir de forma estruturada os requisitos do sistema, o modelo de domínio e os principais cenários de utilização, de modo a sustentar a arquitetura da solução e a respetiva implementação.

Atendendo à natureza crítica do domínio da saúde, a análise do sistema não pode limitar-se à enumeração de funcionalidades isoladas. É igualmente essencial enquadrar os requisitos de segurança, interoperabilidade, explicabilidade e adequação ao contexto clínico, assegurando que a solução proposta responde não apenas ao problema técnico da recomendação, mas também às exigências práticas e éticas inerentes ao apoio à decisão em prescrição medicamentosa.

3.1 Visão Geral do Sistema

O sistema a desenvolver consiste numa plataforma inteligente de apoio à decisão clínica, concebida para analisar o perfil do utente, a medicação ativa, as condições clínicas associadas e outros elementos de contexto relevantes, com o objetivo de detetar situações de risco e apresentar alertas e recomendações terapêuticas mais adequadas.

A solução assenta numa abordagem híbrida em cascata, combinando uma camada de segurança clínica baseada em regras determinísticas com um motor de recomendação contextual e um módulo explicativo suportado por um modelo de linguagem de grande dimensão (LLM). Esta abordagem permite articular a robustez das verificações clínicas explícitas com uma análise mais flexível do contexto do utente, procurando equilibrar segurança, precisão, interpretabilidade e utilidade prática. O módulo LLM é utilizado exclusivamente para geração de explicações em linguagem natural a partir dos alertas e recomendações já produzidos, não participando na decisão clínica.

Do ponto de vista funcional, o sistema permite introduzir ou importar informação clínica estruturada, analisar prescrições em tempo real, verificar alergias, interações medicamentosas, contraindicações e duplicações terapêuticas, e apresentar ao profissional de saúde alertas priorizados e justificados. Numa fase inicial, o protótipo é suportado por dados sintéticos gerados com a ferramenta *Synthea*, bases de conhecimento farmacológico codificadas em formato JSON e um modelo de aprendizagem supervisionada treinado com rótulos fracos (*silver labels*) derivados do motor de segurança clínica e seguidamente validados pelo desenvolvedor (*golden labels*), permitindo validar a viabilidade técnica e metodológica da solução sem recorrer a dados clínicos identificáveis.

Os principais *stakeholders* do sistema incluem os médicos, enquanto utilizadores primários e responsáveis pela decisão de prescrição, os farmacêuticos clínicos, enquanto intervenientes com papel relevante na validação terapêutica e na análise da segurança medicamentosa, e os administradores do sistema, responsáveis pela configuração das fontes de conhecimento e manutenção técnica. Indirectamente, o utente assume-se como *stakeholder* central, na medida em que constitui o principal beneficiário da redução de erros de prescrição e do aumento da segurança clínica proporcionada pela solução.

A Tabela 3.1 apresenta os principais *stakeholders* e atores identificados para o sistema, caracterizando o seu tipo, papel no contexto da prescrição e interesse principal na solução proposta.

Tabela 3.1 - Principais entidades caracterizadas em tipo e interesse principal.

Entidade	Tipo	Interesse principal
Médico	Stakeholder e Ator	Prescrever com maior segurança, reduzir erros e receber explicações claras e contextualizadas
Farmacêutico	Stakeholder e Ator	Rever prescrições complexas, validar risco terapêutico e apoiar a reconciliação medicamentosa
Utente	Stakeholder	Beneficiar de maior segurança terapêutica e menor probabilidade de eventos adversos evitáveis
Instituição de saúde	Stakeholder	Melhorar a segurança do doente, reduzir custos evitáveis e garantir conformidade e interoperabilidade
Gestor clínico ou hospitalar	Stakeholder	Monitorizar indicadores de utilização, risco e impacto operacional
Administrador do sistema	Stakeholder e Ator	Gerir utilizadores, perfis, parâmetros operacionais e versões das bases de conhecimento
Sistema EHR/CPOE	Ator externo	Fornecer e receber dados clínicos estruturados no fluxo de prescrição

Base de conhecimento farmacológico	Ator externo	Suportar verificações de interações, contraindicações, doses e advertências
Equipa de investigação e desenvolvimento	Stakeholder	Melhorar o protótipo, analisar desempenho e validar a abordagem proposta

3.2 Requisitos Funcionais

Os requisitos funcionais descrevem os serviços e comportamentos que o sistema deverá disponibilizar aos seus utilizadores. No contexto da presente solução, esses requisitos resultam diretamente do objetivo identificado: apoiar o profissional de saúde na deteção e prevenção de erros de prescrição, recorrendo a uma combinação de verificação clínica determinística, recomendação contextual e mecanismos de explicação.

Os requisitos funcionais são agrupados em cinco áreas principais: gestão de utilizadores e acesso, ingestão e gestão de dados clínicos, análise de segurança clínica, recomendação e explicação, e monitorização e administração do sistema.

Para exprimir de forma orientada ao utilizador as interações com o sistema, os requisitos funcionais são complementados com histórias de utilizador (*user stories*), que capturam quem interage com o sistema, o que pretende realizar e qual o benefício esperado. A Tabela 3.2 apresenta as histórias de utilizador definidas, organizadas por ator, que servem de base à especificação dos requisitos funcionais e orientam as decisões de design do sistema.

Tabela 3.2 - Requisitos funcionais.

ID	Ator	Requisito funcional	Descrição resumida
RF01	Utilizador	Autenticar no sistema	O sistema deve permitir o acesso apenas a utilizadores autorizados, de acordo com o respetivo perfil.
RF02	Administrador	Gerir utilizadores e perfis	O sistema deve permitir criar, alterar e desativar utilizadores e respetivas permissões.
RF03	Médico / Sistema externo	Importar ou introduzir dados clínicos	O sistema deve permitir obter dados do utente e da prescrição através de ficheiros, API ou introdução manual.
RF04	Médico	Submeter prescrição para análise	O sistema deve permitir ao médico submeter uma prescrição para avaliação automática.

RF05	Sistema	Analisar prescrição e gerar alertas clínicos	O sistema deve avaliar a prescrição face ao perfil clínico do utente e gerar alertas relativos a alergias, interações, contraindicações, duplicações ou outros riscos relevantes.
RF06	Sistema	Priorizar alertas	O sistema deve classificar os alertas de acordo com a sua gravidade e relevância clínica, apoiando a redução da fadiga de alertas.
RF07	Sistema	Gerar recomendações terapêuticas	O sistema deve sugerir alternativas terapêuticas admissíveis quando for identificado risco ou possibilidade de melhoria da prescrição.
RF08	Médico / Farmacêutico	Consultar explicações	O sistema deve apresentar a justificação clínica e documental associada aos alertas e recomendações.
RF09	Médico / Farmacêutico	Registar feedback	O sistema deve permitir registar aceitação, rejeição, ignorar ou comentário relativamente aos alertas e recomendações.
RF10	Administrador	Gerir conhecimento clínico e farmacológico	O sistema deve permitir atualizar regras, fontes documentais e parâmetros utilizados pelos componentes de segurança e recomendação.
RF11	Administrador / Investigador	Consultar indicadores de utilização	O sistema deve disponibilizar métricas agregadas sobre análises realizadas, tipos de alerta, recomendações e feedback registado.

3.3 Requisitos Não Funcionais

Os requisitos não funcionais dizem respeito às propriedades de qualidade e às restrições operacionais do sistema. Num sistema de apoio à decisão clínica, a utilidade da solução não depende apenas da existência de funcionalidades, mas também da sua robustez, segurança, desempenho, compreensibilidade e capacidade de integração com o ecossistema digital de saúde. Deste modo, os requisitos não funcionais influenciam o sucesso e a adoção da aplicação.

A Tabela 3.3 sintetiza os requisitos não funcionais do sistema, organizados por categoria de qualidade, indicando o critério de aceitação e a sua relevância para o contexto clínico.

Tabela 3.3 - Requisitos não funcionais.

ID	Categoria	Requisito não funcional	Critério de avaliação
RNF01	Segurança	O sistema deve restringir o acesso às funcionalidades de acordo com o perfil do utilizador.	Testes de acesso por perfil demonstram que utilizadores sem permissão não executam operações restritas.
RNF02	Auditoria	O sistema deve registar as análises realizadas e as decisões do utilizador.	100% das análises devem gerar registo com data, prescrição, alertas/recomendações e feedback, quando exista.
RNF03	Rastreabilidade	O sistema deve permitir rastrear a origem dos alertas e recomendações.	Cada alerta ou recomendação deve estar associado a uma regra, fonte ou versão do modelo.
RNF04	Desempenho	O sistema deve devolver a análise inicial da prescrição em tempo compatível com utilização interativa.	Pelo menos 95% das análises sem geração LLM devem ser concluídas abaixo de um limiar definido no ambiente experimental.
RNF05	Reprodutibilidade	O sistema deve produzir resultados consistentes para a mesma entrada e a mesma versão de regras/modelos.	Reexecuções com o mesmo caso de teste e mesma versão devem gerar o mesmo conjunto de alertas e recomendações.
RNF06	Interoperabilidade	O sistema deve suportar ingestão de dados clínicos estruturados.	O protótipo deve importar corretamente os ficheiros/tabelas definidos para o <i>dataset</i> utilizado.
RNF07	Explicabilidade	O sistema deve apresentar justificações associadas aos resultados clínicos relevantes.	Alertas críticos e recomendações devem incluir raciocínio clínico e/ou referência documental.
RNF08	Manutenibilidade	O sistema deve permitir atualização das regras	As regras devem estar separadas do código

		clínicas sem alterar a lógica principal.	principal ou organizadas em módulo próprio.
--	--	--	---

3.4 Casos de Uso

O diagrama de casos de uso apresentado na Figura 3.4 representa, de forma sintética, os principais casos de uso do sistema e o ator que os desencadeia. O único ator externo identificado para o protótipo é o Profissional de Saúde, que interage diretamente com a interface do sistema. Os casos de uso cobrem os fluxos funcionais implementados: submissão de prescrições, seja por introdução manual ou por importação de contexto sintético (modo Synthea), consulta dos alertas e recomendações gerados, pedido de explicação em linguagem natural e registo de feedback. Os requisitos que suportam cada caso de uso são descritos na secção 3.2.




Figura 3.4 - Diagrama de casos de uso do sistema.

3.5 Modelo de Domínio

O modelo de domínio tem como finalidade representar os principais conceitos do sistema e as relações estabelecidas entre eles. Desta forma, este modelo descreve as entidades relevantes do problema e a forma como estas se articulam no contexto da análise de prescrições e da geração de alertas e recomendações. No sistema proposto, o domínio pode ser compreendido a partir de quatro núcleos principais: o perfil clínico do utente, a prescrição, o conhecimento farmacológico e os resultados da análise.

A Figura 3.5 apresenta o diagrama de classes UML do modelo de domínio do sistema proposto.




Figura 3.5 - Modelo de domínio (Diagrama de Classes) do sistema proposto.

As relações fundamentais do domínio organizam-se do seguinte modo: o Utente possui um Perfil Clínico, o qual agrega Condições Clínicas, Alergias, Observações Clínicas e Medicação Ativa. Sobre esse utente é emitida uma Prescrição, composta por uma ou mais Linhas de Prescrição, cada uma associada a um Medicamento. Durante a análise, a Prescrição é confrontada com as Regras Clínicas e com o conhecimento farmacológico disponível, nomeadamente Interações Medicamentosas e Contraindicações. Desse processo podem resultar Alertas, os quais, por sua vez, podem originar Recomendações. Tanto os alertas como as recomendações possuem uma Explicação associada, gerada pelo módulo LLM a partir dos resultados estruturados produzidos pelo motor de segurança clínica. Por fim, o profissional de saúde pode registar Feedback associado ao alerta ou recomendação analisado.

3.6 Cenários de Utilização

Os cenários de utilização descrevem, numa perspetiva dinâmica, as sequências de interações entre os atores e o sistema nas principais situações de uso. Para cada cenário, é apresentado um diagrama de sequência UML que ilustra a ordem das mensagens trocadas e as responsabilidades de cada componente. Os cenários apresentados correspondem aos fluxos de maior relevância funcional: a análise automática de uma prescrição, o registo de feedback por parte do profissional de saúde e o pedido de explicação LLM.




Figura 3.6.1 - Cenário 1: Análise de Prescrição (Diagrama de Sequência).

O primeiro cenário descreve o fluxo principal de análise de uma prescrição. O profissional de saúde submete, através da interface, a prescrição e o contexto clínico do utente. O

orquestrador valida e normaliza os dados de entrada, consolida o perfil clínico e invoca o motor de segurança clínica, responsável por executar as verificações determinísticas: alergias, interações medicamentosas, contraindicações e duplicações terapêuticas, produzindo alertas estruturados. O motor de recomendação recebe esses alertas e gera alternativas terapêuticas candidatas, ordenadas pelo modelo supervisionado de *ranking*. Por fim, o módulo LLM recebe o contexto estruturado da análise e produz uma explicação em linguagem natural. A resposta consolidada é devolvida ao *frontend* e registada na base de dados *SQLite* para fins de auditoria.




Figura 3.6.2 - Cenário 2: Registo de Feedback (Diagrama de Sequência).

O segundo cenário descreve o registo de feedback por parte do profissional de saúde. Após consultar os resultados da análise, o utilizador indica se aceitou, rejeitou ou ignorou um alerta ou recomendação apresentado. Esta decisão é enviada ao orquestrador, que a persiste no repositório operacional, associando-a ao resultado da análise previamente registado. O feedback recolhido é utilizado para fins de auditoria e poderá alimentar futuras iterações do modelo supervisionado.




Figura 3.5.3 - Cenário 3: Pedido de Explicação LLM (Diagrama de Sequência).

O terceiro cenário descreve o pedido de explicação em linguagem natural por parte do profissional de saúde. Este fluxo é opcional e independente da análise inicial, sendo desencadeado após a apresentação dos resultados. O profissional solicita explicitamente a explicação, que é gerada com base nos alertas e recomendações já produzidos. O sistema invoca o modelo de linguagem local (Ollama) com um *prompt* clínico estruturado; caso a resposta não cumpra os critérios de validação (língua, comprimento e ausência de *tokens* de raciocínio), é ativado um mecanismo de *fallback* determinístico que gera uma explicação estruturada a partir dos dados da análise. O resultado é apresentado ao utilizador sob a forma de texto em linguagem natural.

4 Arquitetura do Sistema

O presente capítulo descreve a arquitetura do sistema proposto, detalhando os seus componentes estruturais, as responsabilidades de cada módulo, os fluxos de dados *online* e *offline*, e as principais decisões de design que sustentam a solução. A arquitetura foi concebida de forma modular e sequencial, com separação explícita entre a camada de verificação clínica determinística, a camada de recomendação contextual e a camada de explicação em linguagem natural, assegurando rastreabilidade, extensibilidade e segurança na operação do sistema.

A solução é constituída por dois grandes subsistemas: um *backend* desenvolvido em Python com o *framework* FastAPI, responsável pela lógica de negócio, análise clínica e gestão de dados; e um *frontend* desenvolvido em React, que disponibiliza ao utilizador uma interface de interação para submissão de prescrições, consulta de alertas e recomendações, e registo de feedback. A comunicação entre ambos é realizada por uma API REST, com respostas em formato JSON.

4.1 Visão Geral

A arquitetura global do sistema segue um padrão em cascata, onde cada módulo produz resultados que são consumidos pelo módulo seguinte, garantindo que a decisão de recomendação é sempre subordinada às verificações determinísticas de segurança clínica. Este design assegura que nenhum medicamento alternativo é sugerido ao utilizador sem ter sido previamente avaliado pelo motor de regras, eliminando assim o risco de recomendações clinicamente inadmissíveis.

A Figura 4.1 ilustra a visão geral da arquitetura do sistema, representando os principais componentes e o sentido do fluxo de dados desde a submissão da prescrição pelo utilizador até à apresentação dos resultados.




Figura 4.1 - Visão geral da arquitetura do sistema.

O fluxo de execução online inicia-se na interface do utilizador, que submete a prescrição e o contexto clínico do utente ao *backend* através de um pedido HTTP POST. O módulo de orquestração recebe o pedido, normaliza os dados de entrada e coordena a execução sequencial dos módulos internos: o motor de segurança clínica, o motor de recomendação e, de forma assíncrona ou sob pedido explícito, o módulo de explicação baseado em LLM. O resultado consolidado é persistido numa base de dados SQLite e devolvido ao *frontend* para visualização.

4.2 Arquitetura Global

O sistema é estruturado em quatro camadas funcionais distintas, representadas na Figura 4.2: a camada de apresentação (frontend React), a camada de orquestração e API (FastAPI), a camada de lógica de negócio (motores de segurança, recomendação e explicação), e a camada de dados (bases de conhecimento, modelo supervisionado e repositório operacional SQLite).




Figura 4.2 - Diagrama de camadas da arquitetura global do protótipo.

A separação em camadas permite que cada componente seja desenvolvido, testado e substituído de forma independente. Em particular, a camada de lógica de negócio não possui dependências diretas do *frontend*, o que facilita a integração futura com outros clientes, como sistemas de informação hospitalar (HIS) ou plataformas de EHR. A camada de dados é partilhada entre os módulos de análise online e o pipeline offline de treino supervisionado, assegurando consistência nas representações de medicamentos, condições clínicas e padrões históricos.

A Tabela 4.2 resume as tecnologias adotadas em cada camada da arquitetura, indicando o componente, a tecnologia utilizada e a respetiva responsabilidade no sistema.

Tabela 4.2 – Tecnologias adotadas por camada da arquitetura.

Camada	Tecnologia	Responsabilidade
Apresentação	React 18 + Vite	Interface de utilizador; submissão de prescrições; visualização de alertas e recomendações
API / Orquestração	FastAPI (Python)	Exposição de endpoints REST; validação de pedidos; coordenação dos módulos internos
Segurança Clínica	Python (rules_engine.py)	Verificação determinística de interações, contraindicações e duplicações terapêuticas
Recomendação	Python (recommender.py)	Geração e scoring de alternativas terapêuticas candidatas
ML / Ranking	scikit-learn + joblib	Modelo supervisionado de ranking de candidatos (classificador multiclasse)
Explicação	Ollama + LLM local (Qwen3)	Geração de explicações em linguagem natural com fallback determinístico
Persistência	SQLite	Armazenamento de análises, feedback e métricas operacionais
Conhecimento	JSON (knowledge_base.json)	Base de conhecimento farmacológico: medicamentos, interações, classes terapêuticas
Dados Clínicos	Synthea (CSV)	Dados clínicos sintéticos para contexto de utentes e treino do modelo

4.3 Componentes do Sistema

Esta secção descreve em detalhe cada componente da arquitetura, apresentando as suas responsabilidades, interfaces e lógica interna. A Figura 4.3 apresenta o diagrama de componentes UML, evidenciando as dependências e o sentido do fluxo de informação entre os módulos.




Figura 4.3 - Diagrama de componentes da arquitetura do protótipo.

4.3.1 Módulo de Orquestração

O módulo de orquestração é implementado no ficheiro `main.py` e constitui o ponto de entrada de todos os pedidos ao sistema. É construído sobre o *framework* FastAPI, que disponibiliza validação automática dos modelos de dados de entrada (via Pydantic), documentação interativa da API (Swagger UI) e suporte a pedidos assíncronos. O módulo expõe um conjunto de *endpoints* REST que cobrem os principais fluxos de interação com o sistema.

O orquestrador disponibiliza três categorias de *endpoints*: análise de prescrições (em modo manual e em modo Synthea), registo de feedback do profissional de saúde, e geração de

explicações em linguagem natural via LLM. Esta interface única concentra todas as decisões de encaminhamento e isola a lógica de negócio de quaisquer detalhes de transporte. A especificação completa dos *endpoints*, incluindo métodos HTTP, parâmetros e contratos de dados, é apresentada no Capítulo 5.

Antes de invocar os módulos internos, o orquestrador executa uma etapa de normalização do problema clínico principal (*main_problem*), mapeando variantes textuais para identificadores canônicos (e.g., "dor" → "pain", "hipertensão arterial" → "hypertension"). Esta normalização é essencial para garantir a consistência dos resultados entre a camada de segurança clínica, o motor de recomendação e o módulo LLM. Adicionalmente, quando o feedback submetido inclui uma alternativa terapêutica proposta pelo profissional, o orquestrador avalia automaticamente essa alternativa através do motor de segurança clínica, devolvendo os alertas identificados e uma mensagem explicativa sobre a admissibilidade da proposta.

O *startup* do servidor FastAPI desencadeia a inicialização da base de dados SQLite, garantindo que as tabelas de análises e feedback existem antes de qualquer pedido ser processado. Cada análise completada é persistida com um identificador UUID único (*analysis_id*), que serve de chave de associação para o feedback e para a explicação LLM subsequentes, assegurando uma rastreabilidade completa de cada ciclo de decisão.

4.3.2 Motor de Segurança Clínica

O motor de segurança clínica, implementado em *rules_engine.py*, é responsável pela verificação determinística da prescrição face ao contexto clínico do utente e à base de conhecimento farmacológico. A sua execução é sempre prioritária e não pode ser contornada por outros módulos: qualquer candidato que gere alertas de severidade elevada ("high") ou crítica ("critical") é automaticamente excluído do processo de recomendação, garantindo que a segurança clínica é uma barreira rígida e não uma dimensão ponderável.

O motor executa quatro categorias de verificação, conforme apresentado na Tabela 4.3.2: deteção de medicamentos desconhecidos, verificação de contraindicações e precauções renais, deteção de interações medicamentosas e verificação da associação de risco *triple whammy*, que identifica a combinação perigosa de diuréticos, anti-inflamatórios e anti-hipertensores que risco de lesão renal aguda. Cada verificação produz objetos de alerta estruturados, com campos que incluem o tipo, severidade, descrição, origem (prescrição, medicação ativa ou risco combinado), identificadores dos medicamentos envolvidos e um identificador de regra (*rule_id*) para rastreabilidade.

Tabela 4.3.2 - Verificações executadas pelo motor de segurança clínica.

Verificação	Função	Severidade possível
Medicamento desconhecido	Identifica medicamentos não reconhecidos pela base de conhecimento do protótipo	low
Contraindicações e precauções renais	Verifica se a prescrição está contraindicada para condições clínicas do utente; emite alerta de precaução renal em caso de compromisso renal grave	critical / high
Interações medicamentosas	Avalia pares de medicamentos (prescritos e ativos no utente) face a regras de interação por par de fármacos, classe terapêutica ou risco QT; seleciona o alerta de maior especificidade e severidade por par	moderate / high / critical
<i>Triple whammy</i>	Deteta a associação simultânea de AINE, IECA/ARA e diurético, associada a risco aumentado de deterioração renal aguda	high

A classificação da origem de cada alerta é determinada automaticamente com base na proveniência dos medicamentos envolvidos: se pelo menos um dos medicamentos pertence à prescrição submetida, o alerta é classificado como "prescription_related"; se ambos pertencem à medicação ativa pré-existente, é classificado como "active_medication_existing"; nos restantes casos, como "combined_profile_risk". Esta distinção permite ao utilizador compreender de imediato a natureza de cada problema identificado e priorizar a sua resposta clínica.

Para as interações medicamentosas, o motor implementa um mecanismo de deduplicação por par: quando múltiplas regras se aplicam ao mesmo par de medicamentos, apenas é emitido o alerta de maior severidade e especificidade, evitando a proliferação de alertas redundantes que contribuiriam para a fadiga de alertas.

4.3.3 Motor de Recomendação

O motor de recomendação, implementado em `recommender.py`, é ativado exclusivamente quando o motor de segurança clínica identifica pelo menos um alerta de severidade moderada, elevada ou crítica com origem na prescrição submetida. A sua função é gerar e ordenar alternativas terapêuticas clinicamente admissíveis, num processo estruturado em três etapas: geração de candidatos, filtragem por segurança e *scoring* multidimensional.

A geração de candidatos parte da lista de alternativas definidas na base de conhecimento para cada medicamento prescrito. São excluídos os candidatos que já constam da medicação ativa do utente, evitando recomendações redundantes. Cada candidato é então reavaliado pelo motor de segurança clínica: os que apresentam alertas de severidade "high" ou "critical" são eliminados, constituindo a barreira determinística da recomendação. Adicionalmente, se existir pelo menos um candidato sem alertas de severidade moderada ou superior, os candidatos com

alertas moderados são também descartados, privilegiando as alternativas mais seguras disponíveis.

O *scoring* de cada candidato admissível resulta da composição de quatro dimensões clínicas: segurança farmacológica, adequação ao contexto clínico, proximidade terapêutica e histórico de feedback, combinadas com a contribuição do modelo supervisionado de *ranking*. Esta abordagem híbrida garante que os critérios de segurança predominam sobre a similaridade ou a popularidade, e permite que o sistema melhore progressivamente com o feedback acumulado. A formulação quantitativa das dimensões de *scoring* e os respectivos pesos são detalhados no Capítulo 5.

Numa etapa de refinamento secundário, quando dois ou mais candidatos apresentam *scores* muito próximos ($< 0,05$), o sistema recorre ao *score* histórico observado em padrões de prescrição com perfil de utente semelhante (mesmo grupo etário, função renal e problema clínico) para desempate, com um peso adicional de 0,05. Esta abordagem preserva a prioridade das dimensões clínicas e utiliza a informação histórica do *dataset* apenas como critério de desempate secundário.

O motor incorpora ainda um tratamento de nuance clínica extra: quando o paracetamol emerge como candidato em contexto de inflamação após prescrição de um AINE, os *scores* de adequação contextual e proximidade terapêutica são reduzidos, e é adicionada uma razão explicativa que esclarece que o paracetamol constitui uma alternativa sintomática e analgésica, e não um substituto anti-inflamatório equivalente.

4.3.4 Módulo de Aprendizagem Supervisionada

O módulo de aprendizagem supervisionada, implementado em `ml_model.py`, disponibiliza um classificador multiclasse que prevê a adequação terapêutica de um candidato medicamentoso para o contexto clínico do utente. O modelo é carregado em memória uma única vez por sessão (através de `@lru_cache`) e persiste entre pedidos, evitando *overhead* desnecessário de leitura do disco.

O modelo é treinado *offline* com exemplos gerados a partir das combinações de candidatos e contextos clínicos avaliados pelo motor de segurança clínica, e rotulados com três classes: 0 (não admissível), 1 (admissível com precaução) e 2 (admissível). O *score* de adequação é calculado a partir das probabilidades de classe, ponderadas pelos pesos 0,00, 0,60 e 1,00, respetivamente, produzindo um valor contínuo entre 0 e 1 que representa a probabilidade ponderada de admissibilidade clínica do candidato.

O modelo recebe como entrada um conjunto de *features* numéricas e categóricas que capturam o perfil clínico do utente e as propriedades do candidato terapêutico, produzindo uma estimativa de adequação em três níveis. A lista completa de *features* e o processo de treino são descritos no Capítulo 5.

O processo de construção do *dataset* de treino segue uma abordagem de rótulos fracos (*silver labels*) seguida de revisão humana (*golden labels*). Numa primeira fase, o motor de segurança

clínica é aplicado a todas as combinações candidato-contexto geradas a partir dos dados *Synthea*, atribuindo automaticamente rótulos com base nos alertas produzidos. Numa segunda fase, os exemplos mais representativos ou ambíguos são exportados para revisão humana pelo desenvolvedor, que valida ou corrige os rótulos automáticos. Os dados revistos são utilizados para treino final do modelo, garantindo que a supervisão humana calibra o classificador face às nuances clínicas que as regras automáticas não capturam com precisão suficiente.

4.3.5 Módulo de Explicação LLM

O módulo de explicação LLM, implementado em `llm_explainer.py`, gera explicações em linguagem natural para os resultados da análise clínica, tornando o raciocínio do sistema compreensível para o profissional de saúde. Este módulo não participa na decisão clínica: é invocado exclusivamente após a produção dos alertas e recomendações, operando sobre resultados já validados pelo motor de segurança clínica.

A comunicação com o modelo de linguagem é realizada via API local Ollama, utilizando por omissão o modelo `Qwen3:4b-instruct`. O sistema constrói um *prompt* estruturado que inclui o contexto clínico do utente, os alertas identificados (ordenados por severidade decrescente), as recomendações geradas e o estilo de explicação esperado, fornecido através de exemplos *few-shot*. O *prompt* instrui o modelo a gerar uma explicação organizada em quatro secções: problema identificado, motivo do alerta, motivo da recomendação e limitações.

A resposta do LLM é sujeita a validação linguística e estrutural antes de ser devolvida ao utilizador. São verificadas a linguagem da resposta (PT-PT), o comprimento mínimo e máximo, e a ausência de indicadores de raciocínio interno (ex: *tokens* de "thinking"). Caso a validação falhe, o sistema ativa automaticamente um mecanismo de *fallback* determinístico, que gera uma explicação estruturada diretamente a partir dos dados da análise, sem recurso ao LLM. O utilizador é informado da utilização deste mecanismo através de uma nota técnica visível na interface. A Figura 4.4 ilustra o fluxo de invocação do módulo LLM e a lógica de *fallback*.




Figura 4.3.5 - Fluxo de invocação do módulo LLM e mecanismo de fallback.

O módulo suporta ainda um modo de pergunta livre (*user_question*), que permite ao profissional de saúde formular uma questão específica sobre a análise. Neste caso, o *prompt* é adaptado para incorporar a questão e o modelo é instruído a responder de forma direta e contextualizada, mantendo o enquadramento clínico. A separação entre o módulo de explicação e os módulos de decisão garante que eventuais falhas ou alucinações do LLM não comprometem a validade clínica dos alertas e recomendações já produzidos.

4.3.6 Camada de Persistência e Dados

A camada de persistência e dados é composta por três elementos: a base de dados operacional SQLite, a base de conhecimento farmacológico em formato JSON e o índice de utentes Synthea em formato CSV.

A base de dados operacional, gerida pelo módulo `database.py`, armazena dois tipos de registos: análises e *feedback*. A tabela de análises guarda, por cada pedido processado, o identificador único (`analysis_id`), o identificador do utente, a origem do pedido ("manual" ou "synthea"), o *timestamp* em UTC, o *payload* completo do pedido, os alertas e recomendações gerados em formato JSON, a explicação textual e o tempo de resposta em milissegundos. A tabela de *feedback* regista, por cada decisão do profissional, o `feedback_id`, o `analysis_id` associado, a decisão tomada ("accepted", "rejected" ou "ignored"), o medicamento ou recomendação em causa, um comentário opcional, a alternativa terapêutica proposta pelo profissional e o resultado da avaliação automática dessa alternativa.

A base de conhecimento farmacológico (`knowledge_base.json`) codifica, para cada medicamento, os atributos relevantes para a análise clínica: substância ativa, nome de apresentação, classe terapêutica, indicações, contraindicações, precaução renal, risco QT e lista de alternativas terapêuticas. As regras de interação medicamentosa são igualmente codificadas neste ficheiro, com suporte para três tipos de correspondência: por par de fármacos específicos (drug-drug), por par de classes terapêuticas (class-class) e por combinação de classe e fármaco (class-drug).

O índice Synthea (`synthea_context_index.csv`), construído por um *script offline* a partir dos dados exportados pela ferramenta Synthea, agrega por utente as condições clínicas normalizadas, as alergias, a medicação ativa, o estado renal estimado e uma sugestão automática do problema clínico principal. Este índice é utilizado pelo módulo `synthea_loader.py` para reconstruir o contexto clínico completo de um utente a partir do seu identificador, sem necessidade de reprocessar os dados Synthea em tempo real.

4.3.7 Interface de Utilizador

A interface de utilizador, desenvolvida em React 18 com Vite, constitui a camada de apresentação do sistema. Organiza-se em dois modos de submissão: introdução manual e carregamento de contexto (histórico) clínico Synthea, e apresenta os resultados da análise de forma progressiva: alertas, recomendações e explicação LLM. A implementação detalhada da interface é descrita no Capítulo 5.

4.4 Fluxo de Dados Online

O fluxo de dados *online* corresponde ao ciclo completo de análise de uma prescrição em tempo real, desde a submissão pelo utilizador até à apresentação dos resultados e ao registo de

feedback. A Figura 4.4 apresenta o diagrama de sequência UML que descreve este fluxo em detalhe.




Figura 4.4 - Diagrama de sequência do fluxo de análise online.

O fluxo inicia-se quando o profissional de saúde submete a prescrição e o contexto clínico do utente através da interface. O orquestrador recebe o pedido, valida o *schema* de entrada (via Pydantic) e normaliza o problema clínico principal. Em seguida, carrega a base de conhecimento farmacológico e os padrões históricos, e invoca o motor de segurança clínica com o contexto normalizado.

O motor de segurança clínica executa sequencialmente as verificações de medicamentos desconhecidos, contraindicações e precauções renais, interações medicamentosas e associação *triple whammy*, produzindo uma lista de alertas estruturados. Esta lista é devolvida ao orquestrador, que a passa ao motor de recomendação. Se existirem alertas de severidade moderada, elevada ou crítica com origem na prescrição, o motor de recomendação gera candidatos, filtra os inadmissíveis e calcula os *scores* de cada alternativa, integrando a contribuição do modelo supervisionado. A resposta consolidada (*analysis_id*, alertas,

recomendações e explicação determinística preliminar) é persistida na base de dados e devolvida ao *frontend*.

O profissional pode solicitar uma explicação aprofundada via LLM, que constitui um pedido separado ao *endpoint* /explain/llm. O módulo LLM recupera o registo da análise da base de dados, constrói o *prompt* e invoca o modelo local via Ollama.

A explicação gerada, ou o *fallback* determinístico em caso de falha de validação da explicação do LLM, é devolvida ao *frontend* e apresentada ao utilizador. O registo de feedback constitui um terceiro pedido independente, que persiste a decisão do profissional e, quando aplicável, avalia automaticamente a alternativa terapêutica proposta.

4.5 Fluxo Offline de Treino e Validação

O fluxo *offline* de treino e validação é o processo pelo qual o modelo de aprendizagem supervisionada é construído e atualizado a partir dos dados disponíveis. Este fluxo é independente do ciclo de análise *online* e pode ser executado periodicamente para incorporar novos exemplos revistos. A Figura 4.5 ilustra as etapas deste fluxo.




Figura 4.5 - Fluxo offline de treino e validação do modelo supervisionado.

O fluxo inicia-se com a geração de combinações candidato-contexto a partir do índice Synthea e da base de conhecimento farmacológico. Cada combinação é avaliada pelo motor de segurança clínica, produzindo rótulos automáticos que classificam a adequação terapêutica de cada candidato. Numa fase seguinte, os rótulos são submetidos a revisão humana para corrigir casos limítrofes, gerando o *dataset* final com *golden labels*. Com este *dataset*, é treinado e serializado o modelo de ranking supervisionado (`ranking_model.joblib`), que é carregado em memória pelo módulo `ml_model.py` em tempo de execução. Os detalhes quantitativos do processo de treino e os resultados de avaliação são apresentados no Capítulo 5.

4.6 Decisões Arquiteturais

Esta secção documenta as principais decisões de *design* arquitetural tomadas no desenvolvimento do protótipo, contextualizando as alternativas consideradas e as justificações técnicas e clínicas subjacentes a cada escolha.

A primeira decisão diz respeito à prioridade da camada de regras determinísticas sobre o módulo de aprendizagem automática. Em sistemas de apoio à decisão clínica, a interpretabilidade e a previsibilidade do comportamento do sistema são requisitos críticos. A adoção de uma arquitetura em cascata, onde o motor de regras opera como barreira rígida e o modelo supervisionado apenas influencia o ranking das alternativas pré-aprovadas, garante que o sistema nunca recomenda um medicamento clinicamente inadmissível, independentemente do *score* previsto pelo modelo. Esta abordagem é consistente com as recomendações da literatura sobre sistemas híbridos de CDSS e com as exigências regulatórias aplicáveis a sistemas de suporte à decisão médica.

A segunda decisão refere-se à separação explícita entre o módulo de explicação LLM e os módulos de decisão clínica. O LLM opera exclusivamente sobre resultados já produzidos e validados, e a sua falha (seja por indisponibilidade do serviço Ollama, por resposta em linguagem errada ou por resposta clinicamente inadequada) nunca compromete a disponibilidade ou a validade dos alertas e recomendações. O mecanismo de *fallback* determinístico garante que o utilizador recebe sempre uma explicação estruturada, mesmo na ausência de conectividade com o modelo local.

A terceira decisão é a utilização de SQLite como base de dados operacional. Para um protótipo de investigação, o SQLite oferece as vantagens da simplicidade de configuração, da portabilidade (base de dados num único ficheiro) e da ausência de dependências externas. A estrutura relacional adotada suporta as necessidades de rastreabilidade e auditoria do protótipo, nomeadamente a associação entre análises, feedback e alternativas avaliadas. Em cenário de produção, a migração para um sistema de gestão de base de dados relacional mais robusto (e.g., PostgreSQL) não implicaria alterações à lógica de negócio, dado o isolamento da camada de persistência de dados.

A quarta decisão refere-se à representação da base de conhecimento farmacológico em formato JSON. Esta escolha foi motivada pela legibilidade e facilidade de edição incremental durante o desenvolvimento, pela ausência de *overhead* de infraestrutura e pela

compatibilidade direta com as estruturas de dados Python utilizadas nos módulos de análise. Em contrapartida, esta abordagem limita a escalabilidade a grandes bases de conhecimento e dificulta a incorporação de raciocínio ontológico complexo. A integração futura com padrões de interoperabilidade farmacológica (e.g., terminologias SNOMED CT, RxNorm ou ATC) constituiria uma evolução natural desta componente.

A quinta decisão relevante diz respeito à utilização de dados sintéticos Synthea em detrimento de dados clínicos reais. Esta opção foi determinada por razões éticas, legais e práticas: o acesso a dados de saúde identificáveis implica aprovação de comissões de ética, acordos de partilha de dados e procedimentos de anonimização rigorosos, incompatíveis com o contexto e horizonte temporal de um protótipo de dissertação de mestrado. Os dados Synthea, gerados por simulação estatística de populações clínicas reais, permitem validar a viabilidade técnica e metodológica da solução proposta sem comprometer a segurança ou a privacidade de indivíduos reais.

5 Implementação

O presente capítulo descreve em detalhe o desenvolvimento do protótipo, abrangendo as tecnologias adotadas, a implementação do *backend* e do *frontend*, a integração do modelo de linguagem de grande dimensão e a integração dos dados clínicos sintéticos utilizados no treino e na validação do sistema. A exposição complementa a vista arquitetural do Capítulo 4, focando-se nas decisões de implementação concretas, nas estruturas de código produzidas e nos resultados obtidos em cada componente.

5.1 Tecnologias Utilizadas

A seleção das tecnologias seguiu três critérios principais: adequação ao domínio (suporte a validação de dados estruturados, integração com LLMs locais e compatibilidade com *pipelines* de *machine learning* em Python), maturidade e documentação da comunidade, e leveza de infraestrutura, dado o contexto de protótipo de investigação sem servidor dedicado. A Tabela 5.1 apresenta as tecnologias utilizadas em cada camada do sistema.

Tabela 5.1 - Tecnologias utilizadas por camada do sistema.

Camada	Tecnologia	Versão	Papel no sistema
Runtime backend	Python	3.12	Linguagem principal do <i>backend</i>
Framework API	FastAPI + Uvicorn	Atual	Exposição de <i>endpoints</i> REST e servidor ASGI
Validação de dados	Pydantic	v2	Modelos de dados com validação automática
Machine Learning	scikit-learn	Atual	Treino e avaliação do classificador de <i>ranking</i>
Serialização ML	joblib	Atual	Persistência e carregamento do modelo treinado

Manipulação de dados	pandas	Atual	Processamento do índice Synthea e <i>datasets</i> de treino
Cliente HTTP	httpx	Atual	Comunicação com a API Ollama (síncrona)
Base de dados	SQLite (stdlib)	—	Persistência de análises e feedback
LLM local	Ollama	Atual	Plataforma de execução de modelos LLM localmente
Modelo LLM	Qwen3:4b-instruct	Atual	Geração de explicações em linguagem natural
Frontend	React 18 + Vite	18 / Atual	Interface de utilizador (SPA)
Dados sintéticos	Synthea	4.0.0	Geração de populações clínicas sintéticas

5.2 Backend

O *backend* foi desenvolvido em Python 3.12, estruturado como uma aplicação FastAPI com separação entre os módulos de orquestração, lógica de negócio, persistência e carregamento de dados. A Figura 5.2 apresenta a estrutura de diretórios do *backend*, evidenciando a organização dos módulos e dos artefactos de dados.




Figura 5.2 - Estrutura de diretórios do Protótipo.

5.2.1 Modelos de Dados (schemas.py)

Os modelos de dados são definidos com Pydantic v2 em schemas.py, garantindo validação automática de todos os pedidos e respostas da API. O modelo central de entrada é o PatientContext, que encapsula o identificador do utente, a idade, o sexo, as condições clínicas, as alergias, a medicação ativa e o estado renal. A prescrição é representada por uma lista de objetos MedicationLine, cada um com medicamento, dose, frequência e via de administração. O modelo de resposta AnalyzeResponse consolida o identificador da análise, os alertas, as recomendações, as notas de recomendação e a explicação textual preliminar.

A modelação de alertas (Alert) inclui campos para tipo, severidade (low / moderate / high / critical), medicamento envolvido, descrição clínica, origem (prescription_related / active_medication_existing / combined_profile_risk), flags de envolvimento na prescrição e na medicação ativa, identificador de regra (rule_id) e lista de identificadores de medicamentos envolvidos. Esta estrutura permite ao *frontend* filtrar, agrupar e apresentar os alertas de forma contextualizada, sem necessidade de processamento adicional. A Tabela 5.2.1 resume os modelos Pydantic definidos e as suas responsabilidades.

Tabela 5.2.1 - Modelos Pydantic definidos em schemas.py.

Modelo	Sentido	Campos principais
PatientContext	Entrada	patient_id, age, sex, conditions, allergies, active_medications, renal_status, main_problem
MedicationLine	Entrada	medication, dose, frequency, route
PrescriptionRequest	Entrada (POST /analyze)	patient: PatientContext, prescription: List[MedicationLine]
SyntheaAnalyzeRequest	Entrada (POST /analyze/synthea)	patient_id, main_problem, prescription
Alert	Saída	type, severity, medication, description, origin, rule_id, medication_ids
Recommendation	Saída	medication, score_base, score_final, reasons, secondary_historical_score
AnalyzeResponse	Saída	analysis_id, alerts, recommendations, recommendation_notes, explanation
FeedbackRequest	Entrada (POST /feedback)	analysis_id, patient_id, medication, decision, comment, user_alternative
FeedbackResponse	Saída	feedback_id, analysis_id, saved, alternative_evaluation
LLMExplanationRequest	Entrada (POST /explain/llm)	analysis_id, user_question
LLMExplanationResponse	Saída	analysis_id, model, explanation, fallback_used, fallback_notice

5.2.2 Base de Conhecimento Farmacológico (knowledge_base.json)

A base de conhecimento farmacológico é implementada em formato JSON (knowledge_base.json) e carregada em memória a cada pedido via data_loader.py. Na versão

atual do protótipo, contém 20 medicamentos (Tabela 5.2.2) e 19 regras de interação, cobrindo 14 classes terapêuticas.

Cada entrada de medicamento especifica: `display_name` (nome de apresentação), `active_substance` (princípio ativo), `therapeutic_class` (classe terapêutica), `indications` (lista de problemas clínicos), `contraindicated_conditions` (contraindicações), `renal_caution` (risco renal - booleano), `qt_risk` (risco QT - booleano), `renal_alert_severity` (severidade renal) e `alternatives` (lista de identificadores de alternativas).

Tabela 5.2.2 - Classes terapêuticas codificadas na base de conhecimento farmacológico.

Identificador interno	Designação	Medicamentos
aine	Anti-inflamatório não esteroide	Ibuprofeno, Naproxeno
analgesico_antipiretico	Analgésico/antipirético	Paracetamol
antiagregante	Antiagregante plaquetário	Ácido acetilsalicílico, Clopidogrel
antiarritmico_classe_iii	Antiarrítmico classe III	Amiodarona
anticoagulante	Anticoagulante oral	Varfarina
antidepressivo_triciclico	Antidepressivo tricíclico	Amitriptilina
ara	Antagonista dos recetores da angiotensina (ARA)	Losartan, Valsartan
digitalico	Digitálico	Digoxina
diuretico_ansa	Diurético de ansa	Furosemida
diuretico_tiazidico	Diurético tiazídico	Hidroclorotiazida
estatina	Estatina (inibidor HMG-CoA redutase)	Sinvastatina, Atorvastatina
ieca	Inibidor da enzima de conversão da angiotensina	Enalapril, Ramipril
isrs	Inibidor seletivo da recaptação de serotonina	Sertralina
macrolido	Macrólido	Azitromicina, Claritromicina

Cada regra de interação especifica o tipo de correspondência (`class_class`, `drug_drug`, `class_drug` ou `qt_qt`), os intervenientes, a severidade e descrição do alerta gerado.

5.2.3 Normalização de Entradas (normalization.py)

O módulo `normalization.py` resolve a variabilidade terminológica dos dados de entrada através de dois dicionários de sinónimos: `MEDICATION_SYNONYMS` e `CONDITION_SYNONYMS`.

O primeiro mapeia 20 fármacos, suportando designações em português e inglês, nomes comerciais, abreviaturas e combinações com dosagem (e.g., "Ibuprofen 400 MG Oral Tablet [Ibu]", "ibuprofeno", "ibuprofen 400 mg" → "ibuprofen"). A função `normalize_medication_id` aplica ainda pré-processamento de texto (conversão para minúsculas, remoção de acentuação e pontuação) antes de consultar o mapeamento, garantindo robustez perante variantes de formatação.

O `CONDITION_SYNONYMS` cobre os problemas clínicos suportados em português e inglês (e.g., "dor", "dor aguda" → "pain"). Esta normalização é fundamental para a interoperabilidade com dados Synthea, que exporta designações no formato RxNorm (e.g., "Clopidogrel 75 MG Oral Tablet").

5.2.4 Motor de Segurança Clínica (rules_engine.py)

O motor de segurança clínica implementa quatro funções de verificação sequencialmente invocadas pela função principal `run_safety_checks`: `check_unknown_medications`, `check_contraindications`, `check_interactions` e `check_triple_whammy`. Cada função produz objetos `Alert` estruturados, sendo os resultados consolidados e devolvidos como lista ao orquestrador.

A verificação de interações (`check_interactions`) implementa um algoritmo de deduplicação por par: para cada combinação de dois medicamentos (do conjunto de medicamentos ativos + prescritos), são aplicadas todas as regras elegíveis, sendo retido apenas o alerta da regra de maior severidade e especificidade. A especificidade segue a ordem `drug_drug > class_drug > class_class > qt_qt`, o que garante que regras mais específicas prevaleçam sobre regras de classe.

A classificação da origem de cada alerta (`prescription_related`, `active_medication_existing` ou `combined_profile_risk`) é determinada pela função `classify_pair_origin`, que verifica se pelo menos um medicamento pertence à prescrição submetida ou apenas à medicação pré-existente. A Figura 5.2.4 apresenta o diagrama de atividades do motor de segurança clínica.




Figura 5.2.4 - Diagrama de atividades do Motor de Segurança.

5.2.5 Motor de Recomendação (recommender.py)

O motor de recomendação é implementado em `recommender.py` e estrutura-se em cinco fases: verificação do gatilho, geração de candidatos, filtragem por segurança, *scoring* multidimensional e refinamento histórico. O gatilho é ativado quando existem alertas de severidade moderada, elevada ou crítica com origem na prescrição (`is_prescription_related_alert`). Os candidatos são gerados a partir do campo `alternatives` de cada medicamento prescrito na base de conhecimento, excluindo os que já constam da medicação ativa (`is_candidate_already_active`).

A filtragem aplica a barreira determinística: candidatos com alertas `high` ou `critical` são eliminados (`has_blocking_alert`). Se existir pelo menos um candidato sem alertas moderados, os candidatos com alertas moderados são também descartados. A função `score_candidate_base` calcula o `score` base de cada candidato admissível através da fórmula:

$$\text{score_base} = 0,45 \times \text{Sseg} + 0,30 \times \text{Sctx} + 0,20 \times \text{Ssim} + 0,05 \times \text{Sfb} \quad (x)$$

onde:

- `Sseg` representa a segurança clínica (parte de 1,0, penalizada por precaução renal grave e contraindicações);
- `Sctx` a adequação contextual ao problema clínico (base 0,5, incrementada em 0,4 se o candidato tem indicação para o problema principal);
- `Ssim` a proximidade terapêutica (1,0 se mesma classe do medicamento original, 0,7 se classe diferente com indicação compatível);
- `Sfb` o feedback histórico (*placeholder* em 0,05 nesta versão).

O `score` base é depois combinado com o `score` previsto pelo modelo supervisionado de *ranking* (30% de peso): `score_final = 0,70 \times \text{score\_base} + 0,30 \times \text{score\_ML}` (x).

Adicionalmente, a função `apply_secondary_historical_refinement` desempata candidatos com `scores` muito próximos (diferença $\leq 0,05$) com base em padrões históricos de aceitação para grupos de utentes com perfil semelhante.

O ficheiro `historical_patterns.json` regista padrões de aceitação de alternativas terapêuticas agregados por perfil de utente (faixa etária, sexo, estado renal e problema clínico principal). Na versão atual do protótipo, este ficheiro serve como fonte de desempate secundário no *scoring* do motor de recomendação e é populado com dados agregados do feedback registado na base de dados SQLite.

O motor inclui ainda um tratamento de nuance clínica: quando o paracetamol emerge como candidato em contexto de inflamação após prescrição de um AINE (`is_symptomatic_analgesic_fallback`), os `scores` `Sctx` e `Ssim` são limitados a 0,45 e é adicionada uma razão explicativa que distingue o paracetamol como alternativa sintomática e não como substituto anti-inflamatório equivalente.

5.2.6 Camada de Persistência (database.py)

A persistência operacional é gerida pelo módulo `database.py` através de SQLite, com duas tabelas principais. A tabela `analyses` armazena, por cada análise, o `analysis_id` (UUID único), o `patient_id`, a origem do pedido (manual ou synthea), o timestamp em UTC, o payload completo do pedido em JSON, os alertas e recomendações serializados em JSON, a explicação textual e o tempo de resposta em milissegundos. A tabela `feedback` regista as decisões do profissional (`accepted` / `rejected` / `ignored`), associadas ao `analysis_id` correspondente, com campos opcionais para comentário, alternativa proposta e resultado da avaliação automática dessa alternativa.

O *endpoint* `GET /metrics` agrega estas tabelas e devolve estatísticas operacionais (total de análises, distribuição de feedback por decisão, taxa de aceitação, tempo médio de resposta e distribuição de alertas por severidade e tipo).

5.3 Frontend

A interface de utilizador foi desenvolvida como uma aplicação React 18 de página única (SPA), utilizando Vite como ferramenta de *build*. A escolha do Vite justifica-se pelo arranque rápido do servidor de desenvolvimento, pelo suporte nativo a módulos ES e pela simplicidade de configuração face a alternativas como Create React App. O ficheiro de entrada é `index.html`, com ponto de montagem React em `main.jsx`. Toda a lógica de interface está concentrada em `App.jsx`, opção deliberada para um protótipo de investigação onde a modularidade em múltiplos componentes do *frontend* não traria benefícios práticos.

5.3.1 Estrutura e Modos de Operação

A interface organiza-se em torno de dois modos de submissão de prescrições, controlados por abas: o modo de introdução manual e o modo Synthea. No modo manual, o profissional preenche diretamente os campos de contexto clínico (ID do utente, idade, sexo, condições, alergias, medicação ativa, estado renal e problema clínico principal) e os campos de prescrição (medicamento, dose, frequência e via). Os campos de contexto aceitam múltiplos valores separados por vírgula, que são processados pela função `parseList` antes de serem enviados. É disponibilizado um botão de preenchimento com dados de exemplo (`EXAMPLE_PATIENT` / `EXAMPLE_PRESCRIPTION`) para facilitar a demonstração do sistema.

No modo Synthea, a interface consulta o *endpoint* `GET /synthea/patients` com filtros configuráveis (apenas adultos, apenas utentes com medicação ativa) e apresenta uma lista de utentes disponíveis do *dataset*. Ao selecionar um utente, os campos de contexto clínico são preenchidos automaticamente com os dados do índice Synthea. A prescrição continua a ser introduzida manualmente, permitindo explorar diferentes combinações medicamento-contexto. A Figura 5.3.1 apresenta capturas de ecrã da interface, ilustrando os dois modos de operação e a apresentação dos resultados.

PROTÓTIPO DE APOIO À DECISÃO CLÍNICA

Sistema de Recomendação e Alertas de Prescrição

Análise de prescrição, alertas de segurança clínica, recomendações terapêuticas e registo de feedback do profissional de saúde.

1 Dados do utente

Usar utente Synthea

Inserção manual

Neste modo, o sistema constrói automaticamente idade, sexo, estado renal, alergias e medicação ativa a partir do índice Synthea. Indicar apenas o ID do utente, o problema clínico principal e a prescrição a analisar.

IdentificadorEx.: 1e154a40-6620-e696-d29c-ead7db18c8a2

IdadeEx.: 27

SexoSelecionar...

Estado renalSelecionar...

Problema clínico principalEx.: dor, infeção bacteriana, hipertensão arterial

Condições clínicasSeparar por vírgulas. Ex.: heart_failure, diabetes

2 Prescrição a analisar

MedicamentoEx.: ibuprofen, naproxen, clarithromycin

DoseEx.: 400mg

FrequênciaEx.: 8/8h, 12/12h, 1x/dia

ViaEx.: oral

Analisar prescrição

PROTÓTIPO DE APOIO À DECISÃO CLÍNICA

Sistema de Recomendação e Alertas de Prescrição

Análise de prescrição, alertas de segurança clínica, recomendações terapêuticas e registo de feedback do profissional de saúde.

1 Dados do utente

Usar utente Synthea

Inserção manual

IdentificadorEx.: 1e154a40-6620-e696-d29c-ead7db18c8a2

IdadeEx.: 27

SexoSelecionar...

Estado renalSelecionar...

Problema clínico principalEx.: dor, infeção bacteriana, hipertensão arterial

Condições clínicasSeparar por vírgulas. Ex.: heart_failure, diabetes

AlergiasSeparar por vírgulas

2 Prescrição a analisar

MedicamentoEx.: ibuprofen, naproxen, clarithromycin

DoseEx.: 400mg

FrequênciaEx.: 8/8h, 12/12h, 1x/dia

ViaEx.: oral

Analisar prescrição

Figura 5.3.1 – Interface de utilizador do protótipo: a) Utente Synthea; b) Inserção manual.

5.3.2 Apresentação de Resultados e Mecanismo de Feedback

A explicação LLM é solicitada de forma explícita, através de um botão dedicado, que envia um pedido ao *endpoint* POST `/explain/llm` com o `analysis_id` da análise corrente e uma questão de contexto padrão. Quando o módulo usa o *fallback* determinístico, a interface exibe a nota técnica (`fallback_notice`) de forma visível.

O formulário de feedback permite ao profissional registrar a decisão sobre cada alerta ou recomendação (aceite, rejeitada ou ignorada), com campos opcionais para comentário e, no caso de rejeição de recomendação, para proposta de alternativa terapêutica com justificação. Quando uma alternativa é proposta, o sistema avalia-a automaticamente através do motor de segurança clínica e apresenta os alertas identificados na resposta, informando se a proposta apresenta problemas clínicos conhecidos na base de conhecimento atual.

5.4 Integração de LLM

A integração do modelo de linguagem é realizada através da plataforma Ollama, que permite executar modelos LLM localmente sem dependências de serviços externos. A escolha do Ollama foi motivada por três fatores: a confidencialidade dos dados clínicos processados (que não são enviados a APIs remotas), a ausência de custos por pedido e a facilidade de substituição do modelo subjacente sem alterações ao código (configurável via variável de ambiente `OLLAMA_MODEL`). O modelo por omissão é o Qwen3:4b-instruct, selecionado pelo equilíbrio entre capacidade de raciocínio em Português de Portugal e eficiência computacional em hardware local sem GPU dedicada.

5.4.1 Construção do Prompt Clínico

A função `build_clinical_prompt` constrói o *prompt* enviado ao LLM a partir dos dados da análise recuperados da base de dados. O *prompt* inclui: o contexto clínico do utente (idade, sexo, estado renal, condições, alergias, medicação ativa e problema principal — mapeados para etiquetas em português através de dicionários como `MAIN_PROBLEM_LABELS`, `RENAL_STATUS_LABELS` e `THERAPEUTIC_CLASS_LABELS`); os alertas mais relevantes (até três, ordenados por severidade decrescente), com origem e categoria da regra mapeadas para linguagem clínica (`ORIGIN_LABELS`, `RULE_CATEGORY_LABELS`); e as recomendações geradas, quando existem.

O *prompt* segue uma abordagem *few-shot* com exemplos de estilo que ilustram o formato esperado da explicação. São disponibilizados três *templates* distintos, selecionados automaticamente com base no tipo de análise: `with_recommendation` (quando existe alternativa terapêutica admissível), `with_symptomatic_recommendation` (quando a alternativa é sintomática, como o paracetamol em contexto de inflamação pós-AINE) e `sem_recomendação`. Quando o utilizador formula uma **questão livre** (`user_question`), o *prompt* é adaptado para incorporá-la e instruir o modelo a responder de forma direta e contextualizada.

5.4.2 Validação da Resposta e Mecanismo de Fallback

A função `validate_llm_response` verifica três critérios na resposta do LLM: a língua portuguesa (presença de palavras comuns como "que", "para", "com", "são", "uma"), o comprimento (mínimo 200 e máximo 4000 caracteres) e a ausência de *tokens* de raciocínio interno ("`<think>`"), que indicam que o modelo expôs o seu processo de pensamento em vez da explicação final. A falha em qualquer um destes critérios ativa o *fallback* determinístico (`generate_deterministic_fallback`), que constrói automaticamente uma explicação estruturada a partir dos dados da análise, sem recurso ao LLM. O campo `fallback_used` na resposta sinaliza se o *fallback* foi utilizado, e o campo `fallback_notice` transmite uma nota técnica explicativa ao utilizador. Esta abordagem garante que o sistema fornece sempre uma explicação útil, mesmo quando o serviço Ollama está indisponível ou a resposta é clinicamente inadequada.

A comunicação com o Ollama é realizada de forma síncrona via `httpx`, com o parâmetro `stream=False` para aguardar a resposta completa antes de a validar. A URL base do Ollama (`OLLAMA_BASE_URL`) e o modelo (`OLLAMA_MODEL`) são configuráveis por variáveis de ambiente, permitindo adaptar o módulo a diferentes configurações de hardware e modelos disponíveis sem alterações ao código.

5.5 Integração de Dados Clínicos

A integração de dados clínicos no protótipo cobre dois fluxos distintos: o carregamento de contextos clínicos de utentes sintéticos para suporte ao modo Synthea da interface, e a construção do *dataset* de treino do modelo supervisionado de *ranking*. Ambos os fluxos partem dos dados gerados pela ferramenta Synthea.

5.5.1 Geração de Dados com Synthea

A ferramenta Synthea foi utilizada para gerar uma população sintética com características demográficas e clínicas representativas. Os ficheiros CSV exportados: `patients.csv`, `conditions.csv`, `medications.csv`, `allergies.csv` e `observations.csv`, servem de base a todos os fluxos de dados do protótipo. A escolha do Synthea face a dados clínicos reais foi determinada por razões éticas e práticas: o acesso a dados de saúde identificáveis implica aprovação de comissões de ética e acordos de partilha de dados incompatíveis com o horizonte temporal de um protótipo de dissertação. Os dados Synthea permitem validar a viabilidade técnica e metodológica da solução sem comprometer a privacidade de indivíduos reais.

5.5.2 Construção do Índice de Contextos Clínicos

O script `build_synthea_context_index.py` processa os ficheiros Synthea e constrói um índice consolidado por utente (`synthea_context_index.csv`). Para cada utente, o script: normaliza as condições clínicas para identificadores canónicos (via `normalize_condition_id`); mapeia os

medicamentos ativos para o vocabulário interno do protótipo (via `normalize_medication_id`), retendo apenas os reconhecidos; estima o estado renal com base em observações laboratoriais de creatinina sérica (quando disponíveis), categorizando em normal, `mild_impairment` ou `severe_impairment`; e gera uma sugestão automática do problema clínico principal com base nas condições normalizadas. O índice resultante é carregado em memória pelo módulo `synthea_loader.py` (via `pandas.read_csv`), que responde às consultas de contexto de utente em tempo $O(1)$ após a leitura inicial, evitando reproprocessamento dos ficheiros Synthea em cada pedido à API.

5.5.3 Construção do Dataset de Treino (Silver e Golden Labels)

O *dataset* de treino do modelo supervisionado foi construído através de um pipeline offline em quatro etapas, representado na Figura 5.5.3.




Figura 5.5.3 - Pipeline offline de construção do *dataset* de treino (Diagrama de Atividades).

Na primeira etapa, o script `generate_full_training_candidates_synthea.py` percorre o índice Synthea e gera, para cada utente, todas as combinações candidato-contexto possíveis face à base de conhecimento. Na segunda etapa, o motor de segurança clínica é aplicado a cada combinação, atribuindo rótulos automáticos (*silver labels*):

- ausência de alertas relevantes → classe 2 (admissível);
- alertas moderados → classe 1 (admissível com precaução);
- alertas high ou critical → classe 0 (não admissível).

Na terceira etapa, os exemplos gerados são exportados para revisão humana via `export_training_candidates_for_review.py`. Na quarta etapa, o desenvolvedor revê e corrige os rótulos automáticos, produzindo os *golden labels* no ficheiro `training_candidates_for_review_reviewed.csv`.

O *dataset* final contém 2720 exemplos revistos, com distribuição balanceada: 1000 exemplos da classe 0, 720 da classe 1 e 1000 da classe 2. A revisão humana foi particularmente relevante para os casos limítrofes, onde as regras determinísticas não capturam adequadamente a nuance clínica, por exemplo, candidatos com alertas moderados em contextos de risco reduzido, ou alternativas cuja adequação contextual compensa parcialmente a precaução renal.

5.5.4 Treino, Avaliação e Seleção do Modelo

O *pipeline* de treino, implementado no script `train_supervised_ranking_model.py`, avalia quatro classificadores: árvore de decisão, *random forest*, regressão logística e *gradient boosting*. Para cada modelo é construído um pipeline scikit-learn composto por um pré-processador `ColumnTransformer`, com `OneHotEncoder` para as *features* categóricas (candidato, classe do candidato, medicamento original, classe original, problema clínico) e `StandardScaler` para as *features* numéricas, e o classificador. A divisão treino/teste utiliza proporção 75/25 com estratificação por classe. A seleção do modelo baseia-se no macro F1 e na *balanced accuracy*, métricas adequadas a classes com distribuição não perfeitamente uniforme.

A Tabela 5.5.4 apresenta os resultados comparativos dos quatro modelos no conjunto de teste (680 exemplos). O *Gradient Boosting* obteve os melhores resultados em todas as métricas, tendo sido selecionado e serializado em `ranking_model.joblib`.

Tabela 5.5.4 - Resultados comparativos dos classificadores no conjunto de teste.

Modelo	Accuracy	Balanced Accuracy	Macro F1
Gradient Boosting (selecionado)	97,65%	97,66%	0,9774
Random Forest	95,00%	94,79%	0,9500
Decision Tree	94,12%	94,15%	0,9441
Logistic Regression	91,47%	91,96%	0,9156

O *Gradient Boosting* apresentou F1 de 0,976 para a classe 0 (não admissível), 0,986 para a classe 1 (admissível com precaução) e 0,971 para a classe 2 (admissível). A matriz de confusão revela que os poucos erros ocorrem principalmente entre as classes 0 e 2 (9 exemplos classificados como admissíveis quando eram não admissíveis), o que é clinicamente mais cauteloso do que a direção oposta. No entanto, importa contextualizar estes resultados: o *dataset* foi construído a partir de dados sintéticos e de regras determinísticas aplicadas pelo próprio sistema, pelo que o modelo aprende parcialmente a replicar essas regras. A sua principal contribuição é o refinamento do *ranking* entre candidatos com *scores* heurísticos próximos, tendo em conta combinações de *features* que as regras simples não capturam.

As métricas detalhadas de todos os modelos são registadas em `ranking_model_metrics.json` para auditoria e comparação futura, incluindo o relatório de classificação completo por classe e a matriz de confusão.

5.5.5 Testes Clínicos de Regressão

Para garantir a correção clínica do motor de segurança e do motor de recomendação ao longo do desenvolvimento iterativo, foi implementado um conjunto de testes de regressão clínica em `backend/tests`. Os casos de teste (`clinical_regression_cases.py`) cobrem os principais cenários de prescrição problemática: AINE + antiagregante, AINE + antiagregante com insuficiência renal grave, AINE + IECA com duplicação terapêutica, sinvastatina + claritromicina, triple whammy, varfarina + amiodarona, ISRS + anticoagulante e combinação de risco QT. Cada caso define o *payload* de entrada, os alertas esperados (`rule_id`, `severidade`, `origem`), as recomendações esperadas e as recomendações proibidas.

Os testes são executados via `pytest` (`test_clinical_scenarios.py`), com parametrização por caso, e requerem que o servidor FastAPI esteja em execução local. Adicionalmente, os testes de integração `test_clinical_scenario_llm_explanation_structure` validam que a explicação LLM gerada para cada cenário satisfaz os critérios de validação linguística e estrutural implementados no módulo `llm_explainer.py`, requerendo também que o serviço Ollama esteja ativo localmente. Os testes de validação do módulo LLM (`test_llm_validation.py`) verificam os critérios de validação da resposta: língua portuguesa, comprimento e ausência de tokens de raciocínio. Estes testes garantem a rastreabilidade entre os requisitos clínicos e o comportamento observado do sistema.

6 Avaliação e Validação

6.1 Objetivos da Avaliação

6.2 Metodologia Experimental

6.3 Cenários Clínicos de Regressão

6.4 Métricas

6.5 Resultados do Motor de Segurança Clínica

6.6 Resultados do Modelo Supervisionado

6.7 Resultados da Explicação LLM

6.8 Discussão

7 Conclusão

Este capítulo propõe a metodologia de teste do Sistema de Recomendação, delineando as hipóteses de estudo, a abordagem empírica para testar o sistema com dados sintéticos, e as métricas que permitirão quantificar o impacto da intervenção da Inteligência Artificial na prevenção de erros médicos.

7.1 Conclusões

7.2 Contributos

7.3 Limitações

7.4 Trabalho Futuro

Como trabalho futuro, prevê-se a integração de um módulo RAG, através da indexação de fontes normativas e farmacológicas, como RCM, *guidelines* clínicas e normas institucionais. Esta extensão permitiria que as explicações geradas pelo LLM fossem acompanhadas de referências explícitas às passagens documentais que suportam cada alerta ou recomendação, aumentando a rastreabilidade e a confiança do utilizador.

Referências

- [1] R. A. Elliott *et al.*, "Economic analysis of the prevalence and clinical and economic burden of medication error in England," *BMJ Qual. Saf.*, vol. 30, no. 2, pp. 96-105, Jun. 2020, doi: 10.1136/bmjqs-2019-010206.
- [2] Ministério da Saúde, "Sobre os Sistemas de Informação," Serviços Partilhados do Ministério da Saúde. [Online]. Disponível: <https://www.spms.min-saude.pt/sobre-os-sistemas-deinformacao/> [Acedido: 22-Nov-2025].
- [3] J. Graafsma *et al.*, "The use of artificial intelligence to optimize medication alerts generated by clinical decision support systems: a scoping review," *J. Am. Med. Inform. Assoc.*, vol. 31, no. 6, pp. 1411-1422, Mai. 2024, doi: 10.1093/jamia/ocae076.
- [4] H. Y. Jang *et al.*, "Machine learning-based quantitative prediction of drug exposure in drugdrug interactions using drug label information," *npj Digit. Med.*, vol. 5, no. 1, p. 88, Jul. 2022, doi: 10.1038/s41746-022-00639-0.
- [5] M. Felisberto *et al.*, "Override rate of drug-drug interaction alerts in clinical decision support systems: A brief systematic review and meta-analysis," *Health Informatics Journal*, vol. 30, no. 2, Apr. 2024, doi: 10.1177/14604582241263242.
- [6] C. Nebeker *et al.*, "Building the case for actionable ethics in digital health research supported by artificial intelligence," *BMC Med.*, vol. 17, no. 137, Jul. 2019, doi: 10.1186/s12916-019-1377-7.
- [7] M. Ienca *et al.*, "Considerations for ethics review of big data health research: A scoping review," *PLoS ONE*, vol. 13, no. 10, Out. 2018, doi: 10.1371/journal.pone.0204937.
- [8] Association for Computing Machinery, "ACM Code of Ethics and Professional Conduct," Jun. 2018. [Online]. Disponível: <https://www.acm.org/code-of-ethics> [Acedido: 15-Dez-2025].
- [9] Association for Computing Machinery and IEEE Computer Society, "Software Engineering Code of Ethics and Professional Practice," 1999. [Online]. Disponível: <https://www.acm.org/code-of-ethics/software-engineering-code> [Acedido: 15-Dez-2025].
- [10] A. Hanson and L. M. Haddad, "Nursing rights of medication administration," *StatPearls*, Treasure Island (FL), 2023. [Online]. Disponível: <https://www.ncbi.nlm.nih.gov/books/NBK560654/> [Acedido: 04-Jan-2026].
- [11] Autoridade Nacional do Medicamento e Produtos de Saúde (INFARMED), "Resumo das Características do Medicamento (RCM): Ben-U-Ron 1000 mg," *Infomed - Base de Dados Nacional de Medicamentos*, 26 Fev. 2025. [Online]. Disponível:

<https://extranet.infarmed.pt/INFOMED-fo/pesquisa-avancada.xhtml> [Acedido: 03-Jan-2026].

- [12] A. M. Jambrina *et al.*, "Detection and prevention of medication errors by the network of sentinel pharmacies in a Southern European region," *J. Clin. Med.*, vol. 12, no. 1, p. 194, 2023, doi: 10.3390/jcm12010194.
- [13] M. Anzan *et al.*, "Prescribing errors and associated factors in discharge prescriptions in the emergency department: A prospective cross-sectional study," *PLoS ONE*, vol. 16, no. 1, Jan. 2021, doi: 10.1371/journal.pone.0245321.
- [14] G. F. Bonella *et al.*, "Prescribing errors in a Brazilian teaching hospital: Causes and underlying factors from the perspective of junior doctors," *PLoS ONE*, vol. 18, no. 4, Abr. 2023. doi: 10.1371/journal.pone.0284071.
- [15] N. Peiffer-Smadja *et al.*, "Machine learning for clinical decision support in infectious diseases: a narrative review of current applications," *Clinical Microbiology and Infection*, vol. 26, no. 5, pp. 584-595, Mai. 2020. doi: 10.1016/j.cmi.2019.09.009.
- [16] S. Huang *et al.*, "Applications of Clinical Decision Support Systems in Diabetes Care: Scoping Review," *Journal of Medical Internet Research*, vol. 25, Dez. 2023. doi: 10.2196/51024.
- [17] L. G. Armando *et al.*, "Clinical decision support systems to improve drug prescription and therapy optimisation in clinical practice: a scoping review," *BMJ Health & Care Informatics*, vol. 30, no. 1, Mai. 2023. doi: 10.1136/bmjhci-2022-100683.
- [18] M. R. Pinsky *et al.*, "Use of artificial intelligence in critical care: opportunities and obstacles," *Critical Care*, vol. 28, no. 1, p. 113, Abr. 2024. doi: 10.1186/s13054-024-04860-z.
- [19] Z. Fayyaz *et al.*, "Recommendation Systems: Algorithms, Challenges, Metrics, and Business Opportunities," *Applied Sciences*, vol. 10, no. 21, Nov. 2020. doi: 10.3390/app10217748.
- [20] F. Pinelas, "Sistema de recomendação para alívio de stress," Dissertação de Mestrado, ISEP, Porto, Portugal, 2022. [Online]. Disponível: <https://recipp.ipp.pt/entities/publication/0cfdd272-1e84-4a72-9b7c-1af341d1a557> [Acedido: 15-Dez-2025].
- [21] S. Lubos *et al.*, "An overview of video recommender systems: state-of-the-art and research issues," *Frontiers in big data*, vol. 6, Out. 2023. doi: 10.3389/fdata.2023.1281614.

- [22] O. Fouad *et al.*, "A comprehensive review of music recommendation systems," *Advanced Sciences and Technology Journal*, vol. 2, no. 1, pp. 1-18, Jan. 2025. doi: 10.21608/astj.2025.342474.1017.
- [23] M. Uta *et al.*, "Knowledge-based recommender systems: overview and research directions," *Frontiers in Big Data*, vol. 7, Feb. 2024, doi: 10.3389/fdata.2024.1304439.
- [24] S. Nabil *et al.*, "Demographic information combined with collaborative filtering for an efficient recommendation system," *International Journal of Electrical and Computer Engineering (IJECE)*, vol. 14, no. 5, Out. 2024, doi: 10.11591/ijece.v14i5.pp5916-5925.
- [25] S. Kulkarni and S. F. Rodd, "Context Aware Recommendation Systems: A review of the state of the art techniques," *Computer Science Review*, vol. 37, Mai. 2020, doi: 10.1016/j.cosrev.2020.100255.
- [26] M. Abusair *et al.*, "Context-Aware Recommender System based on Content Filtering," *2021 IEEE 15th International Conference on Application of Information and Communication Technologies (AICT)*, p. 1-6, Out. 2021, doi: 10.1109/AICT52784.2021.9620478.
- [27] Y. Li and X. Lin, "Study of collaborative filtering recommendation with user clustering incorporating implicit social relationships and trust relationships," *PLOS ONE*, vol. 20, no. 10, p. 1-15, Out. 2025, doi: 10.1371/journal.pone.0332998.
- [28] Z. Yao, "Review of movie recommender systems based on deep learning," *SHS Web of Conferences*, vol. 159, Fev. 2023. doi: 10.1051/shsconf/202315902010.
- [29] R. De Croon *et al.*, "Health recommender systems: Systematic review," *J. Med. Internet Res.*, vol. 23, no. 6, Jun. 2021, doi: 10.2196/18035.
- [30] Z. Sadeghi *et al.*, "A review of explainable artificial intelligence in healthcare," *Comput. Electr. Eng.*, vol. 118, Jun. 2024, doi: 10.1016/j.compeleceng.2024.109370.
- [31] S.-C. Chien *et al.*, "Alerts in Clinical Decision Support Systems (CDSS): A Bibliometric Review and Content Analysis," *Healthcare*, vol. 10, no. 4, p. 601, Mar. 2022. doi: 10.3390/healthcare10040601.
- [32] G. Van De Sijpe *et al.*, "Overall performance of a drug-drug interaction clinical decision support system: quantitative evaluation and end-user survey," *BMC Medical Informatics and Decision Making*, vol. 22, no. 1, p. 48, Fev. 2022. doi: 10.1186/s12911-022-01783-z.
- [33] C. Pais *et al.*, "Large language models for preventing medication direction errors in online pharmacies," *Nature Medicine*, vol. 30, pp. 1574-1582, Abr. 2024. doi: 10.1038/s41591-024-02933-8.

- [34] Y. Shen *et al.*, "An ontology-driven clinical decision support system (IDDAP) for infectious disease diagnosis and antibiotic prescription," *Artif. Intell. Med.*, vol. 86, pp. 20-32, Feb. 2018, doi: 10.1016/j.artmed.2018.01.003.
- [35] M. Gholamzadeh *et al.*, "The application of knowledge-based clinical decision support systems to enhance adherence to evidence-based medicine in chronic disease," *J. Healthc. Eng.*, Mai. 2023, doi: 10.1155/2023/8550905.
- [36] S. S. Alqahtani *et al.*, "Artificial intelligence in clinical pharmacy—A systematic review of current scenario and future perspectives," *Digital Health*, vol. 11, pp. 1-23, Out. 2025. doi: 10.1177/20552076251388145.
- [37] T. N. Poly *et al.*, "Appropriateness of Overridden Alerts in Computerized Physician Order Entry: Systematic Review," *JMIR Medical Informatics*, vol. 8, no. 7, Jul. 2020. doi: 10.2196/15653.
- [38] S. Kresevic *et al.*, "Optimization of hepatological clinical guidelines interpretation by large language models: A retrieval augmented generation-based framework," *npj Digit. Med.*, vol. 7, no. 102, Abr. 2024, doi: 10.1038/s41746-024-01091-y.
- [39] T. I. Wilhelm *et al.*, "Large language models for therapy recommendations across 3 clinical specialties: Comparative study," *J. Med. Internet Res.*, vol. 25, Out. 2023, doi: 10.2196/49324.
- [40] W. X. Zhao *et al.*, "A Survey of Large Language Models," *arXiv*, 2023. doi: 10.48550/arXiv.2303.18223
- [41] Y. Gao *et al.*, "Retrieval-Augmented Generation for Large Language Models: A Survey," *arXiv*, 2024. doi: 10.48550/arXiv.2312.10997.
- [42] Z. Ji *et al.*, "Survey of Hallucination in Natural Language Generation," *ACM Computing Surveys*, vol. 55, no. 12, pp. 1-38, Mar. 2023. doi: 10.1145/3571730.
- [43] E. Alsentzer *et al.*, "Publicly Available Clinical BERT Embeddings," *arXiv*, Jun. 2019. doi: 10.48550/arXiv.1904.03323.
- [44] J. Shang *et al.*, "Pre-training of Graph Augmented Transformers for Medication Recommendation," *arXiv*, Nov. 2019. doi: 10.48550/arXiv.1906.00346.
- [45] C. Yang *et al.*, "SafeDrug: Dual Molecular Graph Encoders for Safe Drug Recommendation," *arXiv*, Jul. 2022. doi: 10.48550/arXiv.2105.02711.
- [46] S. A. Hollingworth and T. Kairuz, "Measuring medicine use: applying ATC/DDD methodology to real-world data," *Pharmacy*, vol. 9, no. 1, pp. 60, Mar. 2021. doi: 10.3390/pharmacy9010060.

- [47] Z. Juhásová *et al.*, "The use of international classification of diseases codes to identify hospital admissions linked with adverse drug events: Validation study," *British Journal of Clinical Pharmacology*, vol. 91, no. 10, pp. 2910-2918, 2025. doi: 10.1002/bcp.70116.
- [48] N. Pimenta *et al.*, "Interoperability of Clinical Data through FHIR: A review," *Procedia Computer Science*, vol. 220, pp. 856-861, 2023. doi: 10.1016/j.procs.2023.03.115.
- [49] B. Vasey *et al.*, "Reporting guideline for the early-stage clinical evaluation of decision support systems driven by artificial intelligence: DECIDE-AI," *Nature Medicine*, vol. 28, pp. 924-933, Mai. 2022. doi: 10.1038/s41591-022-01772-9.
- [50] J. C. L. Ong *et al.*, "Large language model as clinical decision support system augments medication safety in 16 clinical specialties," *Cell Reports Medicine*, vol. 6, no. 10, Out. 2025. doi: 10.1016/j.xcrm.2025.102323.
- [51] J. Brooke, "SUS: A retrospective," *J. Usability Stud.*, vol. 8, no. 2, pp. 29-40, Fev. 2013. [Online]. Disponível: https://www.researchgate.net/publication/285811057_SUS_a_retrospective [Acedido: 15-Dez-2025].
- [52] S.-C. Chien *et al.*, "Using technology acceptance model to explore physicians' perspectives of clinical decision support system alerts," *BMJ Health & Care Informatics*, vol. 32, no. 1, Jun. 2025. doi: 10.1136/bmjhci-2024-101128.
- [53] K. Seden *et al.*, "Cross-sectional study of prescribing errors in patients admitted to nine hospitals across North West England," *BMJ Open*, vol. 3, no. 1, Jan. 2013, doi: 10.1136/bmjopen-2012-002036.
- [54] A. Avery *et al.*, "The prevalence and nature of prescribing and monitoring errors in English general practice: a retrospective case note review," *British Journal of General Practice*, Jul. 2013, doi: 10.3399/bjgp13X670679.

Anexos

Anexo A - Project Charter

1. Informação geral				
Nome do Projeto:	Sistema de Recomendação e Alertas para Identificar e Prevenir Erros de Prescrição de Medicamentos			
Sponsor:	Orientador: Dulce Mota; Coorientador: Constantino Martins			
Instituição / Departamento	ISEP/GECAD - Research Group on Intelligent Engineering and Computing for Advanced Innovation and Development			
2. Equipa do Projeto				
Cargo	Nome	Departamento	Contact Tel	E-mail
Estudante	Pedro Domingues	DEI	-	-
Orientadora	Dulce Mota	DEI	-	-
Coorientador	Constantino Martins	DEI/GECAD	-	-
3. Stakeholders				
Nome		Poder	Interesse	
Médicos		Alto	Alto	
Farmacêuticos		Alto	Médio	
Gestores Hospitalares		Médio	Médio	
Instituições de saúde		Médio	Alto	
Programadores/desenvolvedores de software		Médio	Baixo	
4. Âmbito				

Problema / justificação
Existir um elevado número de erros de prescrição. A prescrição de medicamentos é uma das etapas mais críticas do processo terapêutico, estando frequentemente associada a erros que podem comprometer a eficácia do tratamento e a segurança do utente. Estudos indicam taxas elevadas de erro na prescrição, variando entre 5% em cuidados de saúde primários e 44% em centros hospitalares [53],[54]. A utilização de sistemas inteligentes de recomendação e alerta tem vindo a assumir um papel central na prevenção destes erros, permitindo apoiar os profissionais de saúde na tomada de decisão clínica. Este projeto propõe o desenvolvimento de um Sistema de Recomendação e Alertas capaz de identificar potenciais incompatibilidades, interações medicamentosas, doses incorretas e duplicação de terapias, fornecendo recomendações personalizadas e em tempo real.
Objetivos do projeto
Diminuir o número de erros de prescrição médica (no mínimo 50%) com o desenvolvimento e validação de um sistema de recomendação e alertas que identifique e previna erros de prescrição de medicamentos, contribuindo para a melhoria da segurança do utente e para o apoio à decisão clínica.
Benefícios
Valor que o clientes ou utilizadores retirarão no futuro com esta dissertação, exemplos: Redução do número de erros de prescrição (no mínimo 50%). Redução de custo ($\approx 17,262,640$ € por ano): [1].
Entregáveis
Prototipo funcional Código fonte Relatório de Dissertação Apresentação final
5. Tempo
Milestones / Datas

Datas que eu me comprometo (podem alterar) Draft: Resumo, Introdução, Contexto e Estado da Arte: 10 de Dezembro 2026. Primeiro Protótipo: 28 de Fevereiro Protótipo Final: 31 de Março Datas obrigatórias (deadlines, que não podem mudar) Extended abstract: 15 de Dezembro 2025; Introdução, Contexto e Estado da Arte: 7 de Janeiro 2026.	
6. Custo	
Fontes de custo	
Pode não existir mas deve ser previsto mesmo para futuro, alguns exemplos: Licenças de bases de dados Licenças de software	
7. Pressupostos	8. Restrições
Utilização de bases de dados Americanas: Sintéticas - Synthea. Reais - mas com formação ética prévia, MIMIC.	Prazos académicos. Escassez de datasets portugueses.
Notas	

Anexo B - Estrutura Analítica do Projeto




Figura 1 - Estrutura Analítica do Projeto (EAP)

A Figura 2 está disponível em:

https://www.canva.com/design/DAG50BCVImA/ylqeU03FMkH_hrypxknmw/edit?utm_content=DAG50BCVImA&utm_campaign=designshare&utm_medium=link2&utm_source=sharebutton

Anexo C - Diagrama de *Gantt*

A Figura 1 (Diagrama de *Gantt*) está disponível em: [https://myisepipp-](https://myisepipp-my.sharepoint.com/:u:/g/personal/1211492_isep_ipp_pt/EZhp0xi9TkZlrSPWc-7vBZQBY-57iRYe9QMA7qUizbRK1A?e=M7HzF9)

[my.sharepoint.com/:u:/g/personal/1211492_isep_ipp_pt/EZhp0xi9TkZlrSPWc-7vBZQBY-57iRYe9QMA7qUizbRK1A?e=M7HzF9](https://myisepipp-my.sharepoint.com/:u:/g/personal/1211492_isep_ipp_pt/EZhp0xi9TkZlrSPWc-7vBZQBY-57iRYe9QMA7qUizbRK1A?e=M7HzF9)

Anexo D - Diagrama de *PRISMA*




Figura 4 - Diagrama de *PRISMA*

Anexo E - Planeamento

O planeamento constitui uma etapa fundamental para assegurar a exequibilidade do projeto de dissertação. Este capítulo descreve a abordagem adotada para a organização das atividades, a gestão de riscos e a alocação de recursos. O foco principal reside na definição de uma estratégia que permita desenvolver um sistema de recomendação seguro e eficaz, cumprindo os requisitos temporais e éticos estabelecidos.

São apresentadas as estratégias de mitigação para os riscos identificados, as competências técnicas e científicas necessárias para trabalhar com inteligência artificial em saúde, e o cronograma detalhado que guia o trabalho desde a fase de preparação (PREPD) até à conclusão da dissertação na fase da Dissertação do Mestrado em Engenharia Informática (DIMEI).

E.1 Gestão de Riscos

A natureza do projeto, que envolve a aplicação de algoritmos de IA num domínio crítico como a saúde, apresenta riscos específicos que podem comprometer a validade científica, a exequibilidade técnica ou a aceitação ética da solução. A gestão proativa destes riscos é, portanto, um pilar fundamental do planeamento.

E.1.1 Principais Riscos Identificados

A análise de riscos permitiu identificar ameaças em quatro dimensões críticas:

- **Riscos Técnicos:** O risco mais pertinente é o fenómeno das "Alucinações" da IA, onde os Grandes Modelos de Linguagem (LLM) podem gerar recomendações clinicamente incorretas ou inventar interações medicamentosas inexistentes com elevada confiança. Adicionalmente, identificou-se o risco associado à qualidade dos dados de treino, nomeadamente a possibilidade de estes estarem incompletos ou não normalizados nos *datasets* públicos, comprometendo deste modo o treino do modelo.
- **Riscos Ético-Legais:** A violação de privacidade constitui um risco significativo, relacionado com o potencial uso indevido de dados sensíveis ou a reidentificação de doentes, o que violaria o Regulamento Geral sobre a Proteção de Dados (RGPD).
- **Riscos Organizacionais:** Destaca-se a "fadiga de alertas", que se traduz na rejeição do sistema pelos médicos devido a um excesso de avisos de baixa relevância clínica, bem como a desconfiança inerente a sistemas do tipo "caixa preta", quando um utilizador não compreende bem o funcionamento interno de um sistema.
- **Riscos de Projeto:** A não conclusão do protótipo (ex: atrasos no Cronograma) dentro dos prazos académicos estipulados é um risco operacional significativo.

E.1.2 Plano de Mitigação

Para cada risco identificado, foram delineadas estratégias de mitigação concretas:

- **Mitigação Técnica:** Para mitigar as alucinações, será implementada uma arquitetura RAG, que obriga o modelo a fundamentar as suas respostas em bases de dados farmacológicas validadas, juntamente com uma camada de verificação baseada em regras determinísticas. A qualidade dos dados será, desta forma, assegurada através de processos robustos de pré-processamento e normalização antes da ingestão pelo modelo.
- **Mitigação Ética:** O risco de privacidade será eliminado através da utilização exclusiva de dados sintéticos e bases de dados públicas anonimizadas, garantindo conformidade total com as normas éticas sem necessitar de acesso a dados reais de doentes nesta fase.
- **Mitigação Organizacional:** Para prevenir a fadiga de alertas, a estratégia foca-se na Experiência do Utilizador (UX), com ajuste nos limiares de sensibilidade do sistema para apresentar apenas alertas clinicamente relevantes.
- **Mitigação de Projeto:** O cumprimento dos prazos será gerido através da adoção de uma metodologia que envolve reuniões quinzenais e a priorização rigorosa das funcionalidades essenciais (Produto Mínimo Viável - MVP) em detrimento de funcionalidades acessórias ("*nice-to-haves*").

E.1.3 Impacto dos Riscos

A avaliação do impacto revela que a materialização dos riscos de alucinações e violação de privacidade teria consequências elevadas, podendo invalidar clinicamente o protótipo ou levantar barreiras legais não superáveis.

O risco de atraso no cronograma possui também um impacto alto, pois comprometeria a avaliação académica. No entanto, os riscos de fadiga de alertas e qualidade dos dados apresentam um impacto médio, afetando a eficácia e usabilidade do sistema, mas não necessariamente a sua viabilidade fundamental.

E.1.4 Análise Geral dos Riscos

A Tabela 1 sistematiza e sumaria a matriz de riscos, classificando-os quanto ao seu impacto e probabilidade, e associando-os às respectivas estratégias de mitigação.

Tabela 3 - Matriz de Riscos e Mitigação

Risco	Categoria	Impacto	Probabilidade	Estratégia de Mitigação
"Alucinações" da IA: O modelo gerar recomendações clinicamente incorretas ou inventadas.	Técnica	Elevado	Média	Implementação de arquitetura RAG (<i>Retrieval-Augmented Generation</i>) ligada a bases de dados validadas (DrugBank). Verificação baseada em regras determinísticas.
Violação de Privacidade (RGPD): Uso indevido de dados sensíveis ou reidentificação.	Ético-Legal	Elevado	Baixa	Utilização exclusiva de <i>datasets</i> sintéticos (Synthea) e bases de dados públicas anonimizadas. Conformidade rigorosa com normas éticas.
Fadiga de Alertas: Rejeição do sistema pelos médicos por excesso de avisos.	Organizacional	Médio	Alta	Ajuste dos limiares de sensibilidade do sistema. Foco na UX (<i>User Experience</i>) para apresentar apenas alertas de severidade relevante.
Qualidade dos Dados: Dados incompletos ou não normalizados nos <i>datasets</i> públicos.	Técnica	Médio	Média	Pré-processamento robusto e normalização de dados antes da ingestão pelo modelo.
Atrasos no Cronograma: Não conclusão do protótipo a tempo da entrega final.	Projeto	Alto	Média	Adoção de metodologia Ágil com <i>sprints</i> quinzenais. Priorização de funcionalidades essenciais (MVP) em detrimento de "nice-to-haves".

E.2 Gestão de Competências

O desenvolvimento deste sistema exige a combinação de competências de engenharia informática com conhecimentos específicos de informática médica e ciência de dados.

E.2.1 Competências Necessárias

Para a concretização dos objetivos, foram identificadas as seguintes competências nucleares:

- **Técnicas:** Domínio de Python e *frameworks* de IA (LangChain, OpenAI API, PyTorch); Capacidade de manipulação de grandes volumes de dados (Pandas, SQL).
- **Científicas:** Capacidade de análise de literatura médica e compreensão de terminologias farmacológicas (grupos, interações, posologia, contraindicações).
- **Transversais:** Rigor ético no tratamento de dados; Gestão de tempo e autonomia na investigação e desenvolvimento.

E.2.3 Desenvolvimento de Competências

Após a identificação das competências nucleares, foi realizado um diagnóstico inicial para avaliar o estado atual destas capacidades. Este processo baseou-se num modelo de autoavaliação (escala 1 a 5) complementado por uma heteroavaliação realizada por pares, permitindo uma análise mais objetiva dos pontos fortes e das áreas que carecem de melhoria.

A Tabela 2 apresenta os resultados detalhados do diagnóstico efetuado:

Tabela 4 - Matriz de Diagnóstico de Competências

Competência	Importância	Autoavaliação	Heteroavaliação
Análise e resolução de problemas	5	4	5
Aprendizagem ao longo da vida	5	4	4
Trabalho em equipa e colaboração	5	5	5
Motivação para a excelência	4	4	4
Adaptabilidade e flexibilidade	4	4	5
Ética e responsabilidade social	5	4	5
Domínio de línguas estrangeiras	5	5	5
Competências técnicas da área específica	5	4	4
Tomada de decisão	5	4	5
Gestão do tempo	5	3	4
Capacidade para assumir riscos	5	4	4
Comunicação oral	5	3	5
Comunicação escrita	5	4	5
Resiliência	4	4	4
Escuta ativa	5	5	5
Relacionamento interpessoal	4	4	5
Liderança	4	4	4
Criatividade e inovação	5	4	4
Gestão das emoções	4	5	5
Negociação	4	3	4
Empatia	5	5	4
Assertividade	4	4	4
Gestão do stress	4	4	4
Proatividade	4	4	5

Competências mais desenvolvidas: A análise dos resultados evidencia um conjunto de competências sólidas, fundamentais para a execução do projeto, destacando-se:

- **Trabalho em equipa e Escuta Ativa (5/5):** A avaliação máxima em ambas as vertentes (auto e heteroavaliação) demonstra uma elevada capacidade de colaboração e de assimilação de feedback, essenciais para a interação com a equipa de orientação.
- **Gestão das Emoções (5/5):** Revela maturidade emocional para lidar com os desafios inerentes a um projeto de investigação.
- **Competências Técnicas e Capacidade de Risco (4/5):** Esta classificação indica uma razoável preparação base para lidar com as tecnologias propostas e para explorar abordagens inovadoras.

Competências a melhorar: Por outro lado, identificaram-se competências com pontuações inferiores face ao seu grau de importância (nível 5), que constituem o foco do plano de desenvolvimento:

- **Gestão do Tempo (3/5):** Identificada como uma área crítica, dado o rigor dos prazos académicos e a complexidade do cronograma.
- **Comunicação Oral (3/5):** A discrepância entre a autoavaliação e a importância desta competência sugere a necessidade de treino específico para a defesa da dissertação.
- **Gestão do Stress (4/5):** Embora com uma avaliação positiva, a sua importância crítica num contexto de *deadlines* justifica a inclusão de um plano de ação preventivo.
- **Tomada de Decisão (4/5):** Sendo um projeto de investigação que exige autonomia, pretende-se elevar esta competência para o nível de excelência.

E.3.4 Plano de Desenvolvimento de Competências

Com base no diagnóstico anterior, foi elaborado um plano de ação focado no fortalecimento das competências identificadas como prioritárias. Este plano define ações concretas e indicadores de progresso para cada área.

1. Gestão do Stress:

- **Ações de Desenvolvimento:**
 - Implementação de rotinas de exercício físico regular para libertação de stress acumulado.
 - Prática de técnicas de meditação e *mindfulness* para melhoria do foco e controlo da ansiedade.

- **Indicadores de Progresso:**

- Manutenção de níveis de produtividade constantes durante picos de trabalho.
- Capacidade de resposta equilibrada perante imprevistos técnicos.

2. Gestão do Tempo:

- **Ações de Desenvolvimento:**

- Elaboração e cumprimento rigoroso do diagrama de *Gantt*.
- Adoção da prática de iniciar as tarefas com antecedência em relação aos prazos limite, evitando a acumulação de trabalho.

- **Indicadores de Progresso:**

- Cumprimento integral das *milestones* definidas posteriormente neste Capítulo 2.
- Ausência de atrasos na entrega dos relatórios parciais.

3. Comunicação Oral:

- **Ações de Desenvolvimento:**

- Leitura regular de artigos científicos em voz alta de modo a melhorar a fluência técnica.
- Participação ativa em reuniões com os orientadores, de modo a ter uma maior intervenção e exposição de ideias ("Falar mais").

- **Indicadores de Progresso:**

- Clareza e assertividade demonstradas nas reuniões quinzenais de acompanhamento.
- Feedback positivo dos orientadores relativamente à capacidade de argumentação.

4. Tomada de Decisão:

- **Ações de Desenvolvimento:**

- Maior iniciativa nas escolhas técnicas do projeto (ex: seleção de *datasets* ou algoritmos), fundamentando-as cientificamente antes da validação.
- Exercício de liderança no planeamento das próprias tarefas, reduzindo a dependência de microgestão externa.

- **Indicadores de Progresso:**

- Redução do tempo despendido em indecisões sobre a arquitetura do sistema.
- Aprovação das escolhas técnicas propostas sem necessidade de correções estruturais profundas.

E.3 Plano de Desenvolvimento

Foi realizado um diagnóstico inicial que identificou a necessidade de aprofundar conhecimentos específicos em Arquiteturas RAG e Normalização de Dados Clínicos. O plano de desenvolvimento inclui a realização de cursos especializados *online*, a leitura técnica da documentação das API (ex: OpenFDA, DrugBank) e reuniões quinzenais de acompanhamento técnico com a equipa de orientação.

E.4 Planeamento do Projeto

O planeamento do projeto segue as diretrizes estabelecidas no *Project Charter*, garantindo o alinhamento entre o âmbito, o tempo e os recursos. O planeamento do projeto segue as diretrizes e metodologias necessárias para assegurar a execução bem-sucedida da dissertação, apresentando aspetos fundamentais como a definição de objetivos, cronogramas, recursos, monitorização de progresso e avaliação de desempenho. Esta subsecção baseia-se em práticas de gestão de projetos académicos da unidade curricular de PREPD, e combina elementos de planeamento, como a Estrutura Analítica do Projeto (EAP) e o diagrama de *Gantt*.

E.4.1 *Project Charter*

O *Project Charter* (Anexo A) serviu como um documento de formalização inicial, estabelecendo as fronteiras e as premissas estratégicas do projeto. Neste documento, foram definidos os seguintes elementos estruturantes:

- **Âmbito:** O projeto foca-se no desenvolvimento de um protótipo de sistema de recomendação híbrido para a prevenção de erros de prescrição. Ficam explicitamente fora do âmbito a integração direta com sistemas hospitalares em produção (devido a restrições de acesso) e a realização de ensaios clínicos com doentes reais.
- **Stakeholders:** Foram identificados e classificados os interessados no projeto quanto ao seu poder e interesse. Destacam-se os médicos (alto poder/alto interesse) como utilizadores principais e os farmacêuticos (alto poder/médio interesse) como validadores técnicos.

- **Restrições e Pressupostos:** O planeamento assume a utilização de dados sintéticos (gerados via *Synthea*) e bases de dados públicas (ex: *DrugBank*, *MIMIC-III*) para garantir a conformidade com o RGPD, dado que não haverá acesso a dados reais de instituições de saúde portuguesas nesta fase.

E.4.1 Estrutura Analítica do Projeto (EAP)

Para tornar o projeto organizável, o âmbito foi decomposto hierarquicamente através de uma Estrutura Analítica do Projeto (EAP). As principais fases de trabalho, ilustradas no Anexo B, são:

1. **Gestão e Planeamento:** Inclui a elaboração do *Project Charter*, cronograma e plano de requisitos e âmbito.
2. **Investigação (Estado da Arte):** Revisão sistemática sobre erros de prescrição e sistemas de recomendação.
3. **Design da Solução:** Definição da arquitetura de sistema, *mockups* e *wireframes*.
4. **Desenvolvimento:** Implementação do *backend*, *frontend*, integração de API e do modelo LLM.
5. **Validação:** Testes de desempenho técnico e avaliação de usabilidade (SUS).
6. **Escrita da Dissertação:** Redação do documento final e preparação da defesa.

E.1.3 Cronograma e Entregáveis

O cronograma do projeto foi desenhado para cumprir os prazos académicos das duas unidades curriculares de: Preparação para Dissertação (PREPD) e Dissertação (DIMEI).

Fase 1: PREPD (Setembro 2025 - Janeiro 2026)

A fase de PREPD foca-se no planeamento e fundamentação teórica. A Tabela 3 resume as datas objetivas de cada tarefa (*milestones*) e entregáveis já concluídos ou previstos para esta etapa:

Tabela 5 - Lista de entregáveis da unidade curricular de PREPD

Entregável	Data de Entrega	Descrição
<i>Project Charter</i>	07/11/2025*	Documento inicial que identifica a equipa, <i>stakeholders</i> , âmbito, <i>milestones</i> , custos, pressupostos e restrições do projeto.
<i>WBS (Work Breakdown Structure)</i>	13/11/2025*	Decomposição hierárquica do trabalho necessário para cumprir os objetivos do projeto: planeamento, investigação e análise, design, desenvolvimento e integração, avaliação e validação, conclusão e documentação.
Plano de Projeto Aprovado	26/11/2025*	Versão consolidada e aprovada do planeamento e gestão de recursos do projeto.
<i>Extended Abstract</i>	15/12/2025	Resumo alargado descrevendo: introdução e enquadramento do problema, perguntas de investigação e objetivos, estado da arte, metodologia proposta, plano de trabalho, considerações éticas e profissionais, e referências bibliográficas.
Trabalho Final PREPD e Apresentação	07/01/2026	Trabalho final da UC contendo a introdução, contexto, problema, objetivo, abordagem, resultados esperados, estrutura do documento, estado da arte, análise de valor, questões éticas e preparação da apresentação.

*Datas não oficiais da UC de PREPD, apenas entregáveis do estudante.

Fase 2: DIMEI (Fevereiro 2026 - Junho 2026)

A segunda fase corresponde à execução técnica e validação. Conforme evidenciado no Diagrama de *Gantt* (Anexo C), as atividades principais desta fase incluem:

- **Fevereiro - Março 2026:** Desenvolvimento do protótipo funcional (MVP) e integração do motor de IA.
- **Abril 2026:** Testes de integração e mitigação de alucinações do modelo.
- **Maió 2026:** Validação com utilizadores e recolha de métricas de precisão.
- **Junho 2026:** Escrita final da dissertação e entrega do documento.

A Figura 1 apresenta o Diagrama de *Gantt*, que evidencia o cronograma temporal e o encadeamento das atividades até à conclusão da dissertação.




Figura 5 - Diagrama de *Gantt* do projeto.

E.4.3 Gestão de Recursos

Para assegurar a execução do plano dentro dos prazos estipulados no diagrama de *Gantt*, foram alocados os seguintes recursos:

- **Recursos Humanos:**
 - **Autor (Pedro Domingues):** Responsável por todas as atividades de execução, desenvolvimento e documentação do projeto.
 - **Orientadora (Dulce Mota):** Supervisão académica, apoio técnico-científico e validação dos entregáveis.
 - **Co-orientador (Constantino Martins):** Supervisão académica, apoio técnico-científico e validação dos entregáveis.
 - **Utilizadores Finais:** Participação em testes e recolha de feedback, com elevado interesse no protótipo final.
- **Recursos Tecnológicos:**
 - **Infraestrutura Computacional:** Computador pessoal com capacidade de processamento para execução local de modelos leves e acesso a API na *cloud* (OpenAI/Llama);
 - **Software:** IDE de desenvolvimento (*VS Code*) e ferramentas de gestão de projeto (*MS Project*).
 - **Dados:** Acesso a *datasets* abertos (*OpenFDA*, *DrugBank*) e ferramentas de geração de dados sintéticos (*Synthea*) para contornar a escassez de dados clínicos reais acessíveis.
- **Recursos Financeiros:**
 - **Formações em Inteligência Artificial:** 0€ - 50€

- Cursos online em IA (e.g., Coursera, Udemy) para reforço de competências técnicas.
- **Treino de Modelos de IA:** 0€ - 50€
 - Custos de computação em *cloud* para treino de modelos.
- **Ferramentas de Desenvolvimento Adicionais:** 0€ - 50€
 - Licenças ou aquisições de software complementar, caso necessário.

Deste modo, a gestão eficiente destes recursos é essencial para garantir que as diferentes fases do projeto decorrem sem interrupções, respeitando as restrições orçamentais e prazos definidos.

E.4.4 Monitorização e Controlo

A monitorização e controlo do projeto foram estruturados para garantir um acompanhamento contínuo do progresso, a identificação atempada de bloqueios e o alinhamento rigoroso com os objetivos científicos definidos.

Desde o início da unidade curricular, foram estabelecidas reuniões regulares de ponto de situação com a equipa de orientação, composta pela Prof.^a Dulce Mota e pelo Prof. Constantino Martins. Estas sessões têm como foco principal a validação do trabalho desenvolvido, garantindo o alinhamento do projeto com os requisitos académicos e ajustando o planeamento conforme necessário.

Estas sessões de acompanhamento permitem:

- **Validação Científica:** Discussão crítica sobre a revisão da literatura e a adequação da arquitetura proposta.
- **Controlo do Cronograma:** Revisão dos marcos (*milestones*) e verificação do cumprimento dos prazos dos entregáveis de PREPD.
- **Gestão de Riscos:** Identificação precoce de desafios técnicos, nomeadamente na integração das API e na normalização dos dados clínicos.
- **Feedback Contínuo:** Ajustes e melhorias na escrita do relatório e na conceção do protótipo.

Assim sendo, as reuniões quinzenais com a equipa de orientação asseguram que o projeto se mantém alinhado aos objetivos pretendidos e promove uma abordagem equilibrada entre a inovação tecnológica e o rigor ético exigido na área da saúde.

E.5 Conclusões do Planeamento

O processo de planeamento constituiu-se como um passo fundamental para a estruturação do projeto e para a identificação e análise das possíveis dificuldades que poderiam dificultar o desenvolvimento do mesmo. Em relação à categorização dos riscos e, especialmente, às questões éticas relacionadas com a privacidade dos dados (RGPD) e ao riscos técnicos relacionados com "alucinações" em IA, formulou-se um plano eficaz para mitigar estes riscos através dos dados sintéticos e o uso de técnicas como RAG.

E uma gestão de competências que demonstrou que era necessário aprofundar conhecimentos tecnológicos (plano de autoformação), que constituem aspetos fundamentais para o melhoramento da qualidade técnica.

A Estrutura de Análise de Projetos de PREPD, ajuda a ter uma perspetiva dos diferentes tópicos e fases definidas sobre o seu desenvolvimento deste projeto, sendo distinguidas no diagrama de *Gantt* a fase da entrega teórica de PREPD e a fase de desenvolvimento prático de DIMEI.

Relativamente aos recursos, a garantia de acesso a bases de dados abertas, como OpenFDA, DrugBank, juntamente com dados sintéticos, Synthea, garante viabilidade na implementação, superando o desafio de acesso a dados hospitalares reais. Sendo um dos principais fatores de sucesso para este projeto a realização de reuniões quinzenais com a equipa de orientação.

Em suma, o planeamento efetuado apresenta bases sólidas para o desenvolvimento do sistema de recomendações e alertas, porque tenta mitigar o risco principal e garante um percurso alinhado ao objetivo principal de ajudar o profissional de saúde na diminuição de erros de prescrições médicas.